法律声明

- 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，小象学院和主讲老师拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意及内容，我们保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：小象
  - 新浪微博：ChinaHadoop

矩阵和线性代数

小象学院 ChinaHadoop.cn

邹博

主要内容

- 偏度/峰度示例
- 统计量的无偏性
- 矩阵
  - 矩阵的乘法/状态转移矩阵
  - 矩阵和向量组
- 特征值和特征向量
  - 正定
- 矩阵求导
  - 向量对向量的导数
  - 标量对向量的导数

统计参数的总结

- 均值(期望，一阶)
- 方差(标准差，二阶)
- 变异系数(Coefficient of Variation)
  - 标准差与平均数的比值称为变异系数，记为C·V
- 偏度Skewness(三阶)
- 峰度Kurtosis(四阶)

偏度

- 三阶累积量与二阶累积量的1.5次方的比率。

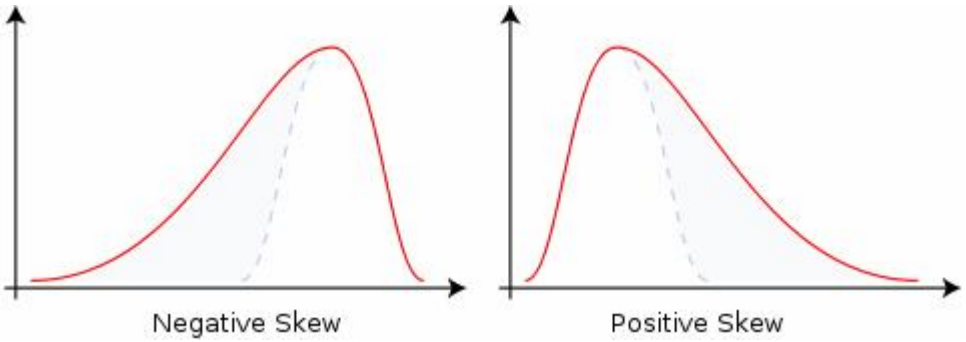

$$\gamma_1 = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{E\left[(X-\mu)^3\right]}{\left(E\left[(X-\mu)^2\right]\right)^{3/2}} = \frac{\kappa_3}{\kappa_2^{3/2}}$$

$$\gamma_1 = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{E\left[X^3\right]-3\mu E\left[X^2\right]+2\mu^2}{\sigma^3} = \frac{E\left[X^3\right]-3\mu\sigma^2-\mu^3}{\sigma^3}$$

峰度 $\frac{\mu_4}{\sigma^4}$

- 峰度是概率密度在均值处峰值高低的特征，通常定义四阶中心矩除以方差的平方减3。

$$\gamma_2 = \frac{\kappa_4}{\kappa_2^2} = \frac{\mu_4}{\sigma^4} - 3 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^4}{\left(\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^2} - 3$$

- $\frac{\mu_4}{\sigma^4}$ 也被称为超值峰度(excess kurtosis)。
  - “减3”是为了让正态分布的峰度为0。

Code

- 均值/方差
- 偏度/峰度

```python
import matplotlib.pyplot as plt
import math
import numpy as np


def calc(data):
    n = len(data)
    niu = 0.0
    niu2 = 0.0
    niu3 = 0.0
    for a in data:
        niu += a
        niu2 += a**2
        niu3 += a**3
    niu /= n
    niu2 /= n
    niu3 /= n
    sigma = math.sqrt(niu2 - niu*niu)
    return [niu, sigma, niu3]
```

```python
def calc_stat(data):
    [niu, sigma, niu3] = calc(data)
    n = len(data)
    niu4 = 0.0
    for a in data:
        a -= niu
        niu4 += a ** 4
    niu4 /= n

    skew = (niu3 - 3*niu*sigma**2 - niu**3) / (sigma**3)
    kurt = niu4 / (sigma**4)
    return [niu, sigma, skew, kurt]
```

统计量Code

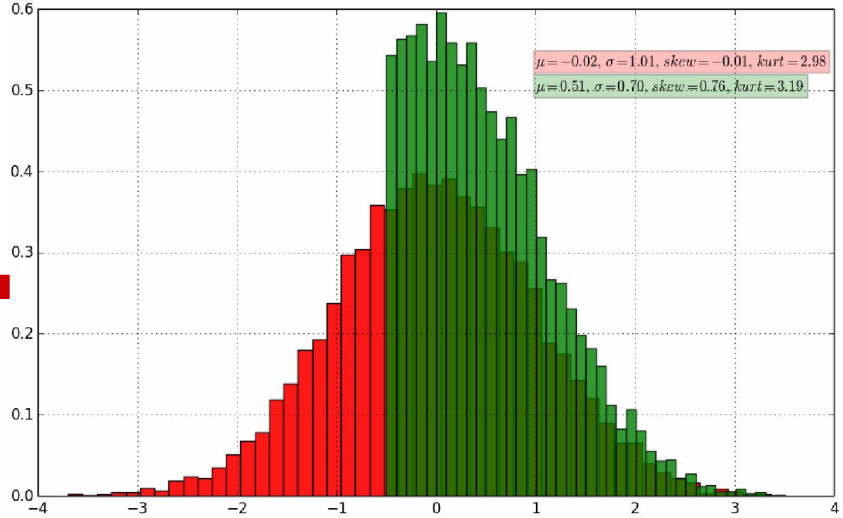


```
if __name__ == "__main__":
    data = list(np.random.randn(10000))
    data2 = list(2*np.random.randn(10000))
    data3 = [x for x in data if x > -0.5]
    data4 = list(np.random.uniform(0, 4, 10000))
    [niu, sigma, skew, kurt] = calc_stat(data)
    [niu2, sigma2, skew2, kurt2] = calc_stat(data2)
    [niu3, sigma3, skew3, kurt3] = calc_stat(data3)
    [niu4, sigma4, skew4, kurt4] = calc_stat(data4)
    print niu, sigma, skew, kurt
    print niu2, sigma2, skew2, kurt2
    print niu3, sigma3, skew3, kurt3
    print niu4, sigma4, skew4, kurt4

    info = r'$\mu=%.2f,\ \sigma=%.2f,\ skew=%.2f,\ kurt=%.2f$' % (niu, sigma, skew, kurt)
    info2 = r'$\mu=%.2f,\ \sigma=%.2f,\ skew=%.2f,\ kurt=%.2f$' % (niu2, sigma2, skew2, kurt2)
    plt.text(1, 0.38, info, bbox=dict(facecolor='red', alpha=0.25))
    plt.text(1, 0.35, info2, bbox=dict(facecolor='green', alpha=0.25))
    plt.hist(data, 50, normed=True, facecolor='r', alpha=0.9)
    plt.hist(data2, 80, normed=True, facecolor='g', alpha=0.8)
    plt.grid(True)
    plt.show()
```

数据分析

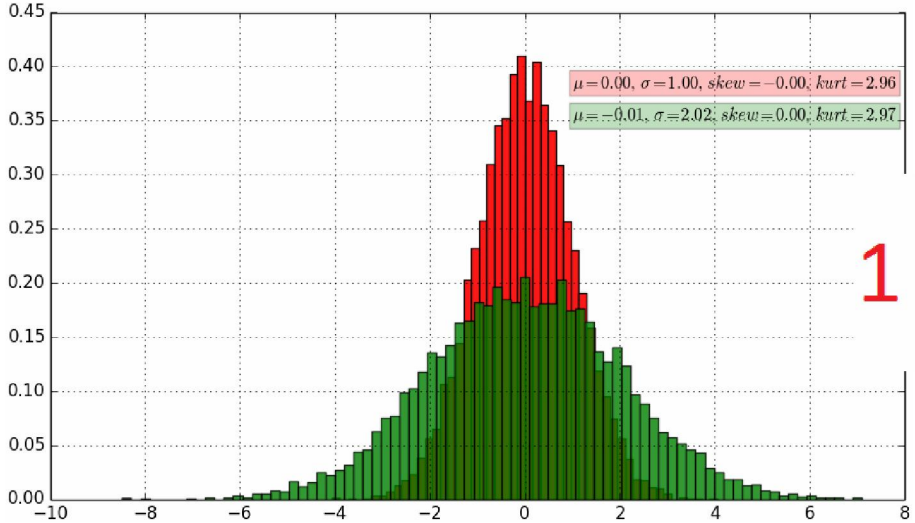

1

2

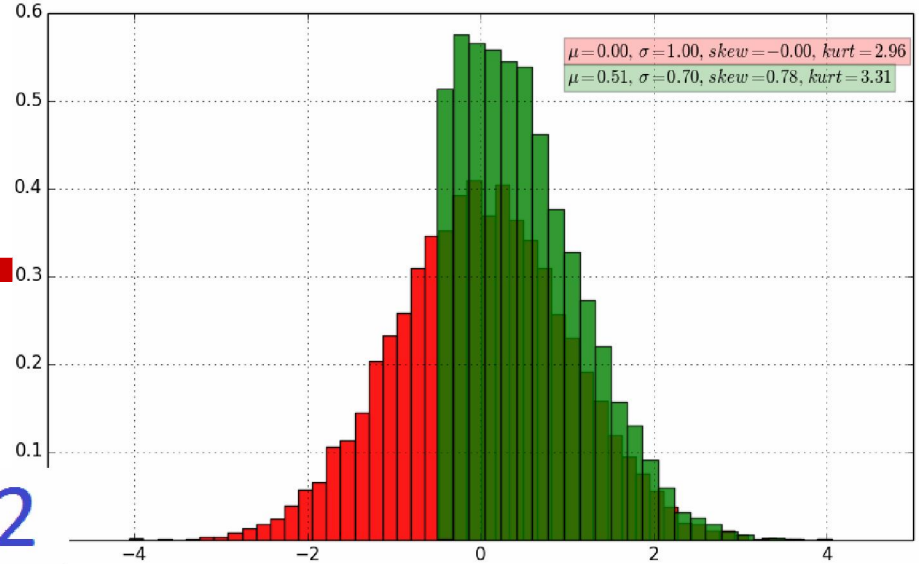

3

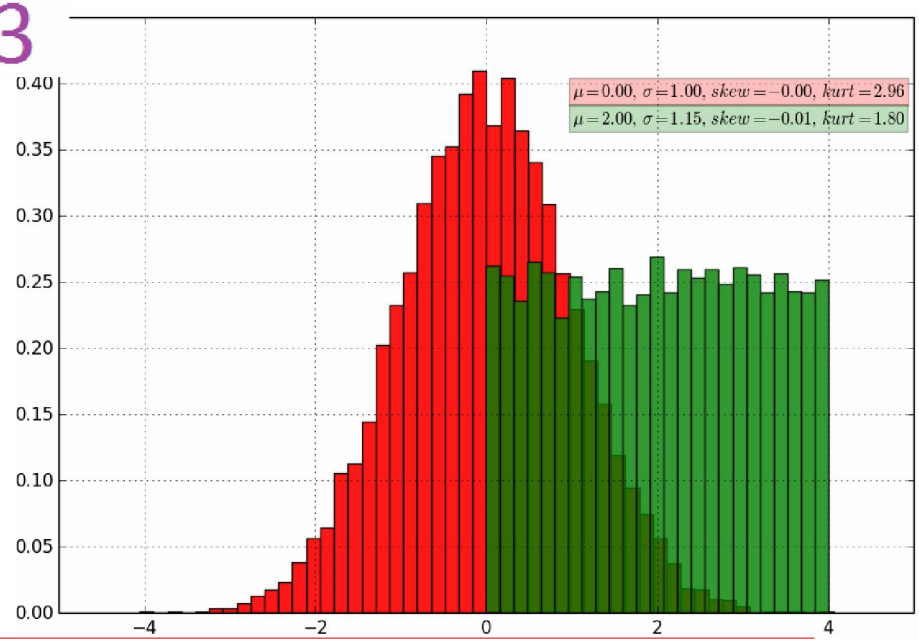

0.0029 1.0001 -0.0040 2.9643
-0.0137 2.0208 0.0046 2.9748
0.5134 0.6962 0.7825 3.3052
2.0016 1.1548 -0.0107 1.8012

实践中的例子

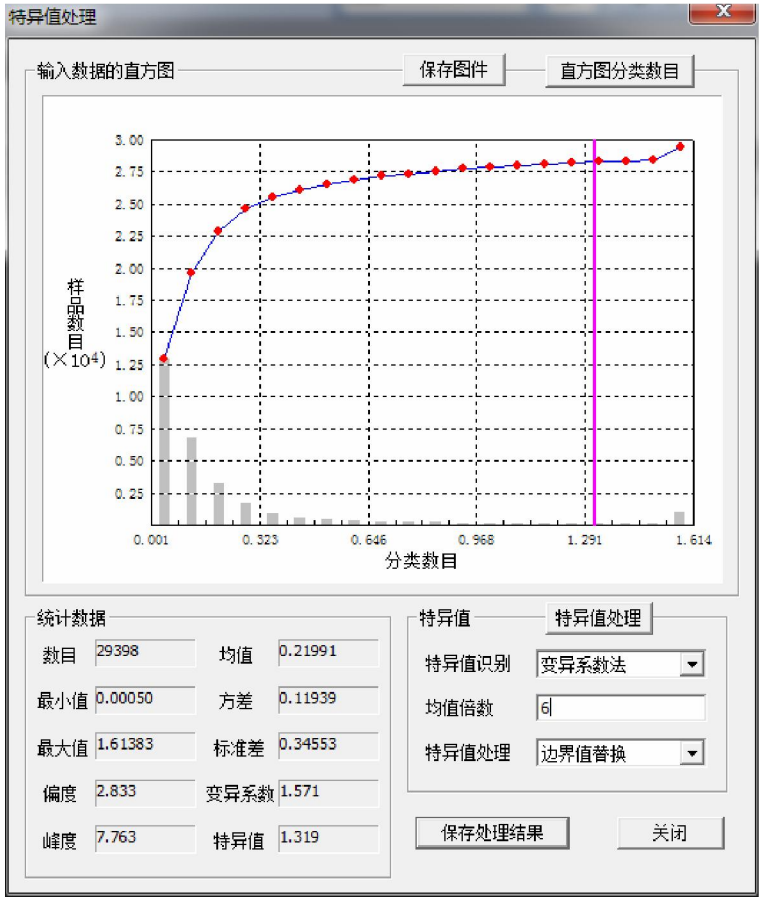
特异值处理
输入数据的直方图
保存图件
直方图分类数目
样品数目 (×10⁴)
分类数目
统计数据
数目 29398
均值 0.21991
最小值 0.00050
方差 0.11939
最大值 1.61383
标准差 0.34553
偏度 2.833
变异系数 1.571
峰度 7.763
特异值 1.319
特异值
特异值处理
特异值识别 变异系数法
均值倍数 6
特异值处理 边界值替换
保存处理结果
关闭

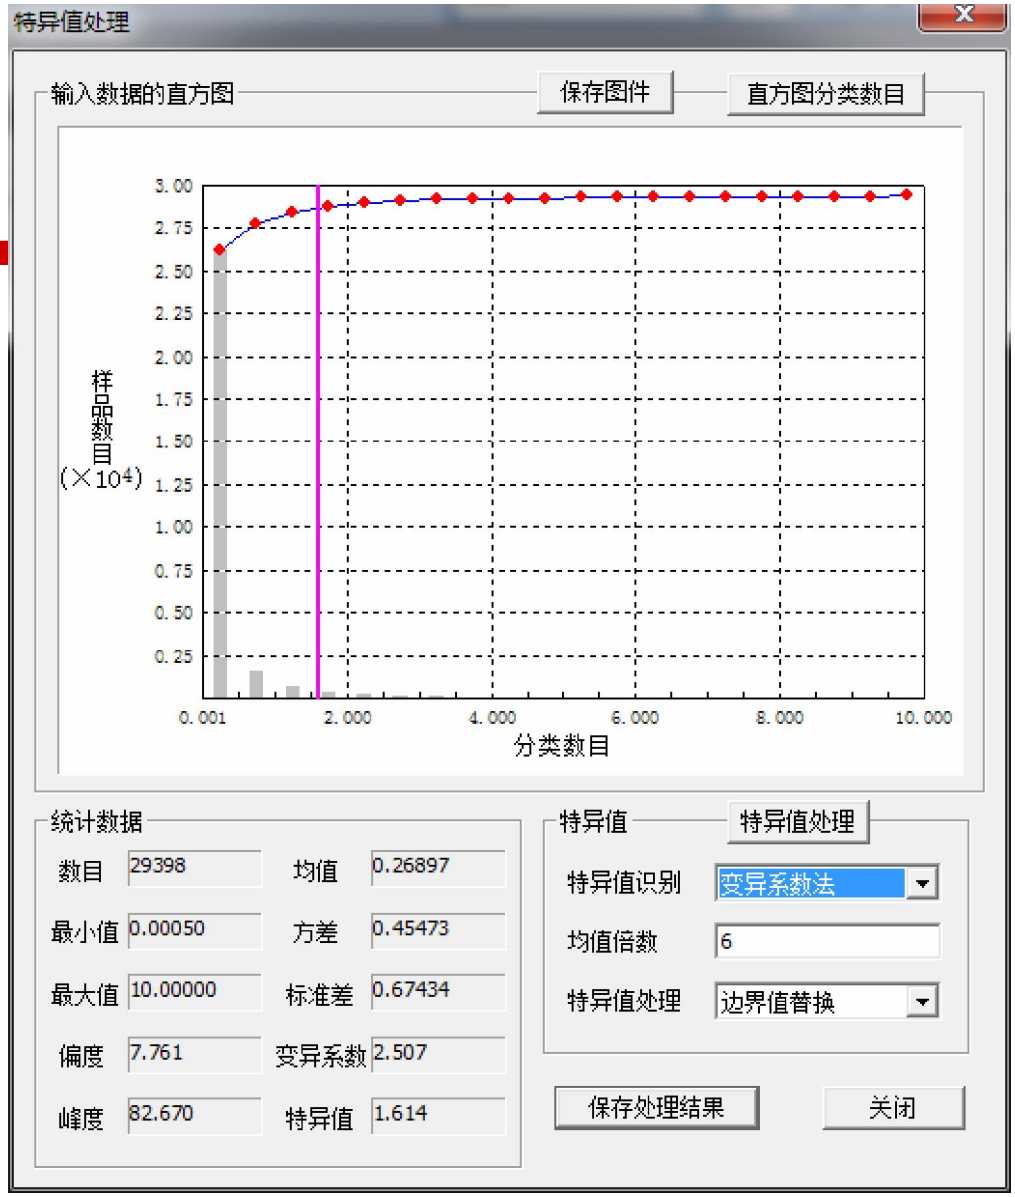
特异值处理
输入数据的直方图
保存图件
直方图分类数目
样品数目 (×10⁴)
分类数目
统计数据
数目 29398
均值 0.26897
最小值 0.00050
方差 0.45473
最大值 10.00000
标准差 0.67434
偏度 7.761
变异系数 2.507
峰度 82.670
特异值 1.614
特异值
特异值处理
特异值识别 变异系数法
均值倍数 6
特异值处理 边界值替换
保存处理结果
关闭

无偏性 $E(\hat{\theta})=\theta$

- 利用已知样本$X_1,X_2,\cdots X_n$能够得到参数的一个估计$\hat{\theta}$，因此，$\hat{\theta}$可以写成$\hat{\theta}(X_1,X_2,\cdots X_n)$，对于不同的样本，$\hat{\theta}$的值一般不同。因此，可以看成是关于样本的随机变量。它是可以求均值的：$E(\hat{\theta})$
- 如果$E(\hat{\theta})$等于总体的实际分布θ，就说这个估计是无偏估计。$E(\hat{\theta})=\theta$
  - 用$\hat{\theta}$去估计θ，有时偏高，有时偏低，但平均来说，它等于未知参数θ

举例

- 无偏估计

$$\hat{\mu} = X_1$$

$$\hat{\mu} = \frac{X_1 + X_2}{2}$$

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

- 不是无偏估计

$$\hat{\mu} = 2X_1$$

$$\hat{\mu} = \frac{X_1 + X_2}{3}$$

$$\hat{\mu} = \frac{1}{n-3}\sum_{i=1}^{n} X_i$$

样本均值和方差是总体的无偏估计

- 设总体均值为 μ，方差为 σ^2，$X_1, X_2, \ldots X_n$ 为来自该总体的样本，即：

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

- 则：

$$E\left(\overline{X}\right) = \mu$$

$$E\left(S^2\right) = \sigma^2$$

均值的无偏性

- 因为$X_1,X_2,\ldots X_n$为同分布的，于是$E(X_i)=\mu$，所以：

$$E(\overline{X})=E\left(\frac{1}{n}\sum_{i=1}^{n}X_i\right)=\frac{1}{n}E\left(\sum_{i=1}^{n}X_i\right)=\frac{1}{n}\sum_{i=1}^{n}E(X_i)=\frac{1}{n}\cdot n\mu=\mu$$

计算 $\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2$

$$\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2=\frac{1}{n}\sum_{i=1}^{n}\left[\left(X_i-\mu\right)+\left(\mu-\overline{X}\right)\right]^2$$

$$=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\mu\right)^2+\frac{2}{n}\sum_{i=1}^{n}\left(X_i-\mu\right)\left(\mu-\overline{X}\right)+\frac{1}{n}\sum_{i=1}^{n}\left(\mu-\overline{X}\right)^2$$

$$=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\mu\right)^2+2\left(\overline{X}-\mu\right)\left(\mu-\overline{X}\right)+\left(\mu-\overline{X}\right)^2$$

$$=\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\mu\right)^2-\left(\mu-\overline{X}\right)^2$$

$$\leq\frac{1}{n}\sum_{i=1}^{n}\left(X_i-\mu\right)^2=\sigma^2$$

方差的无偏性 $\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\overline{X})^2$

- 首先 $Var(\overline{X})=Var\left(\frac{1}{n}\sum_{i=1}^{n}X_i\right)=\frac{1}{n^2}Var\left(\sum_{i=1}^{n}X_i\right)=\frac{1}{n^2}\sum_{i=1}^{n}Var(X_i)=\frac{\sigma^2}{n}$
- 因此 $E(\overline{X}^2)=Var(\overline{X})+[E(\overline{X})]^2=\frac{\sigma^2}{n}+\mu^2$

  $E(X_i^2)=Var(X_i)+[E(X_i)]^2=\sigma^2+\mu^2$
- 而

$$\sum_{i=1}^{n}(X_i-\overline{X})^2=\sum_{i=1}^{n}X_i^2-2\left(\sum_{i=1}^{n}X_i\right)\overline{X}+n\overline{X}^2=\sum_{i=1}^{n}X_i^2-2(n\overline{X})\cdot\overline{X}+n\overline{X}^2=\sum_{i=1}^{n}X_i^2-n\overline{X}^2$$

- 所以

$$E(S^2)=\frac{1}{n-1}\left[E\left(\sum_{i=1}^{n}X_i^2\right)-nE(\overline{X}^2)\right]=\frac{1}{n-1}\left[(n\sigma^2+n\mu^2)-n\left(\frac{\sigma^2}{n}+\mu^2\right)\right]=\sigma^2$$

均方误差准则 $MSE(\hat{\theta}) = E\left[(\hat{\theta}-\theta)^2\right]$

- 用估计量 $\hat{\theta}$ 去估计θ，其误差是 $\hat{\theta}-\theta$，该误差显然随样本 $X_1, X_2, \cdots X_n$ 而定，因此，$\hat{\theta}-\theta$ 是随机变量，它的平方的均值，称作均方误差。这个量越小，平均误差越小，估计结果越优。

$$MSE(\hat{\theta}) = E\left[(\hat{\theta}-\theta)^2\right]$$

- 显然，若 $\hat{\theta}$ 是无偏估计，则MSE即方差。

$$MSE(\hat{\theta}) = E\left[(\hat{\theta}-\theta)^2\right] = E\left[(\hat{\theta}-E(\hat{\theta}))^2\right] = Var(\hat{\theta})$$

线性代数

- 定义：方阵的行列式
  - 1阶方阵的行列式为该元素本身
  - n阶方阵的行列式等于它的任一行(或列)的各元素与其对应的代数余子式乘积之和。

范德蒙行列式Vandermonde

- 证明范德蒙行列式Vandermonde：

$$D_n = \begin{vmatrix} 1 & 1 & 1 & \cdots & 1 \\ x_1 & x_2 & x_3 & \cdots & x_n \\ x_1^2 & x_2^2 & x_3^2 & \cdots & x_n^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_1^{n-1} & x_2^{n-1} & x_3^{n-1} & \cdots & x_n^{n-1} \end{vmatrix} = \prod_{n \ge i \ge j \ge 1} (x_i - x_j)$$

  - 提示：数学归纳法
  - 注：参考Lagrange/Newton插值法

矩阵的乘法

- A为m×s阶的矩阵，B为s×n阶的矩阵，那么，C=A×B是m×n阶的矩阵，其中，

$$c_{ij} = \sum_{k=1}^{s} a_{ik} b_{kj}$$

矩阵模型

- 考虑某随机过程π，它的状态有n个，用1~n表示。记在当前时刻t时位于i状态，它在t+1时刻位于j状态的概率为P(i,j)=P(j|i)：
  - 即状态转移的概率只依赖于前一个状态。

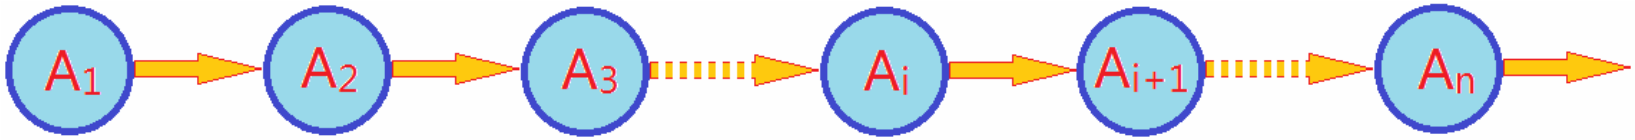

举例

- 假定按照经济状况将人群分成上、中、下三个阶层，用1、2、3表示。假定当前处于某阶层只和上一代有关，即：考察父代为第i阶层，则子代为第j阶层的概率。假定为如下转移概率矩阵：

$$
\begin{array}{cc}
P & \text{子代} \\
\text{父代} & \begin{bmatrix} 0.65 & 0.28 & 0.07 \\ 0.15 & 0.67 & 0.18 \\ 0.12 & 0.36 & 0.52 \end{bmatrix}
\end{array}
$$

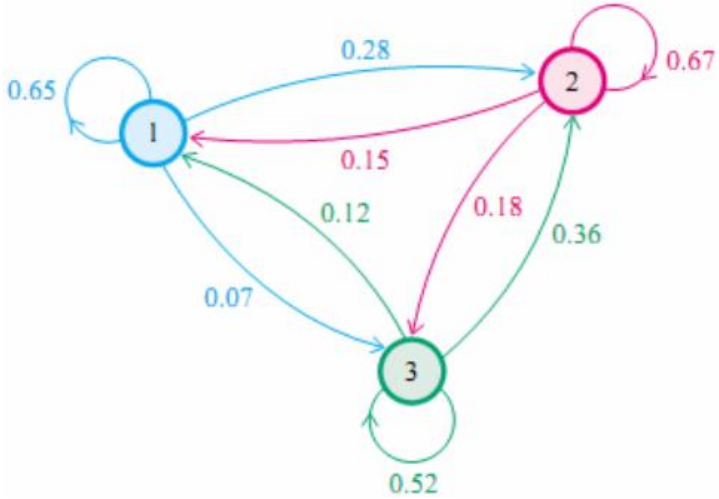

概率转移矩阵

- 第n+1代中处于第j个阶层的概率为：

$$\pi(X_{n+1}=j)=\sum_{i=1}^{K}\pi(X_n=i)\cdot P(X_{n+1}=j\mid X_n=i)$$

$$\Rightarrow \pi^{(n+1)}=\pi^{(n)}\cdot P$$

- 因此，矩阵P即为(条件)概率转移矩阵。
  - 第i行元素表示：在上一个状态为i时的分布概率，即：每一行元素的和为1。
- 思考：初始概率分布π对最终分布的影响？

探索：初始概率 π = [0.21, 0.68, 0.1]迭代

第n代	第1阶层	第2阶层	第3阶层
0	0.21	0.68	0.11
1	0.252	0.554	0.194
2	0.27	0.512	0.218
3	0.278	0.497	0.225
4	0.282	0.49	0.226
5	0.285	0.489	0.225
6	0.286	0.489	0.225
7	0.286	0.489	0.225
8	0.286	0.488	0.225
9	0.286	0.489	0.225
10	0.286	0.489	0.225

初始概率 π = [0.75, 0.15, 0.1]的迭代结果

第n代	第1阶层	第2阶层	第3阶层
0	0.75	0.15	0.1
1	0.522	0.347	0.132
2	0.407	0.426	0.167
3	0.349	0.459	0.192
4	0.318	0.475	0.207
5	0.303	0.482	0.215
6	0.295	0.485	0.22
7	0.291	0.487	0.222
8	0.289	0.488	0.225
9	0.286	0.489	0.225
10	0.286	0.489	0.225

平稳分布

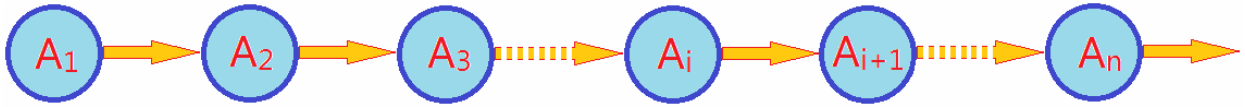

- 初始概率不同，但经过若干次迭代， π 最终稳定收敛在某个分布上。
- 从而，这是转移概率矩阵P的性质，而非初始分布的性质。事实上，上述矩阵P的n次幂，每行都是(0.286,0.489,0.225)，n>20
- 如果一个非周期马尔科夫随机过程具有转移概率矩阵P，且它的任意两个状态都是连通的，则 $\lim_{n\to\infty} P_{ij}^{n}$ 存在，记做 $\lim_{n\to\infty} P_{ij}^{n} = \pi(j)$ 。

平稳分布

- 事实上，下面两种写法等价：

$$\lim_{n\to\infty} P_{ij}^{n} = \pi(j) \qquad \lim_{n\to\infty} P^{n} = \begin{bmatrix} \pi(1) & \pi(2) & \dots & \pi(n) \\ \pi(1) & \pi(2) & \dots & \pi(n) \\ \vdots & \vdots & \ddots & \vdots \\ \pi(1) & \pi(2) & \cdots & \pi(n) \end{bmatrix}$$

- 同时，若某概率分布 $\pi P=\pi$，说明
  - 该多项分布 π 是状态转移矩阵P的平稳分布；
  - 线性方程xP=x的非负解为 π，而 P^n 唯一，因此 π 是线性方程xP=x的唯一非负解。
  - 该问题将在马尔科夫模型中继续探讨。

思考

- 根据定义来计算 $C=A\times B$，需要$m*n*s$次乘法。
  - 即：若A、B都是n阶方阵，C的计算时间复杂度为$O(n^3)$
  - 问：可否设计更快的算法？
- 三个矩阵A、B、C的阶分别是$a_0\times a_1$, $a_1\times a_2$, $a_2\times a_3$，从而$(A\times B)\times C$和$A\times(B\times C)$的乘法次数是$a_0a_1a_2+a_0a_2a_3$、$a_1a_2a_3+a_0a_1a_3$，二者一般情况是不相等的。
  - 问：给定n个矩阵的连乘积：$A_1\times A_2\times A_3\ldots\ldots\times A_n$，如何添加括号来改变计算次序，使得乘法的计算量最小？

Code

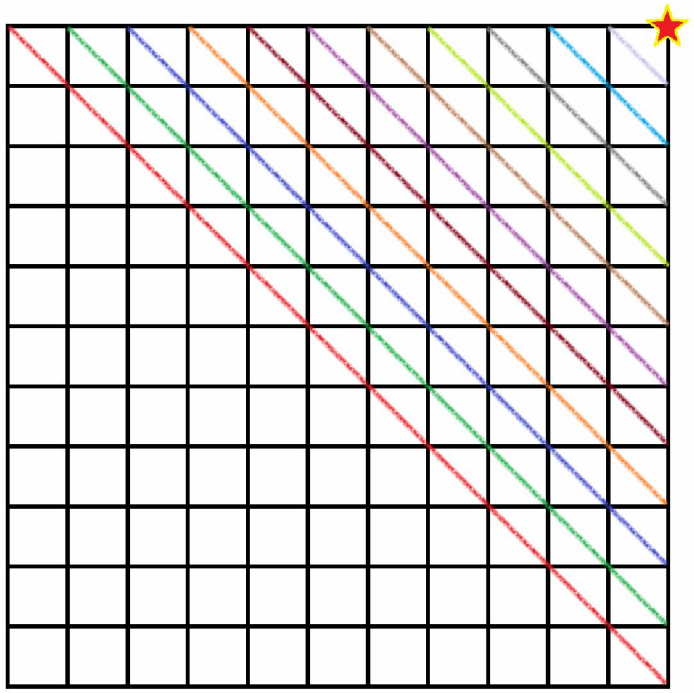

```
//p[0...n]存储了n+1个数，其中，(p[i-1],p[i])是矩阵i的阶；
//s[i][j]记录A[i...j]从什么位置断开；m[i][j]记录数乘最小值
void MatrixMultiply(int* p, int n, int** m, int** s)
{
    int r,i,j,k,t;
    for(i = 1; i <= n; i++)
        m[i][i] = 0;

    //r个连续矩阵的连乘：上面的初始化，相当于r=1
    for(r = 2; r <= n; r++)
    {
        for(i = 1; i <= n-r+1; i++)
        {
            j=i+r-1;
            m[i][j] = m[i+1][j]+ p[i-1]*p[i]*p[j];
            s[i][j] = i;
            for(k = i+1; k < j; k++)
            {
                t = m[i][k] + m[k+1][j] + p[i-1]*p[k]*p[j];
                if(t < m[i][j])
                {
                    m[i][j] = t;
                    s[i][j] = k;
                }
            }
        }
    }
}
```

矩阵和向量的乘法

- A为m×n的矩阵， x为n×1的列向量，则Ax为m×1的列向量，记 $\vec{y} = A \cdot \vec{x}$
- 由于n维列向量和n维空间的点一一对应，上式实际给出了从n维空间的点到m为空间点的线性变换。
  - 旋转、平移
- 特殊的，若m=n，且A为行列式为1的方阵，x为模为1的列向量，则完成了n维空间点的旋转变换。

矩阵和向量的乘法应用

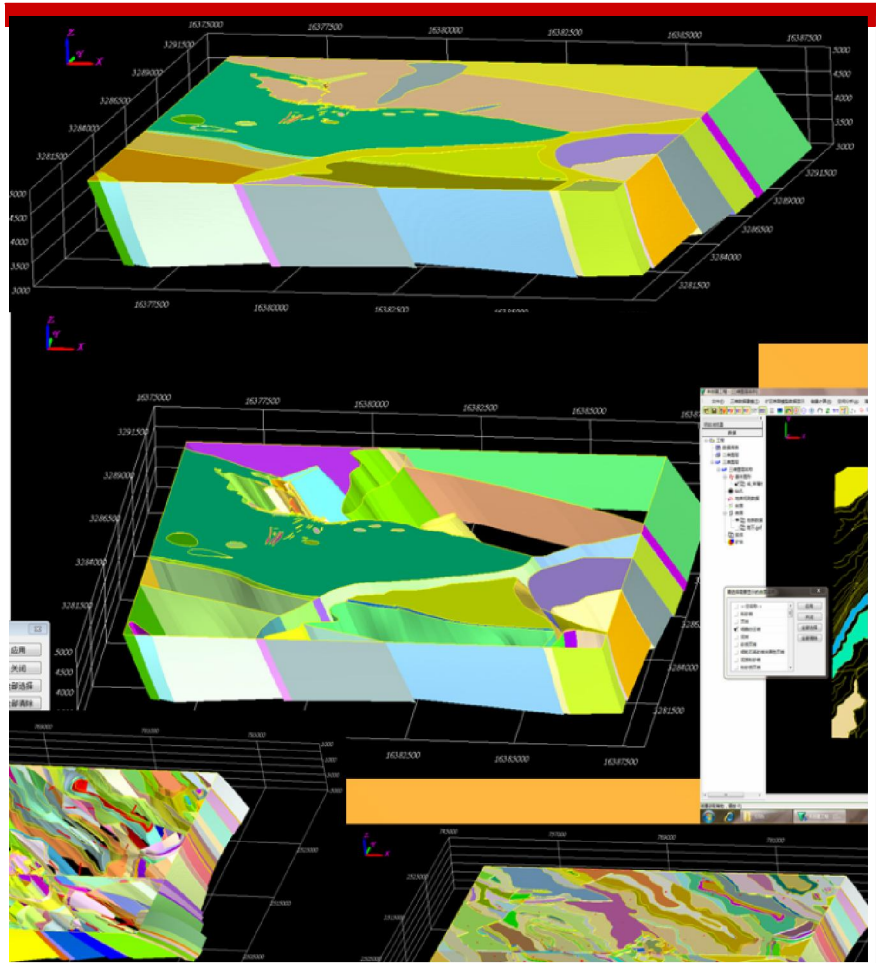

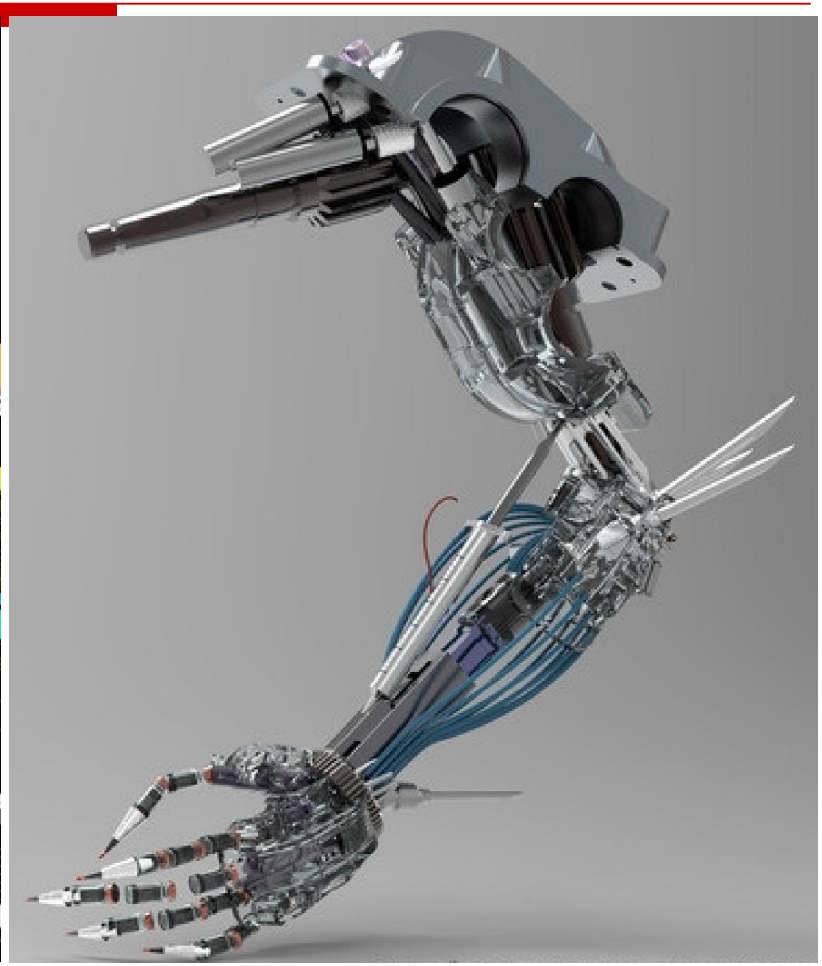

矩阵的秩

- 在m×n矩阵A中，任取k行k列，不改变这k^2个元素在A中的次序，得到k阶方阵，称为矩阵A的k阶子式。
  - 显然，m×n矩阵A的k阶子式有$C_m^k C_n^k$个。
- 设在矩阵A中有一个不等于0的r阶子式D，且所有r+1阶子式(如果存在的话)全等于0，那么，D称为矩阵A的最高阶非零子式，r称为矩阵A的秩，记做R(A)=r。
  - n×n的可逆矩阵，秩为n
  - 可逆矩阵又称满秩矩阵
  - 矩阵的秩等于它行(列)向量组的秩

秩与线性方程组的解的关系

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \cdots\cdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m \end{cases}$$

$$Ax = b$$

- 对于n元线性方程组Ax=b，
  - 无解的充要条件是R(A)<R(A,b)
  - 有唯一解的充要条件是R(A)=R(A,b)=n
  - 有无限多解的充要条件是R(A)=R(A,b)<n

推论

- $Ax=0$有非零解的充要条件是$R(A)<n$
- $Ax=b$有解的充要条件是$R(A)=R(A,b)$

向量组等价

- 向量b能由向量组A:$a_1,a_2,\ldots,a_m$线性表示的充要条件是矩阵$A=(a_1,a_2,\ldots a_m)$的秩等于矩阵$B=(a_1,a_2,\ldots a_m,b)$的秩。
- 设有两个向量组A:$a_1,a_2,\ldots,a_m$及B:$b_1,b_2,\ldots,b_n$，若B组的向量都能由向量组A线性表示，则称向量组B能由向量组A线性表示。若向量组A与向量组B能相互线性表示，则称两个向量组等价。

系数矩阵

- 将向量组A和B所构成的矩阵依次记做 $A=(a_1,a_2,\ldots,a_m)$和$B=(b_1,b_2,\ldots,b_n)$，B组能由A组线性表示，即对每个向量b_j，存在$k_{1j},k_{2j},\cdots k_{mj}$
- 使得

$$b_j = k_{1j}a_1 + k_{2j}a_2 + \cdots + k_{mj}a_m = \begin{pmatrix} a_1 & a_2 & \cdots & a_m \end{pmatrix} \begin{pmatrix} k_{1j} \\ k_{2j} \\ \vdots \\ k_{mj} \end{pmatrix}$$

- 从而得到系数矩阵K

$$\begin{pmatrix} b_1 & b_2 & \cdots & b_n \end{pmatrix} = \begin{pmatrix} a_1 & a_2 & \cdots & a_m \end{pmatrix} \begin{pmatrix} k_{11} & k_{12} & \cdots & k_{1n} \\ k_{21} & k_{22} & \cdots & k_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ k_{m1} & k_{m2} & \cdots & k_{mn} \end{pmatrix}$$

对C=AB的重认识

- 由此可知，若C=A×B，则矩阵C的列向量能由A的列向量线性表示，B即为这一表示的系数矩阵。
  - 对偶的，若C=A×B，则矩阵C的行向量能由B的行向量线性表示，A即为这一表示的系数矩阵
- 向量组B: $b_1,b_2,\ldots,b_n$能由向量组A: $a_1,a_2,\ldots,a_m$线性表示的充要条件是矩阵$A=(a_1,a_2,\ldots,a_m)$的秩等于矩阵$(A,B)=(a_1,a_2,\ldots,a_m,b_1,b_2,\ldots,b_n)$的秩，即：$R(A)=R(A,B)$。

正交阵

- 若n阶矩阵A满足$A^TA=I$，成A为正交矩阵，简称正交阵。
  - A是正交阵的充要条件：A的列(行)向量都是单位向量，且两两正交。
- A是正交阵，x为向量，则A·x称作正交变换。
  - 正交变换不改变向量长度

思考

- 若A、B都是n阶正交阵，那么，A×B是正交阵吗？
- 正交阵和对称阵，能够通过何种操作获得一定意义下的联系？

特征值和特征向量

- A是n阶矩阵，若数λ和n维非0列向量x满足Ax=λx，那么，数λ称为A的特征值，x称为A的对应于特征值λ的特征向量。
  - 根据定义，立刻得到$(A-\lambda I)x=0$，令关于λ的多项式$|A-\lambda I|$为0，方程$|A-\lambda I|=0$的根为A的特征值；将根λ_0带入方程组$(A-\lambda I)x=0$，求得到的非零解，即λ_0对应的特征向量。

特征值的性质

- 设n阶矩阵$A=(a_{ij})$的特征值为$\lambda_1, \lambda_2, \ldots \lambda_n$,则
- $\lambda_1+\lambda_2+\ldots+\lambda_n=a_{11}+a_{22}+\ldots+a_{nn}$
- $\lambda_1\lambda_2\ldots\lambda_n=|A|$
  - 矩阵A主行列式的元素和，称作矩阵A的迹。

思考

- 已知λ是方阵A的特征值，
- 则
  - λ^2是A^2的特征值
  - A可逆时，λ^{-1}是A^{-1}的特征值。

  - 提示：定义

不同特征值对应的特征向量

- 设 $\lambda_1, \lambda_2, \ldots, \lambda_m$ 是方阵A的m个特征值，$p_1, p_2, \ldots, p_m$ 是依次与之对应的特征向量，若 $\lambda_1, \lambda_2, \ldots, \lambda_m$ 各不相等，则 $p_1, p_2, \ldots, p_m$ 线性无关。

- 总结与思考
  - 不同特征值对应的特征向量，线性无关。
  - 若方阵A是对称阵呢？结论是否会加强？
    - 协方差矩阵、二次型矩阵、无向图的邻接矩阵等都是对称阵
    - 在谱聚类中将会有所涉及

引理

- 实对称阵的特征值是实数
  - 设复数λ为对称阵A的特征值，复向量x为对应的特征向量，即$Ax=\lambda x(x\neq 0)$
  - 用$\overline{\lambda}$表示λ的共轭复数，$\overline{x}$表示x的共轭复向量，而A是实矩阵，有$\overline{A}=A$
  - 下面给出证明过程。

证明

- 首先 $A\overline{x} = \overline{A}\overline{x} = \overline{Ax} = \overline{\lambda x} = \overline{\lambda}\overline{x}$
- 因为 $\overline{x}^T(Ax) = \overline{x}^T(Ax) = \overline{x}^T\lambda x = \lambda\overline{x}^T x$

  $\overline{x}^T(Ax) = (\overline{x}^T A^T)x = (A\overline{x})^T x = (\overline{\lambda}\overline{x})^T x = \overline{\lambda}\overline{x}^T x$
- 从而

  $$\lambda\overline{x}^T x = \overline{\lambda}\overline{x}^T x \Rightarrow (\lambda - \overline{\lambda})\overline{x}^T x = 0$$
- 而

  $$\overline{x}^T x = \sum_{i=1}^{n} \overline{x_i} x_i = \sum_{i=1}^{n} |x_i|^2 \neq 0$$
- 所以

  $$\lambda - \overline{\lambda} = 0 \Rightarrow \lambda = \overline{\lambda}$$

利用上述结论很快得到

- 将实数λ带入方程组(A- λ I)x=0，该方程组为实系数方程组，因此，实对称阵的特征向量可以取实向量。

实对称阵不同特征值的特征向量正交

- 令实对称矩阵为A，它的两个不同的特征值 λ_1 λ_2对应的特征向量分别是 μ_1 μ_2；其中，λ_1 λ_2 μ_1 μ_2都是实数或是实向量。
- 则有：$A\mu_1=\lambda_1\mu_1$，$A\mu_2=\lambda_2\mu_2$
- $(A\mu_1)^T=(\lambda_1\mu_1)^T$，从而：$\mu_1^TA=\lambda_1\mu_1^T$
- 所以：$\mu_1^TA\mu_2=\lambda_1\mu_1^T\mu_2$
- 同时，$\mu_1^TA\mu_2=\mu_1^T(A\mu_2)=\mu_1^T\lambda_2\mu_2=\lambda_2\mu_1^T\mu_2$
- 所以，$\lambda_1\mu_1^T\mu_2=\lambda_2\mu_1^T\mu_2$
- 故：$(\lambda_1-\lambda_2)\mu_1^T\mu_2=0$
- 而 $\lambda_1\neq\lambda_2$，所以 $\mu_1^T\mu_2=0$，即：μ_1，μ_2正交。

最终结论

- 设A为n阶对称阵，则必有正交阵P，使得

$$P^{-1}AP = P^{T}AP = \Lambda$$

  - Λ是以A的n个特征值为对角元的对角阵。
  - 该变换称为“合同变换”，A和Λ互为合同矩阵。

二次型

- 含有n个变量的二次齐次函数，称为二次型；
- 一个二次型对应一个对称阵；
- 而对称阵可以由正交阵对角化，
- 从而二次型可以化成只有n个变量平方项的标准型，而这个正交阵，对应着坐标系的旋转变化。

正定阵

- 对于n阶方阵A，若任意n阶向量x，都有$x^TAx>0$，则称A是正定阵。
  - 若条件变成$x^TAx\geqslant 0$，则A称作半正定阵
  - 类似还有负定阵，半负定阵。

正定阵的判定

- 对称阵A为正定阵；
- A的特征值都为正；
- A的顺序主子式大于0；
- 以上三个命题等价。

$$(a_{11}) \quad \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \quad \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$$

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

思考

- 给定任意m×n的矩阵A，证明A^TA一定是半正定方阵。
  - 该结论在线性回归中将用到。

例题：

- 给定凸锥的定义如下：

$$C\text{为凸锥} \Leftrightarrow \forall x_1, x_2 \in C, \theta_1, \theta_2 \geq 0, \text{有}\ \theta_1 x_1 + \theta_2 x_2 \in C$$

- 试证明：n阶半正定方阵的集合为凸锥。

利用定义证明

- 若A、B为n阶半正定阵，则

$$\forall \vec{z},\ \vec{z}^T A\vec{z} \geq 0,\ \vec{z}^T B\vec{z} \geq 0$$

- 从而，$\forall \theta_1, \theta_2 \geq 0,$

$$\vec{z}^T \cdot \left(\theta_1 A + \theta_2 B\right) \cdot \vec{z} = \vec{z}^T \cdot \theta_1 A \cdot \vec{z} + \vec{z}^T \cdot \theta_2 B \cdot \vec{z}$$

$$= \theta_1 \vec{z}^T A\vec{z} + \theta_2 \vec{z}^T B\vec{z} \geq 0$$

- 即：$\forall \theta_1, \theta_2 \geq 0, \theta_1 A + \theta_2 B$ 为半正定阵。从而，n阶半正定阵的集合为凸锥。

向量的导数

- A为m×n的矩阵， **x**为n×1的列向量，则A**x**为m×1的列向量，记 $\vec{y} = A \cdot \vec{x}$
- 思考： $\dfrac{\partial \vec{y}}{\partial \vec{x}} = ?$

推导

- 令

$$A=\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \quad \vec{x}=\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad A\cdot\vec{x}=\begin{pmatrix} a_{11}x_1+a_{12}x_2+\cdots+a_{1n}x_n \\ a_{21}x_1+a_{22}x_2+\cdots+a_{2n}x_n \\ \vdots \\ a_{m1}x_1+a_{m2}x_2+\cdots+a_{mn}x_n \end{pmatrix}$$

- 从而，

$$\frac{\partial\vec{y}}{\partial\vec{x}}=\frac{\partial A\vec{x}}{\partial\vec{x}}=\begin{bmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{bmatrix}=A^T$$

结论与直接推广

- 向量偏导公式：

$$\frac{\partial A\vec{x}}{\partial \vec{x}} = A^T$$

$$\frac{\partial A\vec{x}}{\partial \vec{x}^T} = A$$

$$\frac{\partial\left(\vec{x}^T A\right)}{\partial \vec{x}} = A$$

- 在线性回归中将直接使用该公式。

标量对向量的导数

- A为n×n的矩阵， x为n×1的列向量，
- 记 $y = \vec{x}^T \cdot A \cdot \vec{x}$
- 同理可得： $$\frac{\partial y}{\partial \vec{x}} = \frac{\partial\left(\vec{x}^T \cdot A \cdot \vec{x}\right)}{\partial \vec{x}} = \left(A^T + A\right) \cdot \vec{x}$$
- 若A为对称阵，则有 $$\frac{\partial\left(\vec{x}^T A \vec{x}\right)}{\partial \vec{x}} = 2A\vec{x}$$

附：推导 $\frac{\partial y}{\partial \vec{x}} = \frac{\partial\left(\vec{x}^T \cdot A \cdot \vec{x}\right)}{\partial \vec{x}} = \left(A^T + A\right) \cdot \vec{x}$

- 记：

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \qquad \vec{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

- 有：

$$\vec{x}^T A \cdot \vec{x} = \begin{pmatrix} x_1 & x_2 & \cdots & x_n \end{pmatrix} \cdot \begin{pmatrix} \sum_{j=1}^{n} a_{1j} x_j & \sum_{j=1}^{n} a_{2j} x_j & \cdots & \sum_{j=1}^{n} a_{n,j} x_j \end{pmatrix}^T$$

$$= \sum_{i=1}^{n} \left(\left(\sum_{j=1}^{n} a_{ij} x_j \right) x_i \right) = \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} x_i x_j$$

- 则：

$$\frac{\partial\left(\vec{x}^T A \cdot \vec{x}\right)}{\partial x_i} = \left(\sum_{j=1}^{n} a_{ij} x_j \right) + \left(\sum_{j=1}^{n} a_{ji} x_j \right) = \sum_{j=1}^{n} \left(a_{ij} + a_{ji}\right) x_j$$

延伸算法题

- 根据定义来计算 $C=A\times B$，需要$m*n*s$次乘法。
  - 即：若A、B都是n阶方阵，C的计算时间复杂度为$O(n^3)$
  - 问：可否设计更快的算法？
- 三个矩阵A、B、C的阶分别是$a_0\times a_1$, $a_1\times a_2$, $a_2\times a_3$，从而$(A\times B)\times C$和$A\times(B\times C)$的乘法次数是$a_0a_1a_2+a_0a_2a_3$、 $a_1a_2a_3+a_0a_1a_3$，二者一般情况是不相等的。
  - 问：给定n个矩阵的连乘积：$A_1\times A_2\times A_3\ldots\ldots\times A_n$，如何添加括号来改变计算次序，使得乘法的计算量最小？

附：统计数字的概率

- 给定某正整数N，统计从1到N!的所有数中，首位数字出现1的概率。
- 进而，可以计算首位数字是2的概率，是3的概率，从而得到一条“九点分布”。

Code

```python
def first_number(n):
    while n >= 10:
        n = n / 10
    return n
```

```python
def second_number(n):
    while n >= 100:
        n = n / 10
    return n % 10
```

```python
if __name__ == "__main__":
    n = 1
    frequency = [0 for x in range(0,10,1)]
    for i in range(1,10000,1):
        n = n * i
        m = first_number(n)
        frequency[m] += 1
    print frequency
    plt.plot(frequency, "r-", linewidth=2)
    plt.plot(frequency, "go", markersize=8)
    plt.grid(True)
    plt.show()
```

数字的概率[1243/1146/1112/1016/984/951/965/872/859/851]

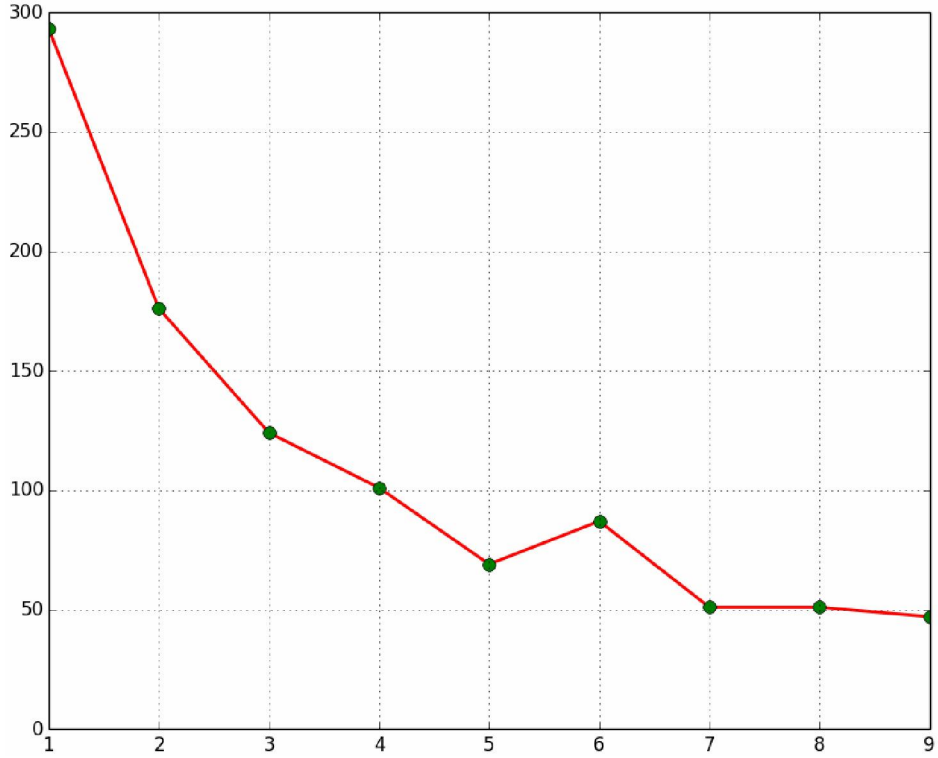

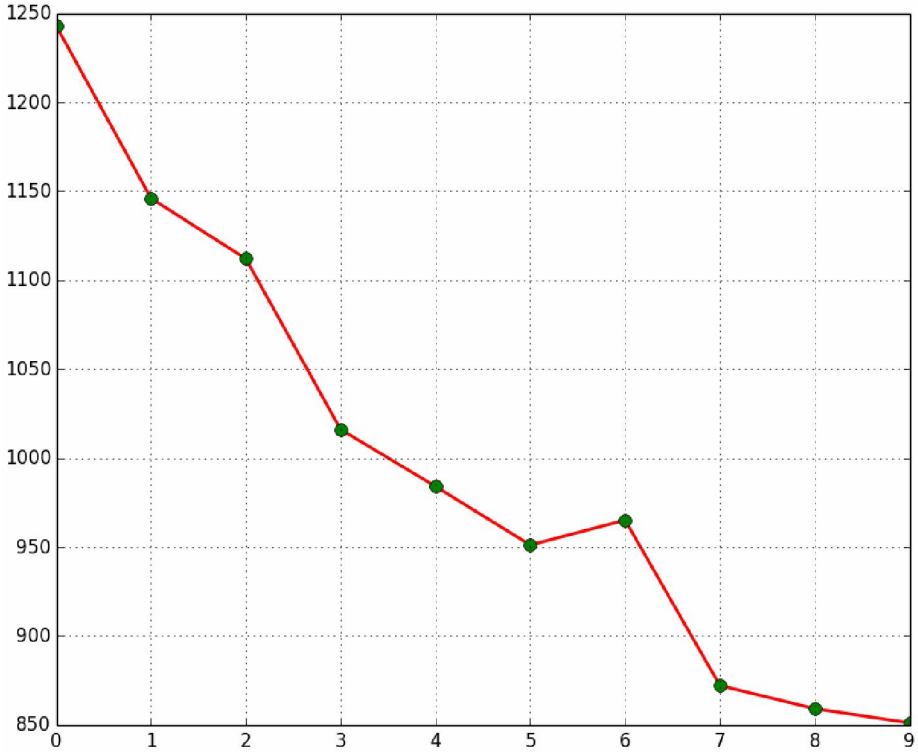

本福特定律

- 本福特定律(本福德法则, Frank Benford)，又称第一数字定律，是指在实际生活得出的一组数据中，以1为首位数字出现的概率约为总数的三成；是直观想象1/9的三倍。
  - 阶乘/素数数列/斐波那契数列首位
  - 住宅地址号码
  - 经济数据反欺诈
  - 选举投票反欺诈

数字	出现概率
1	30.1%
2	17.6%
3	12.5%
4	9.7%
5	7.9%
6	6.7%
7	5.8%
8	5.1%
9	4.6%

参考文献

- 同济大学数学系 编，工程数学线性代数(第五版)，高等教育出版社，2007

我们在这里

- 问题答疑：http://www.xxwenda.com/
  - 烦请邀请visio或其他人回答问题

- 本课程QQ群：
  - 471632108(小象学院：机器学习群)

感谢大家！

恳请大家批评指正！