法律声明

- 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，小象学院和主讲老师拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意及内容，我们保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：小象
  - 新浪微博：ChinaHadoop

凸优化

小象学院 ChinaHadoop.cn

邹博

凸优化主要内容

- 凸集基本概念
  - 凸集保凸运算
  - 分割超平面
  - 支撑超平面
- 凸函数基本概念
  - 上境图
  - Jensen不等式
  - 凸函数保凸运算
- 凸优化一般提法
  - 对偶函数
  - 鞍点解释
  - 用对偶求解最小二乘问题
  - 强对偶KKT条件

思考两个不等式

- 两个正数的算术平均数大于等于几何平均数

$$\frac{a+b}{2} \geq \sqrt{ab}, \quad a>0, b>0$$

- 给定可逆对称阵Q，对于任意的向量x，y，有：

$$x^T Q x + y^T Q^{-1} y \geq 2x^T y$$

- 都可以在凸函数的框架下得到解决。

思考凸集和凸函数

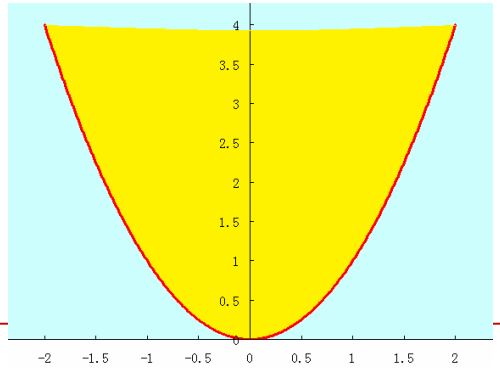

- $y=x^2$是凸函数，函数图像上位于$y=x^2$上方的区域构成凸集。
  - 凸函数图像的上方区域，一定是凸集；
  - 一个函数图像的上方区域为凸集，则该函数是凸函数。
  - 稍后给出上述表述的形式化定义。
- 因此，学习凸优化，考察凸函数，先从凸集及其性质开始。

直线的向量表达

- 已知二维平面上两定点A(4,1)、B(1,3)，试给出经过点A、B的直线方程。

$$\begin{cases} x_1 = \theta \cdot 4 + (1-\theta) \cdot 1 \\ x_2 = \theta \cdot 1 + (1-\theta) \cdot 3 \end{cases}, \theta \in R$$

$$\Rightarrow 2x_1 + 3x_2 - 11 = 0$$

- 写成向量形式：$\vec{x} = \theta \cdot \vec{a} + (1-\theta) \cdot \vec{b}$

几何体的向量表达

- 给定二维平面上两个定点：**a**(x_1,y_1)，**b**(x_2,y_2)，则：
  - 直线 $\vec{x}=\theta\cdot\vec{a}+(1-\theta)\cdot\vec{b},\ \theta\in R$
  - 线段 $\vec{x}=\theta\cdot\vec{a}+(1-\theta)\cdot\vec{b},\ \theta\in[0,1]$
- 推广到高维：
- 三维平面：$\vec{x}=\theta_1\cdot\vec{x}_1+\theta_2\cdot\vec{x}_2+\theta_3\cdot\vec{x}_3,\ \theta_1,\theta_2,\theta_3\in R,\ \theta_1+\theta_2+\theta_3=1$
- 三角形：$\vec{x}=\theta_1\cdot\vec{x}_1+\theta_2\cdot\vec{x}_2+\theta_3\cdot\vec{x}_3,\ \theta_1,\theta_2,\theta_3\in[0,1],\theta_1+\theta_2+\theta_3=1$
- 超平面：

$$\vec{x}=\theta_1\cdot\vec{x}_1+\theta_2\cdot\vec{x}_2+\cdots+\theta_k\cdot\vec{x}_k,\ \theta_1,\theta_2,\cdots,\theta_k\in R,\ \theta_1+\theta_2+\cdots+\theta_k=1$$

- (超)几何体：

$$\vec{x}=\theta_1\cdot\vec{x}_1+\theta_2\cdot\vec{x}_2+\cdots+\theta_k\cdot\vec{x}_k,\ \theta_1,\theta_2,\cdots,\theta_k\in[0,1],\ \theta_1+\theta_2+\cdots+\theta_k=1$$

仿射集(Affine set)

- 定义：通过集合C中任意两个不同点的直线仍然在集合C内，则称集合C为仿射集。

$$\forall \theta \in R, \forall x_1, x_2 \in C, 则 x = \theta x_1 + (1-\theta) x_2 \in C$$

- 仿射集的例子：直线、平面、超平面
  - 超平面：A**x**=**b**
  - f(**x**)=0表示定义域在R^n的超曲面：令f(**x**)=A**x**-**b**，则f(**x**)=0表示“截距”为**b**的超平面。
  - 三维空间的平面是二维的；四维空间的平面是几维的？
    - n维空间的n-1维仿射集为n-1维超平面。
  - 后面将继续考察超平面的定义。

凸集

- 集合C内任意两点间的线段均在集合C内，则称集合C为凸集。

$$\forall x_1, x_2 \in C, \theta \in [0,1], \text{则} \theta x_1 + (1-\theta) x_2 \in C$$

$$\forall x_1, \ldots, x_k \in C, \theta_i \in [0,1] \text{且} \sum_{i=1}^{k} \theta_i = 1,$$

$$\text{则} \sum_{i=1}^{k} \theta_i x_i \in C$$

仿射集和凸集的关系

- 因为仿射集的条件比凸集的条件强，所以，仿射集必然是凸集。

凸集

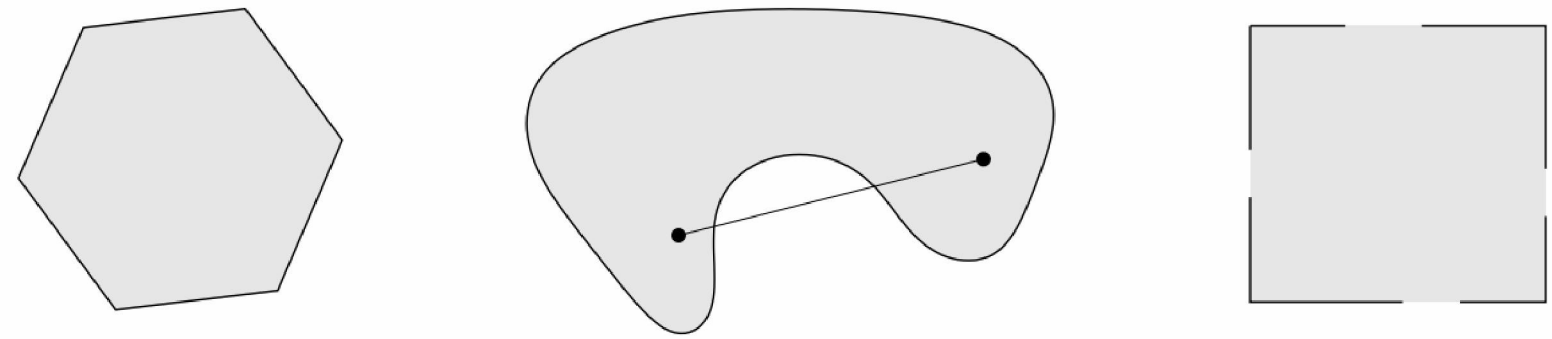

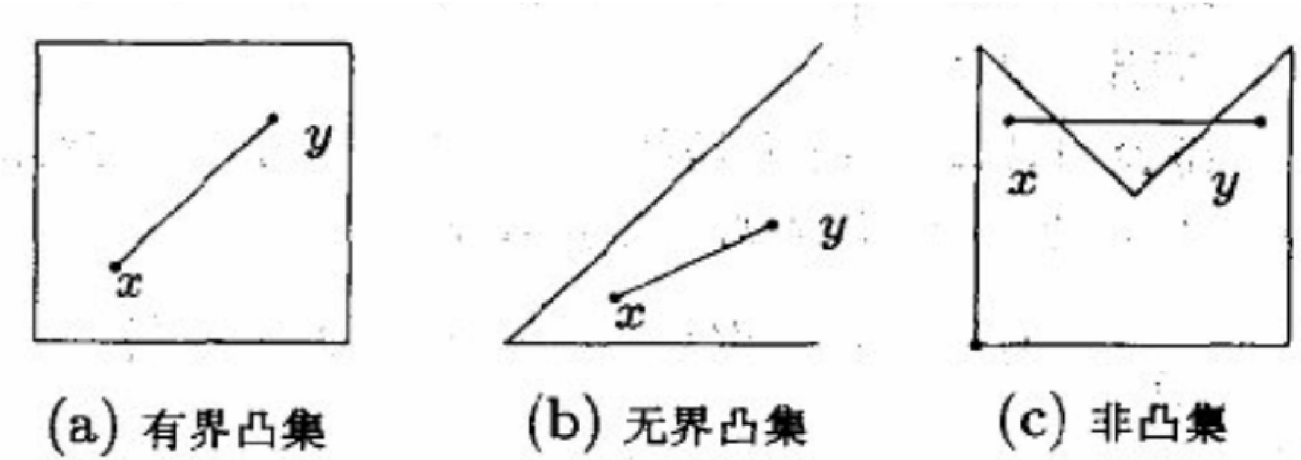

(a) 有界凸集　(b) 无界凸集　(c) 非凸集

凸包

- 集合C的所有点的凸组合形成的集合，叫做集合C的凸包。

$$\operatorname{conv} C = \{\sum_{i=1}^{k} \theta_i x_i \mid x_i \in C, \theta_i \geq 0, \sum_{i=1}^{k} \theta_i = 1\}$$

- 集合C的凸包是能够包含C的最小的凸集。

凸包的例子

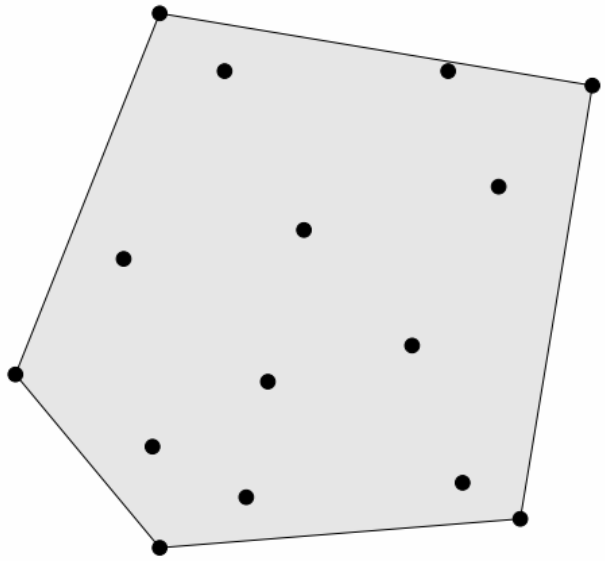

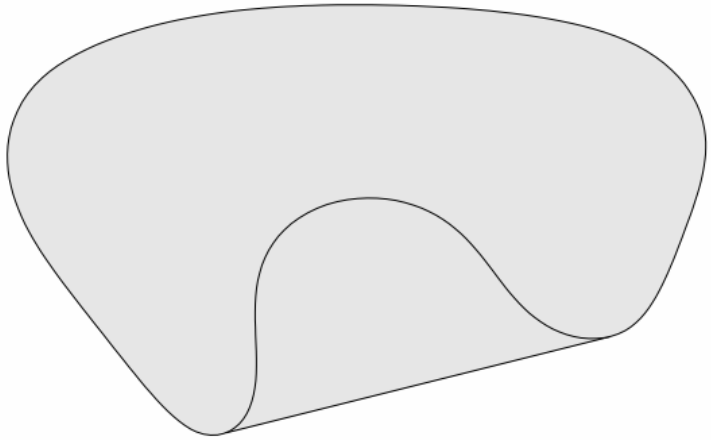

超平面和半空间

- 超平面hyperplane

$$\{x \mid a^T x = b\}$$

- 半空间halfspace

$$\{x \mid a^T x \le b\} \qquad \{x \mid a^T x \ge b\}$$

超平面和半空间

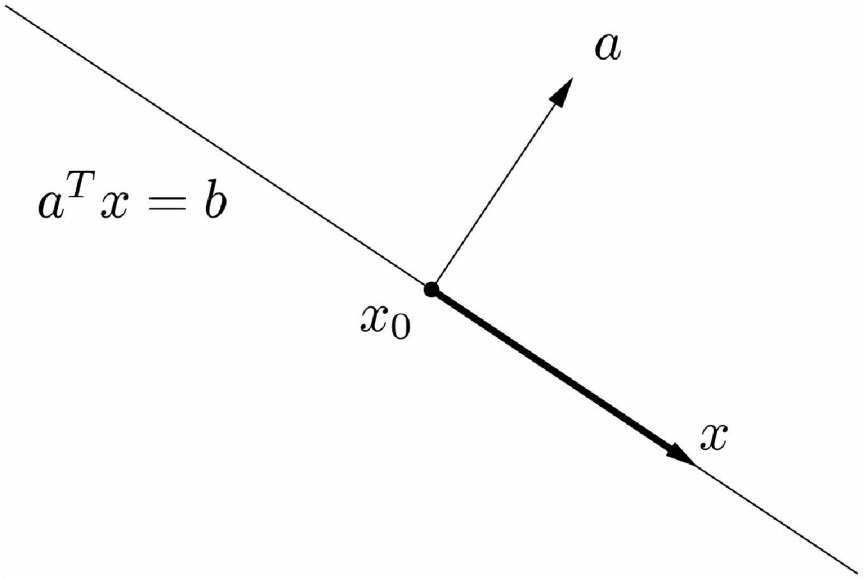

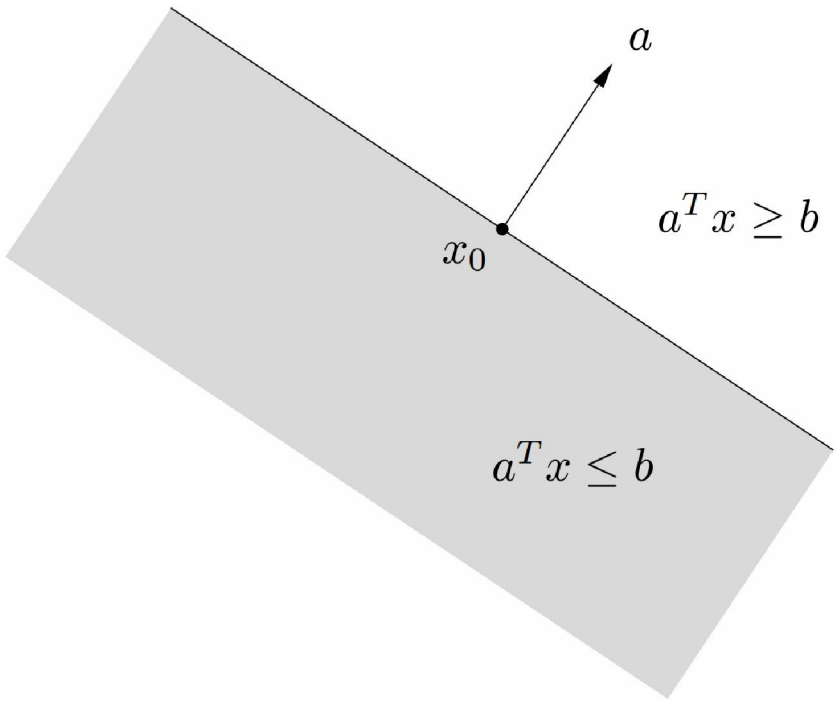

欧式球和椭球

- 欧式球

$$B(x_c, r) = \{x \mid \|x - x_c\|_2 \le r\}$$
$$= \{x \mid (x - x_c)^T (x - x_c) \le r^2\}$$

- 椭球

$$E = \{x \mid (x - x_c)^T P (x - x_c) \le r^2\},$$

P为对称正定矩阵

范数球和范数锥(欧式空间的推广)

- 范数 $\|x\| \geq 0, \|x\| = 0$当且仅当$x = 0$;

  $\|tx\| = |t| \|x\|, t \in R$;

  $\|x + y\| \leq \|x\| + \|y\|$

- 范数球

$$B(x_c, r) = \{x \mid \|x - x_c\| \leq r\}$$

- 范数锥

$$\{(x,t) \mid \|x\| \leq t\}$$

R^3空间中的二阶锥

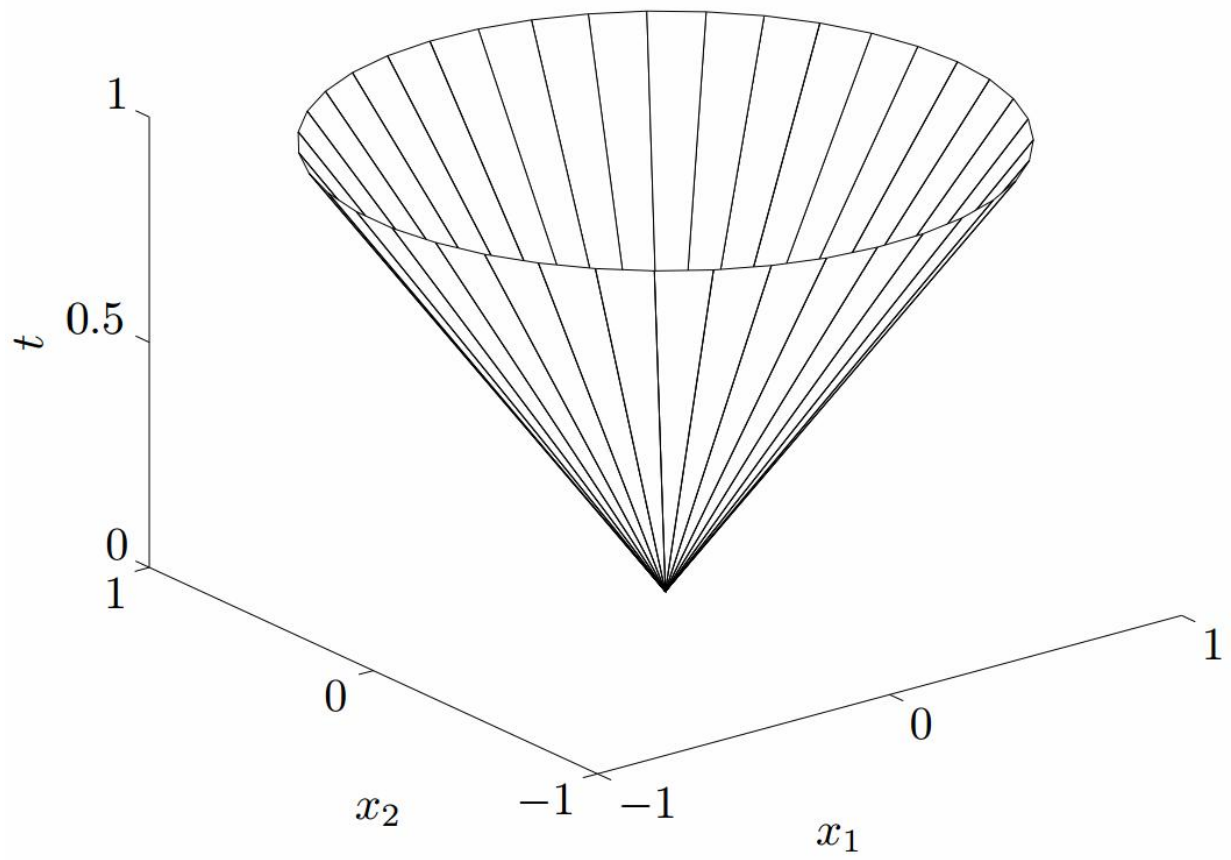

多面体

- 多面体有限个半空间和超平面的交集。

$$P=\{x \mid a_j^T x \le b_j, c_i^T x = d_i\}$$

- 仿射集(如超平面、直线)、射线、线段、半空间都是多面体。
- 多面体是凸集。
- 此外：有界的多面体有时称作多胞形(polytope)。
  - 注：该定义略混乱，不同文献的含义不同。

多面体

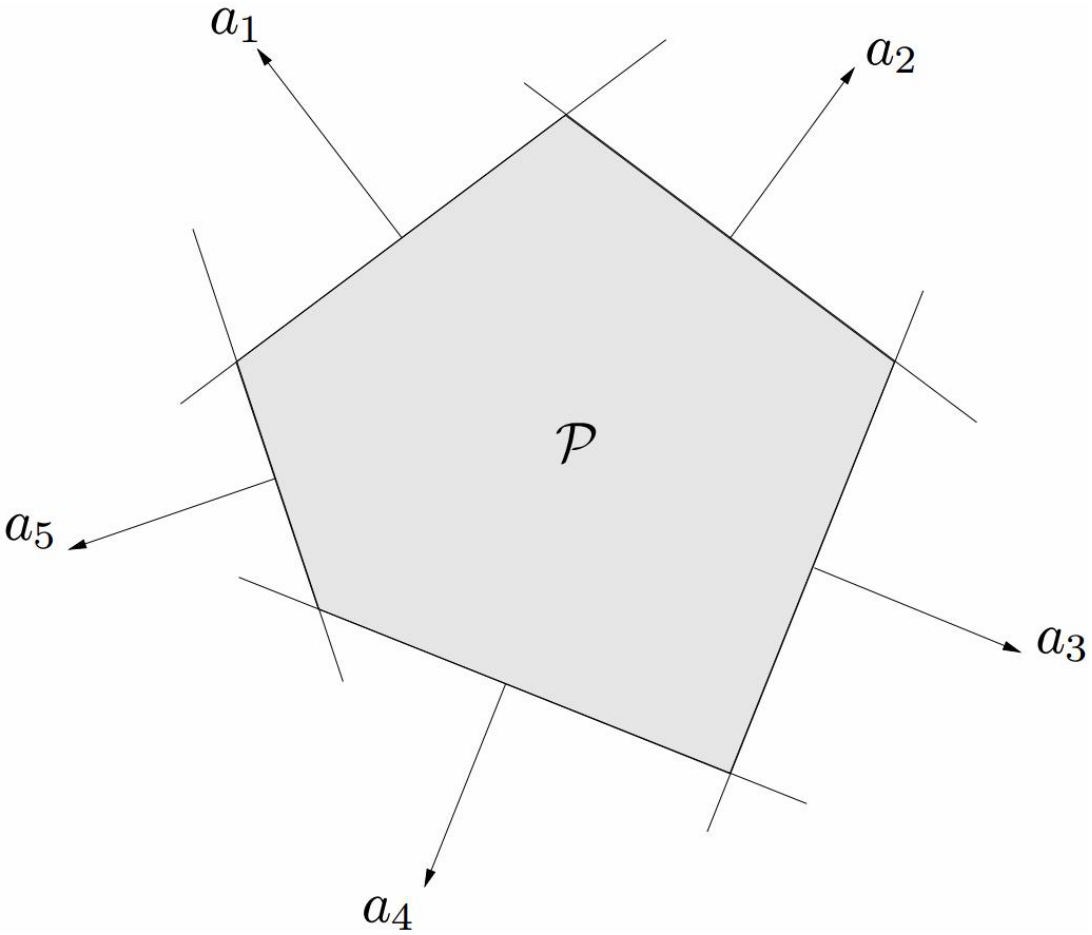

保持凸性的运算

- 集合交运算
  - 思考：如何证明？(提示：根据定义)
- 仿射变换
  - 函数f=Ax+b的形式，称函数是仿射的：即线性函数加常数的形式
- 透视变换
- 投射变换(线性分式变换)

集合交运算：半空间的交

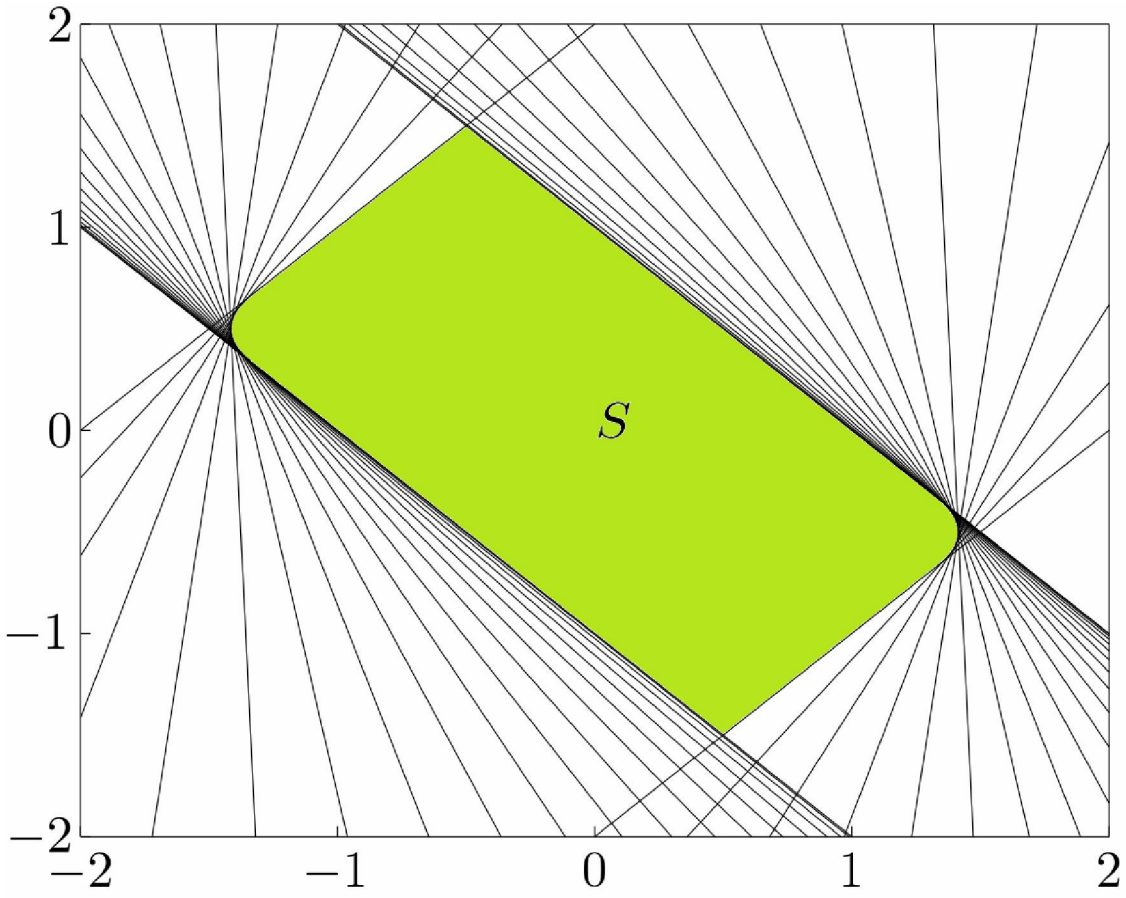

仿射变换

- 仿射变换 $f(x) = Ax + b$, $A \in \mathbf{R}^{m \times n}, b \in \mathbf{R}^m$
  - 伸缩、平移、投影
- 若f是仿射变换, $f : \mathbf{R}^n \to \mathbf{R}^m$ $f(S) = \{f(x) \mid x \in S\}$
  - 若S为凸集，则f(S)为凸集；
  - 若f(S)为凸集，则S为凸集。

进一步分析仿射变换

- 两个凸集的和为凸集

$$S_1 + S_2 = \{x + y \mid x \in S_1,\ y \in S_2\}$$

- 两个凸集的笛卡尔积(直积)为凸集

$$S_1 \times S_2 = \{(x_1, x_2) \mid x_1 \in S_1,\ x_2 \in S_2\}$$

- 两个集合的部分和为凸集(分配率)

$$S = \{(x, y_1 + y_2) \mid (x, y_1) \in S_1,\ (x, y_2) \in S_2\}$$

透视变换

- 透视函数对向量进行伸缩(规范化)，使得最后一维的分量为1并舍弃之。

$$P : \mathbf{R}^{n+1} \to \mathbf{R}^n,\ P(z,t) = z/t$$

- 透视的直观意义
  - 小孔成像

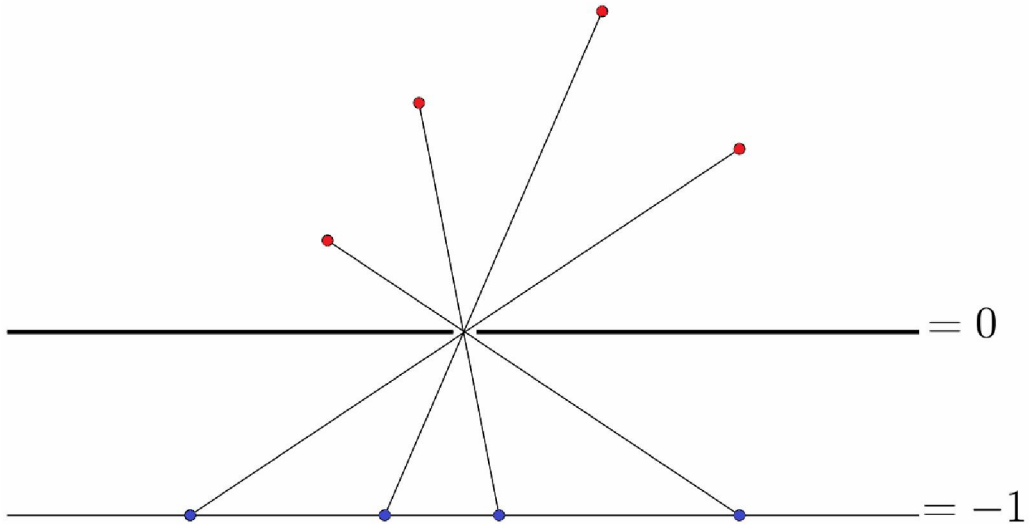

透视变换的保凸性

- 凸集的透视变换仍然是凸集。
- 思考：反过来，若某集合的透视变换是凸集，这个集合一定是凸集吗？

投射函数(线性分式函数)

- 投射函数是透视函数和仿射函数的复合。
- g为仿射函数： $g : \mathbf{R}^n \to \mathbf{R}^{m+1}$

$$g(x) = \begin{bmatrix} A \\ c^T \end{bmatrix} x + \begin{bmatrix} b \\ d \end{bmatrix}$$

$$A \in \mathbf{R}^{m \times n},\ b \in \mathbf{R}^m,\ c \in \mathbf{R}^n,\ d \in \mathbf{R}$$

- 定义f为线性分式函数

$$f(x) = (Ax + b)/(c^T x + d),\ \mathbf{dom}\, f = \{x \mid c^T x + d > 0\}$$

- 若c=0,d>0，则f即为普通的仿射函数。

投射的作用

$$f(x_1,x_2)=\begin{cases} f_1(x_1)=\dfrac{x_1}{x_1+x_2+1} \\ f_2(x_2)=\dfrac{x_2}{x_1+x_2+1} \end{cases}, \quad \mathrm{dom}\ f=\{(x_1,x_2)\mid x_1+x_2+1>0\}$$

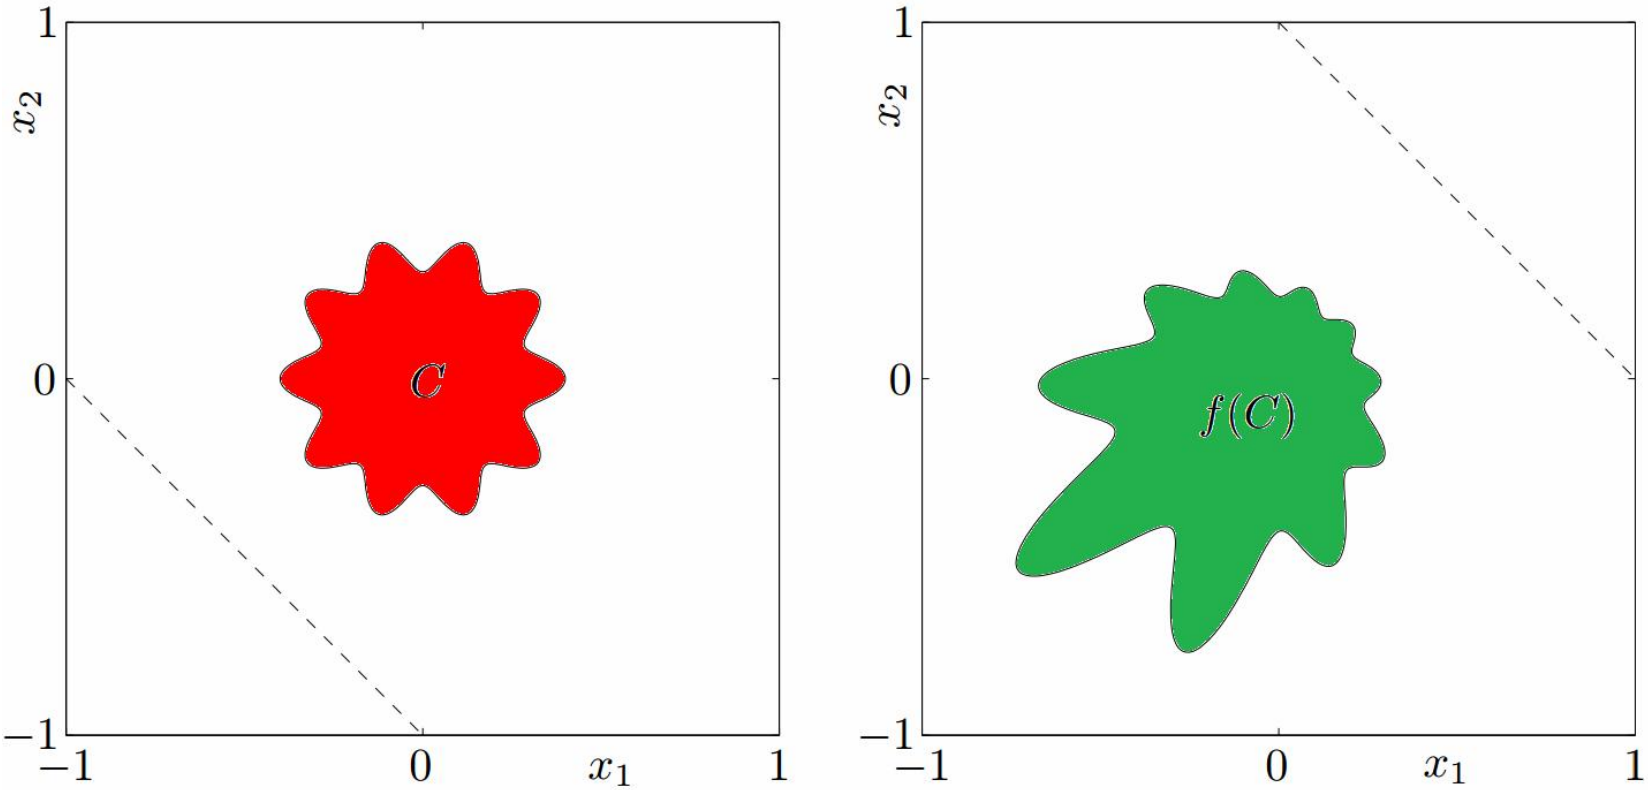

分割超平面

- 设C和D为两不相交的凸集，则存在超平面P，P可以将C和D分离。

$$\forall x \in C, a^T x \le b \text{且} \forall x \in D, a^T x \ge b$$

- 注意上式中可以取等号。
  - “若两个凸集C和D的分割超平面存在，C和D不相交”为假命题。
  - 加强条件：若两个凸集至少有一个是开集，那么当且仅当存在分割超平面，它们不相交。

分割超平面

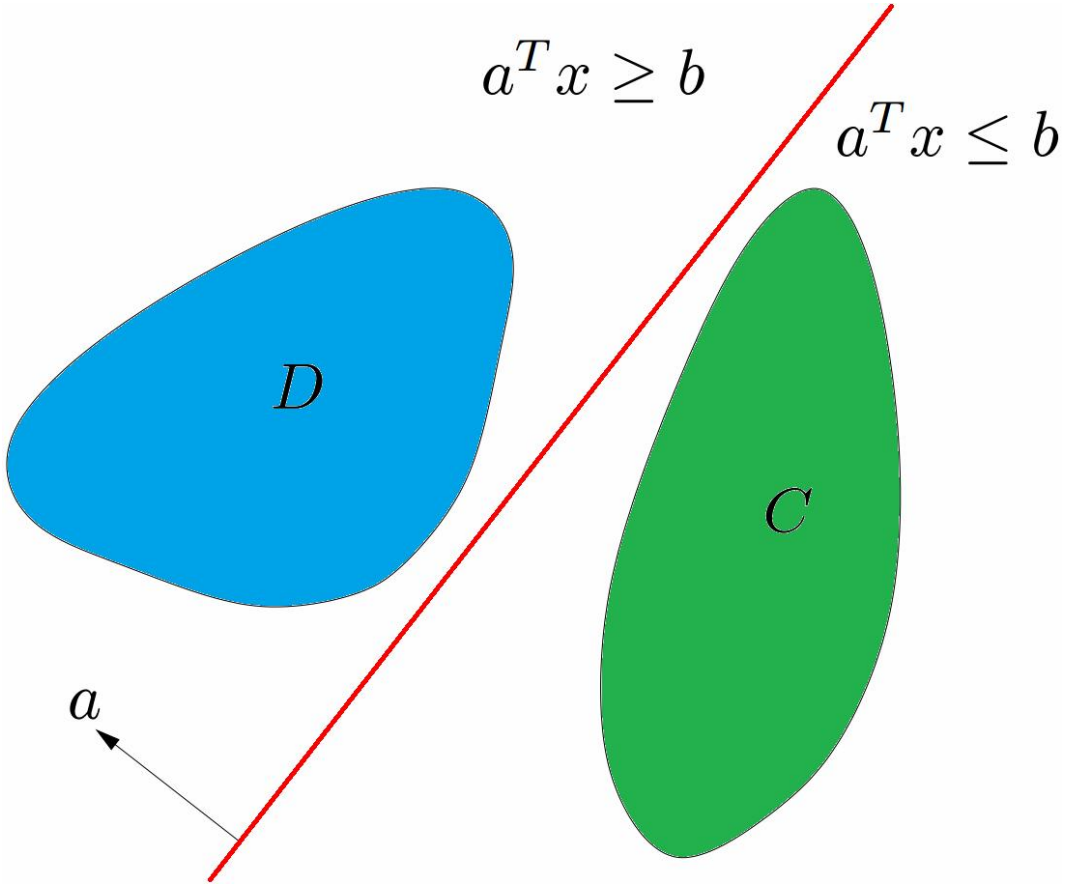

分割超平面的构造

- 两个集合的距离，定义为两个集合间元素的最短距离。
- 做集合C和集合D最短线段的垂直平分线。

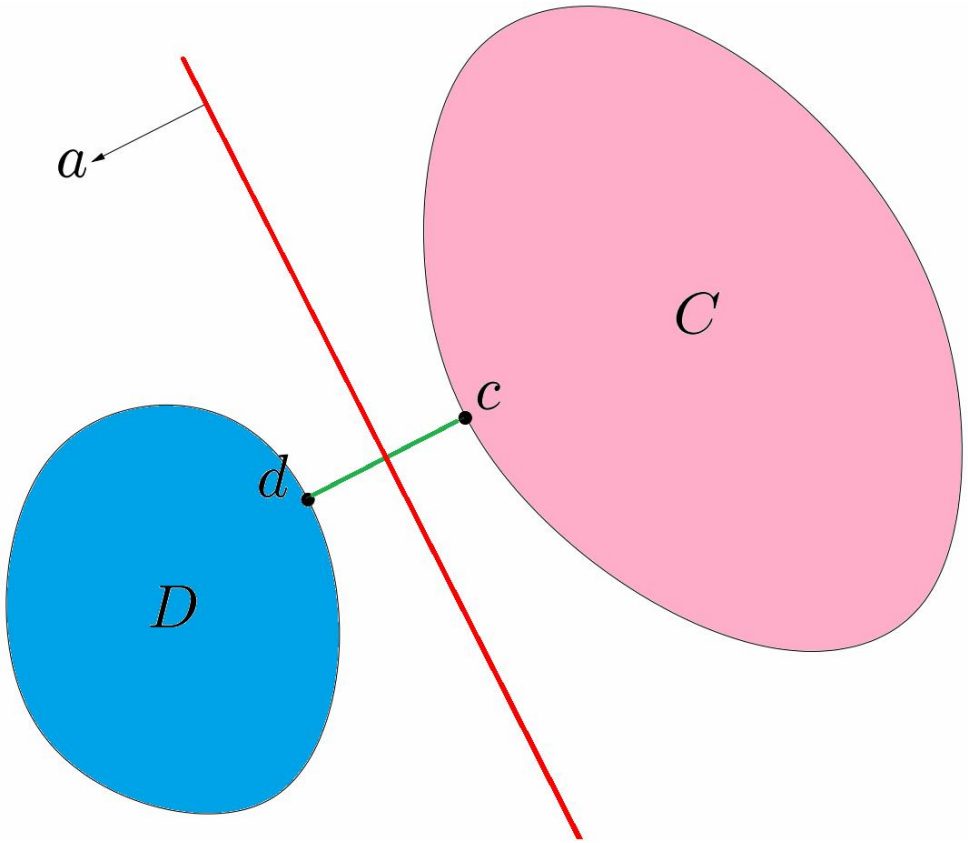

思考

- 如何定义两个集合的“最优”分割超平面？
- 若两个集合有部分相交，如何定义超平面，使得两个集合“尽量”分开？
  - 上述“集合”的元素，可能是若干离散点。若一组集合为(x,1)，另一组集合为(x,2)，则为机器学习中的分类问题。

支撑超平面

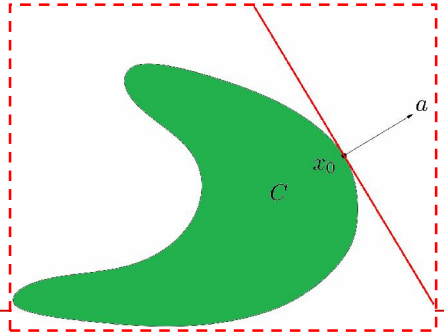

- 设集合C，x0为C边界上的点。若存在a≠0，满足对任意x∈C，都有 $a^T x \le a^T x_0$ 成立，则称超平面 $\{x \mid a^T x = a^T x_0\}$ 为集合C在点x0处的支撑超平面。
- 凸集边界上任意一点，均存在支撑超平面。
- 反之，若一个闭的非中空（内部点不为空）集合，在边界上的任意一点存在支撑超平面，则该集合为凸集。

思考

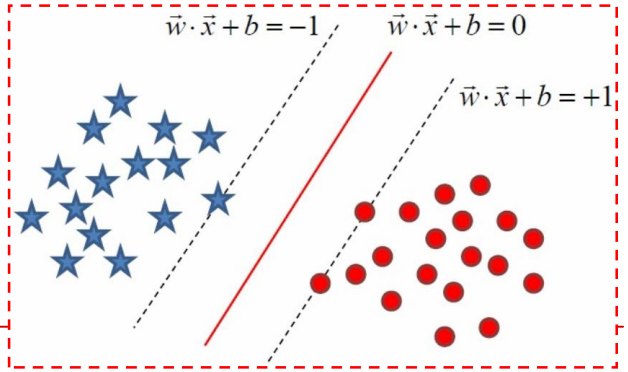

- 如何定义两个集合的“最优”分割超平面？
  - 找到集合“边界”上的若干点，以这些点为“基础”计算超平面的方向；以两个集合边界上的这些点的平均作为超平面的“截距”
  - 支持向量：support vector
- 若两个集合有部分相交，如何定义超平面，使得两个集合“尽量”分开？
  - 注：上述“集合”不一定是凸集，可能是由若干离散点组成。若一组集合为(x,1)，另一组集合为(x,2)，则为机器学习中的分类问题。

凸函数

- 若函数f的定义域domf为凸集，且满足

$$\forall x, y \in \mathrm{dom}\, f, 0 \le \theta \le 1, \text{ 有}$$

$$f(\theta x + (1-\theta) y) \le \theta f(x) + (1-\theta) f(y)$$

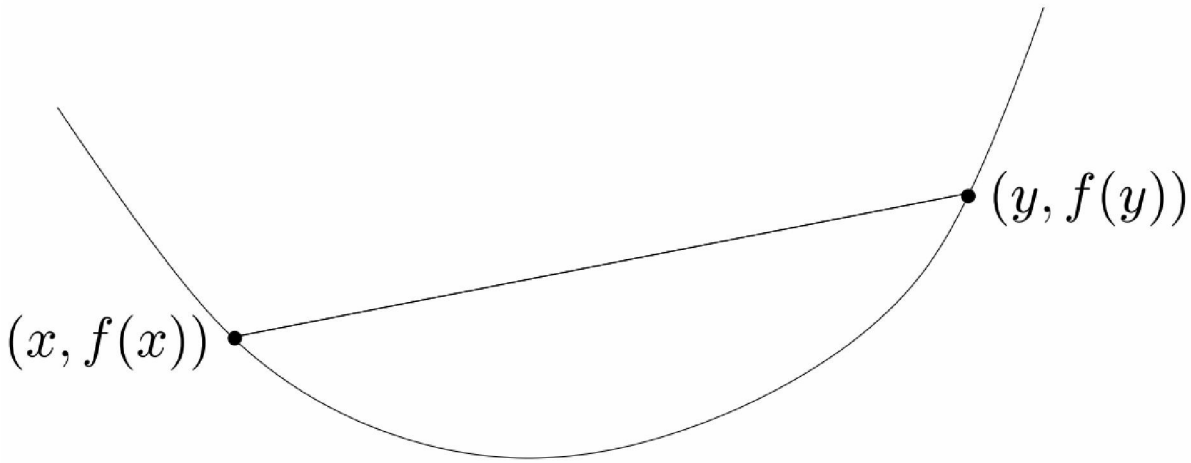

一阶可微

- 若f一阶可微，则函数f为凸函数当前仅当f的定义域domf为凸集，且

$$\forall x, y \in \mathrm{dom} f,\ f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

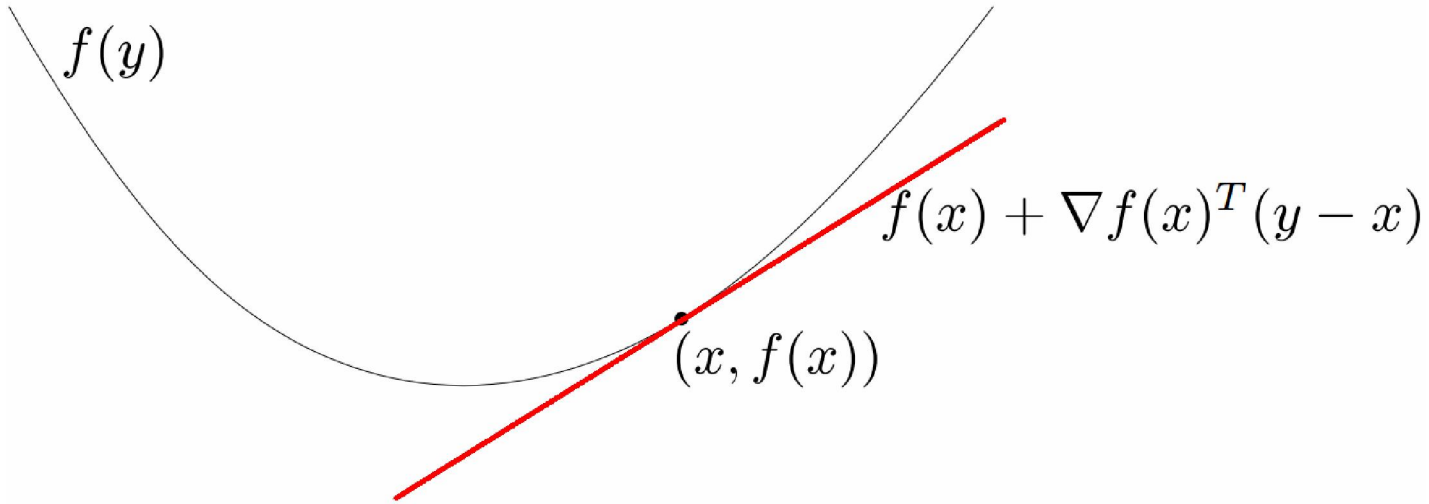

进一步的思考 $f(y) \geq f(x) + \nabla f(x)^T (y - x)$

- 结合凸函数图像和支撑超平面理解该问题
- 对于凸函数，其一阶Taylor近似本质上是该函数的全局下估计。
- 反之，如果一个函数的一阶Taylor近似总是起全局下估计，则该函数是凸函数。
- 该不等式说明从一个函数的局部信息，可以得到一定程度的全局信息。

二阶可微

- 若函数f二阶可微，则函数f为凸函数当前仅当dom为凸集，且

$$\nabla^2 f(x) \succeq 0$$

- 若f是一元函数，上式表示二阶导大于等于0
- 若f是多元函数，上式表示二阶导Hessian矩阵半正定。

凸函数举例

- 指数函数 e^{ax}
- 幂函数 $x^a, x \in R_+, a \geq 1 \text{ or } a \leq 0$
- 负对数函数 $-\log x$
- 负熵函数 $x \log x$
- 范数函数 $\|x\|_p$

$$f(x) = \max(x_1, \ldots, x_n)$$

$$f(x) = x^2 / y, y > 0$$

$$f(x) = \log(e^{x_1} + \ldots + e^{x_n})$$

上境图

- 函数f的图像定义为：$\{(x, f(x)) \mid x \in \mathbf{dom}\, f\}$
- 函数f的上境图(epigraph)定义为：

$$\mathbf{epi}\, f = \{(x, t) \mid x \in \mathbf{dom}\, f,\ f(x) \le t\}$$

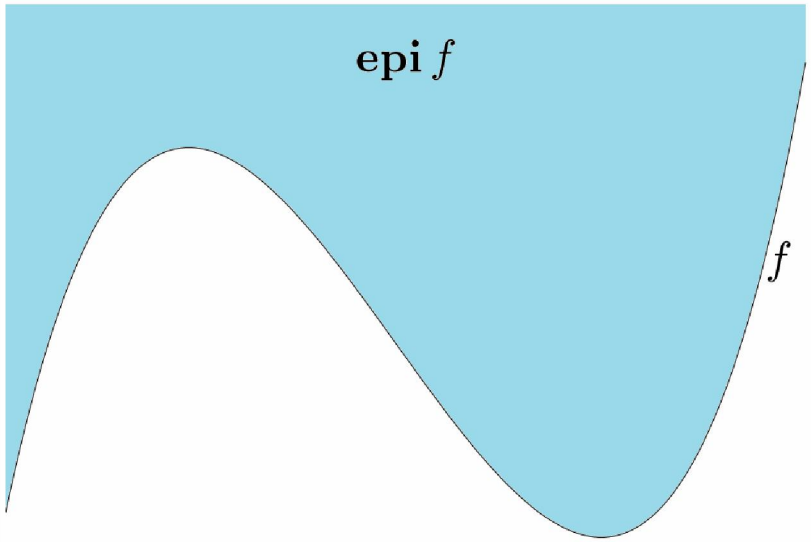

凸函数与凸集

- 一个函数是凸函数，当且仅当其上境图是凸集。
  - 思考：如何证明？(提示：定义)
- 进一步，一个函数是凹函数，当且仅当其亚图(hypograph)是凸集。

$$\mathbf{hypo}\, f = \{(x,t) \mid t \le f(x)\}$$

Jensen不等式：若f是凸函数

- 基本Jensen不等式

$$f(\theta x + (1-\theta)y) \le \theta f(x) + (1-\theta) f(y)$$

- 若 $\theta_1, \ldots, \theta_k \ge 0, \theta_1 + \cdots + \theta_k = 1$
- 则 $f(\theta_1 x_1 + \cdots + \theta_k x_k) \le \theta_1 f(x_1) + \cdots + \theta_k f(x_k)$

- 若 $p(x) \ge 0$ on $S \subseteq \mathbf{dom}\, f$, $\int_S p(x)\, dx = 1$
- 则 $f\left(\int_S p(x) x\, dx\right) \le \int_S f(x) p(x)\, dx$

$$f(\mathbf{E}\, x) \le \mathbf{E}\, f(x)$$

Jensen不等式是几乎所有不等式的基础

- 利用y=-logx是凸函数，证明：

$$\frac{a+b}{2} \geq \sqrt{ab}, \quad a>0, b>0$$

  - 提示：任取a,b>0，θ=0.5带入基本Jensen不等式

- 利用f(E(x))≤E(f(x))，(f是凸函数)，证明下式D≥0

$$D(p \| q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = E_{p(x)} \log \frac{p(x)}{q(x)}$$

注意到y=-logx在定义域上是凸函数

$$
\begin{aligned}
& D(p \| q) \\
&= \sum_x p(x) \log \frac{p(x)}{q(x)} \\
&= -\sum_x p(x) \left(\log \frac{q(x)}{p(x)} \right) \\
&\geq -\log \sum_x \left(p(x) \cdot \frac{q(x)}{p(x)} \right) \\
&= -\log \sum_x q(x) \\
&= -\log 1 \\
&= 0
\end{aligned}
$$

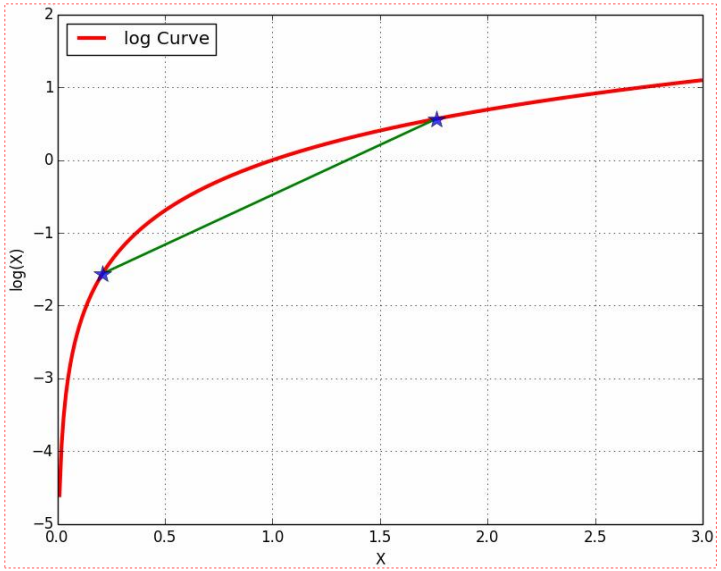

$$f(\mathbf{E}\, x) \leq \mathbf{E}\, f(x)$$

保持函数凸性的算子

- 凸函数的非负加权和

$$f(x) = \omega_1 f_1(x) + \ldots + \omega_n f_n(x)$$

- 凸函数与仿射函数的复合

$$g(x) = f(Ax + b)$$

- 凸函数的逐点最大值、逐点上确界

$$f(x) = \max(f_1(x), \ldots, f_n(x))$$

$$f(x) = \sup_{y \in A} g(x, y)$$

凸函数的逐点最大值

- 若f_1, f_2均为凸函数，定义函数f：

$$f(x) = \max\{f_1(x), f_2(x)\}$$

则函数f为凸函数。

- 证明：$f(\theta \cdot x + (1-\theta) \cdot y)$

$$= \max\{f_1(\theta \cdot x + (1-\theta) \cdot y), f_2(\theta \cdot x + (1-\theta) \cdot y)\}$$
$$\le \max\{\theta \cdot f_1(x) + (1-\theta) \cdot f_1(y), \ \theta \cdot f_2(x) + (1-\theta) \cdot f_2(y)\}$$
$$\le \theta \cdot \max\{f_1(x), f_2(x)\} + (1-\theta) \cdot \max\{f_1(y), f_2(y)\}$$
$$= \theta \cdot f(x) + (1-\theta) \cdot f(y)$$

第二个不等号的证明

$$f_1(x) \le \max\{f_1(x), f_2(x)\} \Rightarrow$$
$$\theta \cdot f_1(x) \le \theta \cdot \max\{f_1(x), f_2(x)\} \cdots\cdots ①$$

$$f_1(y) \le \max\{f_1(y), f_2(y)\} \Rightarrow$$
$$(1-\theta) \cdot f_1(y) \le (1-\theta) \cdot \max\{f_1(y), f_2(y)\} \cdots\cdots ②$$

$$① + ② \Rightarrow$$
$$\theta \cdot f_1(x) + (1-\theta) \cdot f_1(y) \le \theta \cdot \max\{f_1(x), f_2(x)\} + (1-\theta) \cdot \max\{f_1(y), f_2(y)\}$$

同 理

$$\theta \cdot f_2(x) + (1-\theta) \cdot f_2(y) \le \theta \cdot \max\{f_1(x), f_2(x)\} + (1-\theta) \cdot \max\{f_1(y), f_2(y)\}$$

第二个不等号的形式化表达

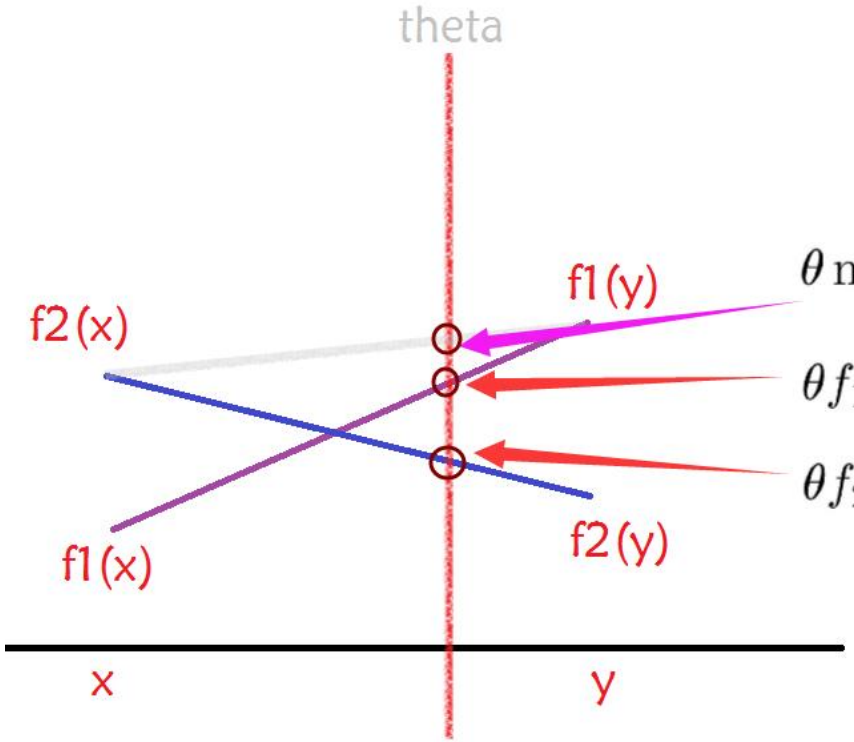

$$\theta \max\{f_1(x), f_2(x)\} + (1-\theta)\max\{f_1(y), f_2(y)\}$$

$$\theta f_1(x) + (1-\theta) f_1(y)$$

$$\theta f_2(x) + (1-\theta) f_2(y)$$

思考

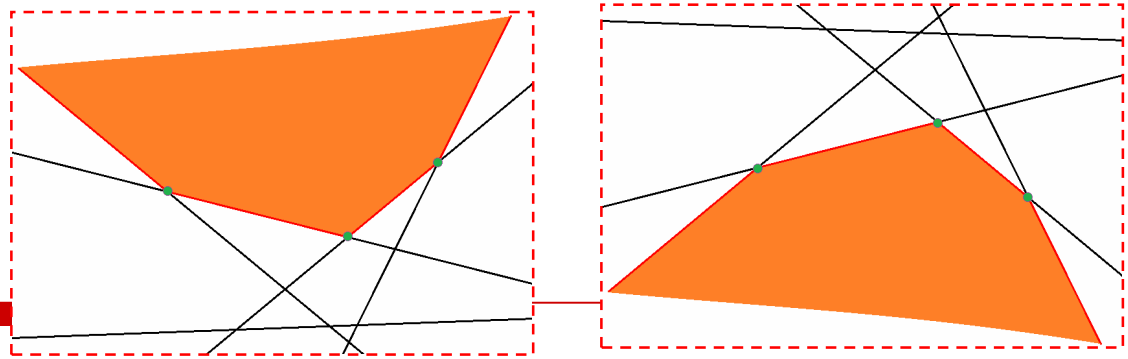

- 逐点上确界和上境图的关系
  - 一系列函数逐点上确界函数对应着这些函数上境图的交集。
  - 直观例子
    - Oxy平面上随意画N条直线(直线是凸的——虽然直线也是凹的)，在每个x处取这些直线的最大的点，则构成的新函数是凸函数；
    - 同时：N条直线逐点求下界，是凹函数；
    - 在Lagrange对偶函数中会用到该结论。

共轭函数

- 原函数 $f:\mathbf{R}^n \to \mathbf{R}$ 共轭函数定义：

$$f^*(y) = \sup_{x \in \mathbf{dom}\, f} \left(y^T x - f(x)\right)$$

- 显然，定义式的右端是关于y的仿射函数，它们逐点求上确界，得到的函数f*(y)一定是凸函数。
- 该名称的原因：
  - 凸函数的共轭函数的共轭函数是其本身。

对共轭函数的理解 $f^*(y) = \sup_{x \in \mathbf{dom}\, f} \left(y^T x - f(x)\right)$

- 如果函数f可微，在满足f'(x)=y的点x处差值最大。

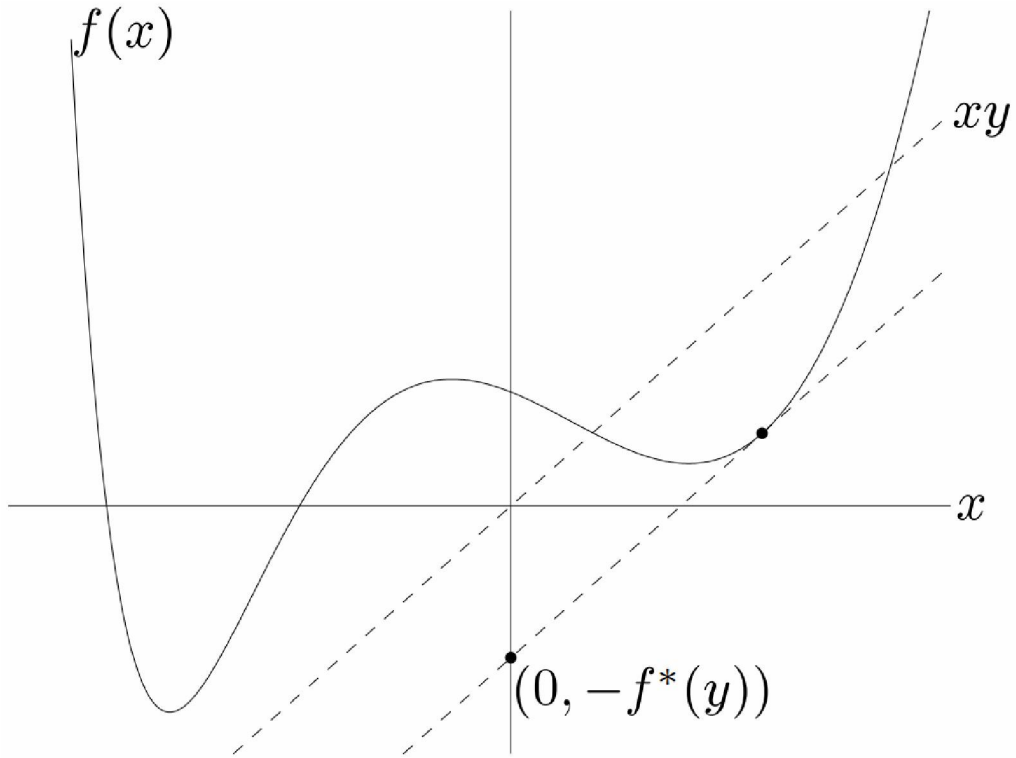

例：求共轭函数

- 可逆对称阵Q，对于任意的向量x，定义函数f： $f(x)=\frac{1}{2}x^TQx$
- 关于(x,y)的函数 $y^Tx-\frac{1}{2}x^TQx$
- 在 $x=Q^{-1}y$ 时取上确界，带入，得到：

$$f^*(y)=\frac{1}{2}y^TQ^{-1}y$$

- f*即是f的共轭函数

Fenchel不等式

- 根据定义

$$f^*(y) = \sup_{x \in \mathbf{dom}\, f} \left(y^T x - f(x)\right)$$

- 立刻可以得到：

$$f(x) + f^*(y) \geq x^T y$$

Fenchel不等式的应用

- 根据f(x)及其共轭函数f*(x)

$$f(x)=\frac{1}{2}x^T Qx \qquad f^*(y)=\frac{1}{2}y^T Q^{-1}y$$

- 带入Fenchel不等式，得到：

$$x^T Qx + y^T Q^{-1} y \geq 2x^T y$$

凸优化

- 优化问题的基本形式

$$\begin{aligned} \text{minimize} \quad & f_0(x), \quad x \in \mathbf{R}^n \\ \text{subject to} \quad & f_i(x) \le 0, \quad i = 1, \ldots, m \\ & h_j(x) = 0, \quad j = 1, \ldots, p \end{aligned}$$

优化变量	$x \in R^n$
不等式约束	$f_i(x) \le 0$
等式约束	$h_j(x) = 0.$
无约束优化	$m = p = 0$

优化问题的基本形式

- 优化问题的域

$$D=\bigcap_{i=0}^{m}\mathrm{dom}f_i\cap\bigcap_{j=1}^{p}\mathrm{dom}h_j$$

- 可行点(解)(feasible)
  - x∈D，且满足约束条件
- 可行域(可解集)
  - 所有可行点的集合
- 最优化值

$$p^*=\inf\{f_0(x)\mid f_i(x)\le 0, i=1,\ldots,m, h_j(x)=0, j=1,\ldots,p\}$$

- 最优化解

$$p^*=f_0(x^*)$$

凸优化问题的基本形式

$$\begin{aligned} \text{minimize} \quad & f_0(x), \quad x \in \mathbf{R}^n \\ \text{subject to} \quad & f_i(x) \le 0, \quad i = 1, \ldots, m \\ & h_j(x) = 0, \quad j = 1, \ldots, p \end{aligned}$$

- 其中，$f_i(x)$为凸函数，$h_j(x)$为仿射函数
- 凸优化问题的重要性质
  - 凸优化问题的可行域为凸集
  - 凸优化问题的局部最优解即为全局最优解

对偶问题

- 一般优化问题的Lagrange乘子法

$$\begin{aligned} \text{minimize} \quad & f_0(x), \quad x \in \mathbf{R}^n \\ \text{subject to} \quad & f_i(x) \le 0, \quad i = 1, \ldots, m \\ & h_j(x) = 0, \quad j = 1, \ldots, p \end{aligned}$$

- Lagrange函数

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^{m} \lambda_i f_i(x) + \sum_{j=1}^{p} \nu_j h_j(x)$$

  - 对固定的x，Lagrange函数L(x, λ ,v)为关于λ和v的仿射函数

Lagrange对偶函数(dual function)

- Lagrange对偶函数

$$g(\lambda,\nu)=\inf_{x\in D}L(x,\lambda,\nu)=\inf_{x\in D}(f_0(x)+\sum_{i=1}^{m}\lambda_i f_i(x)+\sum_{i=1}^{p}\nu_i h_i(x))$$

- 若没有下确界，定义：

$$g(\lambda,\nu)=-\infty$$

- 根据定义，显然有：对∀ λ>0，∀v，若原优化问题有最优值p*，则

$$g(\lambda,\nu)\le p^*$$

- 进一步：Lagrange对偶函数为凹函数。

左侧为原函数，右侧为对偶函数

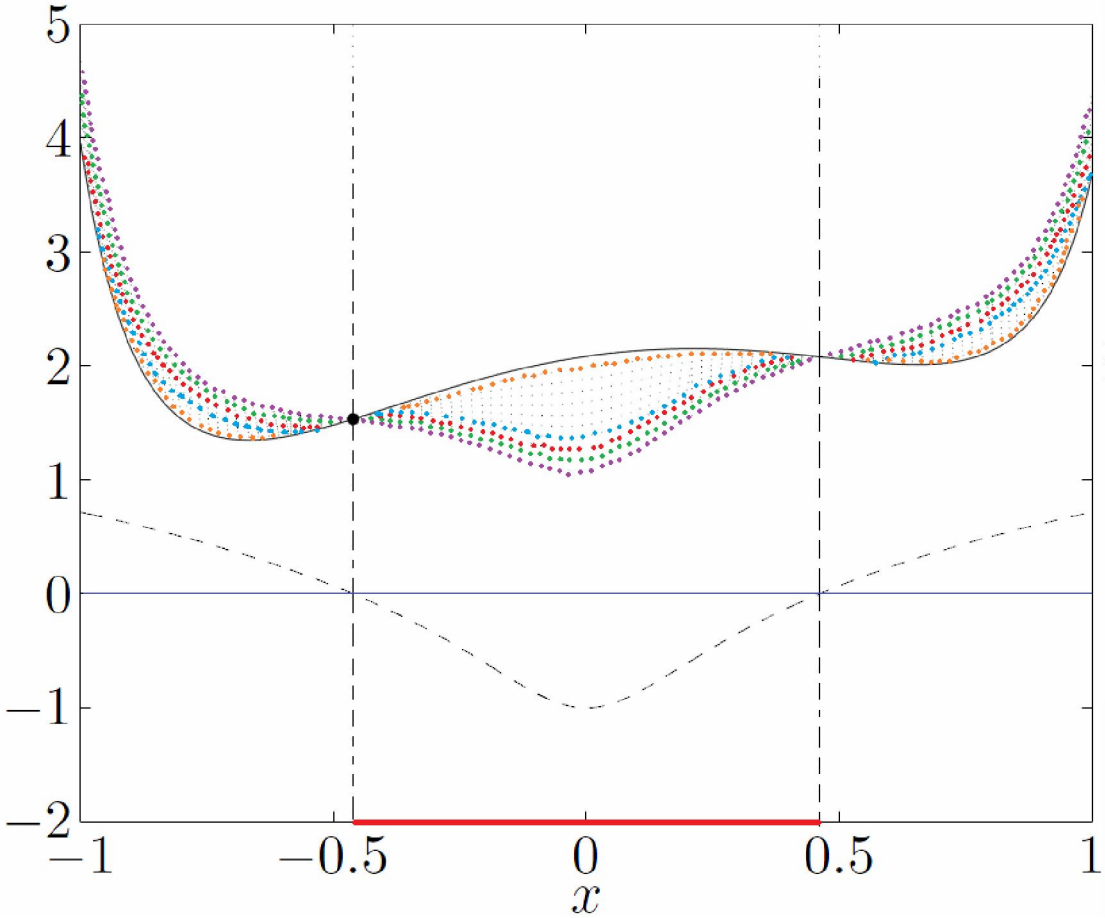

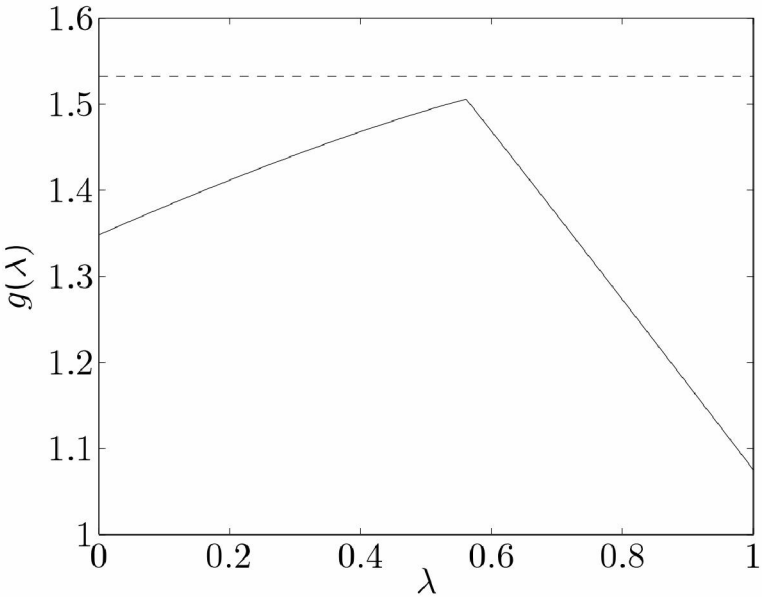

鞍点解释

- 为表述方便，假设没有等式约束，只考虑不等式约束，结论可方便的扩展到等式约束。
- 假设x0不可行，即存在某些i，使得$f_i(x)>0$。则选择 $\lambda_i \to \infty$，对于其他乘子，$\lambda_j = 0, j \neq i$
- 假设x0可行，则有$f_i(x) \leqslant 0, (i=1,2,\ldots,m)$，选择

$$\lambda_i = 0, i = 1,2,\cdots,m$$

- 有：

$$\sup_{\lambda \geq 0} L(x,\lambda) = \sup_{\lambda \geq 0}\left(f_0(x) + \sum_{i=1}^{m} \lambda_i f_i(x) \right) = \begin{cases} f_0(x) & f_i(x) \leq 0, i = 1,2\cdots,m \\ \infty & otherwise \end{cases}$$

鞍点：最优点

- 而原问题是：$\inf_x f_0(x)$
- 从而，原问题的本质为：$\inf_x \sup_{\lambda \geq 0} L(x,\lambda)$
- 而对偶问题，是求对偶函数的最大值，即：

$$\sup_{\lambda \geq 0} \inf_x L(x,\lambda)$$

- 而：

$$\sup_{\lambda \geq 0} \inf_x L(x,\lambda) \leq \inf_x \sup_{\lambda \geq 0} L(x,\lambda)$$

证明：$\max_x \min_y f(x,y) \le \min_y \max_x f(x,y)$

- 对于任意的(x,y) ∈ domf

$$f(x,y) \le \max_x f(x,y)$$

$$\Rightarrow \min_y f(x,y) \le \min_y \max_x f(x,y)$$

$$\Rightarrow \max_x \min_y f(x,y) \le \min_y \max_x f(x,y)$$

强对偶条件

- 若要对偶函数的最大值即为原问题的最小值，考察需要满足的条件：

$$
\begin{aligned}
f_0(x^\star) &= g(\lambda^\star, \nu^\star) \\
&= \inf_x \left(f_0(x) + \sum_{i=1}^m \lambda_i^\star f_i(x) + \sum_{i=1}^p \nu_i^\star h_i(x) \right) \\
&\leq f_0(x^\star) + \sum_{i=1}^m \lambda_i^\star f_i(x^\star) + \sum_{i=1}^p \nu_i^\star h_i(x^\star) \\
&\leq f_0(x^\star).
\end{aligned}
$$

Karush-Kuhn-Tucker (KKT)条件

$$
\begin{aligned}
f_i(x^\star) &\leq 0, \quad i = 1, \ldots, m \\
h_i(x^\star) &= 0, \quad i = 1, \ldots, p \\
\lambda_i^\star &\geq 0, \quad i = 1, \ldots, m \\
\lambda_i^\star f_i(x^\star) &= 0, \quad i = 1, \ldots, m
\end{aligned}
$$

$$
\nabla f_0(x^\star) + \sum_{i=1}^{m} \lambda_i^\star \nabla f_i(x^\star) + \sum_{i=1}^{p} \nu_i^\star \nabla h_i(x^\star) = 0
$$

附：线性方程的最小二乘问题

- 原问题 $\quad \text{minimize} \quad x^T x, \quad x \in \mathbf{R}^n$

  $\text{subject to} \quad Ax = b$

- Lagrange函数

$$L(x,\nu) = x^T x + \nu^T (Ax - b)$$

- Lagrange对偶函数

$$g(\nu) = -\frac{1}{4}\nu^T A A^T \nu - b^T \nu$$

  - 对L求x的偏导，带入L，得到g
  - 对g求v的偏导，求g的极大值，作为原问题的最小值

求L的对偶函数 $L(x,\nu)=x^T x+\nu^T(Ax-b)$

$$\frac{\partial L}{\partial x}=\frac{\partial\left(x^T x+\nu^T(Ax-b)\right)}{\partial x}=2x+A^T\nu\overset{令}{=}0\Rightarrow x^*=-\frac{1}{2}A^T\nu$$

$$\begin{aligned}
L(x,\nu)&=x^T x+\nu^T(Ax-b)\\
&=\left(-\frac{1}{2}A^T\nu\right)^T\left(-\frac{1}{2}A^T\nu\right)+\nu^T\left(A\left(-\frac{1}{2}A^T\nu\right)-b\right)\\
&=\frac{1}{4}\nu^T AA^T\nu-\frac{1}{2}\nu^T AA^T\nu-\nu^T b\\
&=-\frac{1}{4}\nu^T AA^T\nu-\nu^T b\\
&\overset{\Delta}{=}g(\nu)
\end{aligned}$$

求对偶函数的极大值 $g(\nu)=-\frac{1}{4}\nu^T AA^T\nu-\nu^T b$

$$\frac{\partial g}{\partial \nu}=\frac{\partial\left(-\frac{1}{4}\nu^T AA^T\nu-\nu^T b\right)}{\partial \nu}=-\frac{1}{2}AA^T\nu-b\overset{令}{=}0$$

$$\Rightarrow AA^T\nu=-2b$$

$$\Rightarrow A^T AA^T\nu=-2A^T b$$

$$\Rightarrow A^T\nu=-2\left(A^T A\right)^{-1}A^T b$$

$$\Rightarrow -\frac{1}{2}A^T\nu=\left(A^T A\right)^{-1}A^T b$$

$$\Rightarrow x^*=\left(A^T A\right)^{-1}A^T b$$

极小值点 $x^* = \left(A^T A\right)^{-1} A^T b$

- 极小值：$\min\left(x^T x\right)$

$$= \left(\left(A^T A\right)^{-1} A^T b\right)^T \left(\left(A^T A\right)^{-1} A^T b\right)$$

$$= b^T A\left(A^T A\right)^{-1}\left(A^T A\right)^{-1} A^T b$$

$$= b^T A\left(A^T A\right)^{-2} A^T b$$

- 极小值点的结论，和通过线性回归计算得到的结论是完全一致的。
  - 线性回归问题具有强对偶性。

参考文献

- 同济大学数学系 编，工程数学线性代数(第五版)，高等教育出版社，2007
- Convex Optimization, Stephen Boyd,Lieven Vandenberghe, Cambridge University Press, 2004
  - 中译本：王书宁，许鋆，黄晓霖 译，凸优化，清华大学出版社，2013

我们在这里

- 问题答疑：http://www.xxwenda.com/
  - 烦请邀请visio或其他人回答问题

- 本课程QQ群：
  - 471632108(小象学院：机器学习群)

感谢大家！

恳请大家批评指正！