法律声明

- 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，小象学院和主讲老师拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意及内容，我们保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：小象
  - 新浪微博：ChinaHadoop

主题模型

小象学院 ChinaHadoop.cn

邹博

引：Γ函数

- Γ函数是阶乘在实数上的推广

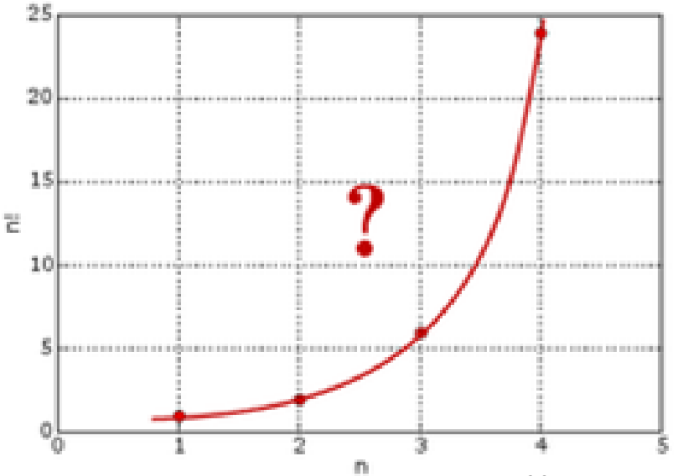

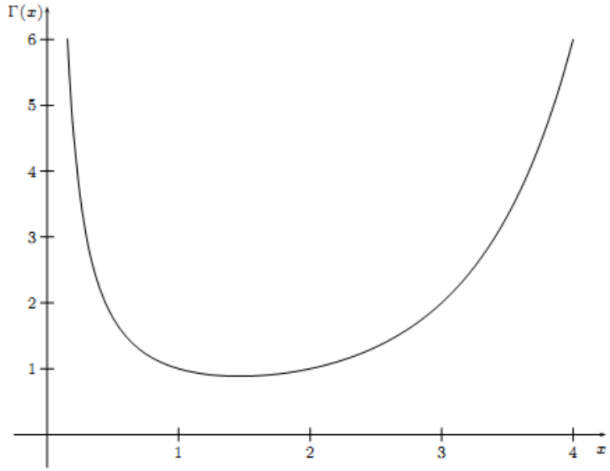

$$\Gamma(x)=\int_0^{+\infty} t^{x-1}e^{-t}dt=(x-1)!$$

$$\Gamma(x)=(x-1)\cdot\Gamma(x-1)\Rightarrow\frac{\Gamma(x)}{\Gamma(x-1)}=x-1$$

复习：Beta分布

- Beta分布的概率密度：

$$f(x)=\begin{cases}\dfrac{1}{B(\alpha,\beta)}x^{\alpha-1}(1-x)^{\beta-1}, & x\in(0,1)\\ 0, & \text{其他}\end{cases}$$

- 其中系数B为：

$$B(\alpha,\beta)=\int_0^1 x^{\alpha-1}(1-x)^{\beta-1}dx=\frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

- Gamma函数可以看成阶乘的实数域推广：

$$\Gamma(x)=\int_0^\infty t^{x-1}e^{-t}dt$$

$$\Rightarrow \Gamma(n)=(n-1)!\Rightarrow B(\alpha,\beta)=\frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

Beta分布的期望

$$f(x)=\frac{1}{B(\alpha,\beta)}x^{\alpha-1}(1-x)^{\beta-1},\ x\in(0,1)$$

$$B(\alpha,\beta)=\int_0^1 x^{\alpha-1}(1-x)^{\beta-1}dx=\frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

- 根据定义：

$$E(X)=\int_0^1 x\cdot\frac{1}{B(\alpha,\beta)}x^{\alpha-1}(1-x)^{\beta-1}dx$$

$$=\frac{1}{B(\alpha,\beta)}\int_0^1 x^{(\alpha+1)-1}(1-x)^{\beta-1}dx$$

$$=\frac{B(\alpha+1,\beta)}{B(\alpha,\beta)}=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\Big/\frac{\Gamma(\alpha+\beta+1)}{\Gamma(\alpha+1)\Gamma(\beta)}$$

$$=\frac{\alpha}{\alpha+\beta}$$

朴素贝叶斯的分析

- 可以胜任许多文本分类问题。
- 无法解决语料中一词多义和多词一义的问题——它更像是词法分析，而非语义分析。
- 如果使用词向量作为文档的特征，一词多义和多词一义会造成计算文档间相似度的不准确性。
- 可以通过增加“主题”的方式，一定程度的解决上述问题：
  - 一个词可能被映射到多个主题中
    - ——一词多义
  - 多个词可能被映射到某个主题的概率很高
    - ——多词一义

文档和主题

```
文档 1 : 茶馆 ( 0.0163591635916 ) 社会 ( 0.00528905289053 ) 王利发 ( 0.00528905289
文档 2 : 决议 ( 0.0138983050847 ) 打击 ( 0.00824858757062 ) 安理会 ( 0.00824858757
文档 3 : 会议 ( 0.0124491456469 ) 脱贫 ( 0.0124491456469 ) 党校 ( 0.0108218063466
文档 4 : 美团 ( 0.0306066176471 ) 阿里 ( 0.0103860294118 ) 业务 ( 0.0103860294118
文档 5 : 户口 ( 0.0221347331584 ) 登记 ( 0.0195100612423 ) 人口 ( 0.0142607174103
文档 6 : 人员 ( 0.0111471861472 ) 飞机 ( 0.00898268398268 ) 称 ( 0.00681818181818
文档 7 : 号线 ( 0.0328544061303 ) 站 ( 0.0194444444444 ) 14 ( 0.0184865900383 )
文档 8 : 支付 ( 0.0198394495413 ) 腾讯 ( 0.0072247706422 ) 支付宝 ( 0.007224770642
文档 9 : 决议 ( 0.0138983050847 ) 打击 ( 0.00824858757062 ) 安理会 ( 0.00824858757
文档 10 : 足协 ( 0.0186473429952 ) 足球 ( 0.0138164251208 ) 佩兰 ( 0.011884057971
==========
主题 1 : 美团 ( 0.0306066176471 ) 阿里 ( 0.0103860294118 ) 业务 ( 0.0103860294118
主题 2 : 会议 ( 0.0124491456469 ) 脱贫 ( 0.0124491456469 ) 党校 ( 0.0108218063466
主题 3 : 号线 ( 0.0328544061303 ) 站 ( 0.0194444444444 ) 14 ( 0.0184865900383 )
主题 4 : 人物 ( 0.00214876033058 ) 民族 ( 0.00214876033058 ) 资本家 ( 0.0021487603
主题 5 : 足协 ( 0.0186473429952 ) 足球 ( 0.0138164251208 ) 佩兰 ( 0.011884057971 )
主题 6 : 户口 ( 0.0221347331584 ) 登记 ( 0.0195100612423 ) 人口 ( 0.0142607174103
主题 7 : 决议 ( 0.0138983050847 ) 打击 ( 0.00824858757062 ) 安理会 ( 0.00824858757
主题 8 : 人员 ( 0.0111471861472 ) 飞机 ( 0.00898268398268 ) 称 ( 0.00681818181818
主题 9 : 茶馆 ( 0.0163591635916 ) 社会 ( 0.00528905289053 ) 王利发 ( 0.00528905289
主题 10 : 支付 ( 0.0198394495413 ) 腾讯 ( 0.0072247706422 ) 支付宝 ( 0.0072247706
```

1.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

话剧《茶馆》是著名作家老舍先生创作的一部不朽的名著，三幕话剧剧本，1957年完成；1958年由北京人民艺术剧院首排，焦菊隐、夏淳导演，于是之、郑榕、蓝天野、英若诚、黄宗洛等人主演，全剧以老北京一家大茶馆的兴衰变迁为背景，向人们展示了从清末到抗战胜利后的50年间

3.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

工作的意见》，听取关于巡视55家国有重要骨干企业有关情况的专题报告。中共中央总书记习近平主持会议。

会议认为，改革开放以来，党和国家实施大规模扶贫开发，使7亿农村贫困人口摆脱贫困，取得了举世瞩目的伟大成就，谱写了人类反贫困历史上的辉煌篇章。党的十八大以来，我们把扶贫开发工作摆在更加突出的位置，实施精准扶贫，开创了扶贫开发事业新局面。

会议指出，扶贫开发事关全面建成小康社会，

6.txt - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

重症乘客乘飞机救治被耽搁 南航称因刹车故障
新京报 分享 670参与
新京报讯 近日，有乘客发布《生死间，一个记者有话想对你们说》文章，称其乘坐南航CZ6101次航班时突发疾病，飞机降落后50分钟后才打开舱门，航空公司和地面救护人员都未及时施救的遭遇。昨日，南航通过官微对旅客表达歉意，因当天飞机刹车系统出现故障故不能继续滑行，目前仍在继续调查。
网友称遇急病遭“怠慢”，辗转多个医院
据媒体报道，11月9日，张先生从沈阳搭乘中国南方航空CZ6101次航班飞往北京首都国际机场。张先生称，飞机起飞约5分钟后，他感到腹部疼痛，随即向空乘人员反映，空乘人员表示可能是气压问题引起，并没有进行处理。
之后其腹痛的情况越来越严重，空乘人员赶紧帮忙预约了救护车，空乘和急救人员被指为谁该抬患者下飞机发生争执，患者最后自行勉强下旋梯爬进救护车。最后张先生在8小时后辗转了首都机场医院等，才被推送到北京大学人

pLSA模型

- 基于概率统计的pLSA模型(probabilistic Latent Semantic Analysis，概率隐语义分析)，增加了主题模型，形成简单的贝叶斯网络，可以使用EM算法学习模型参数。

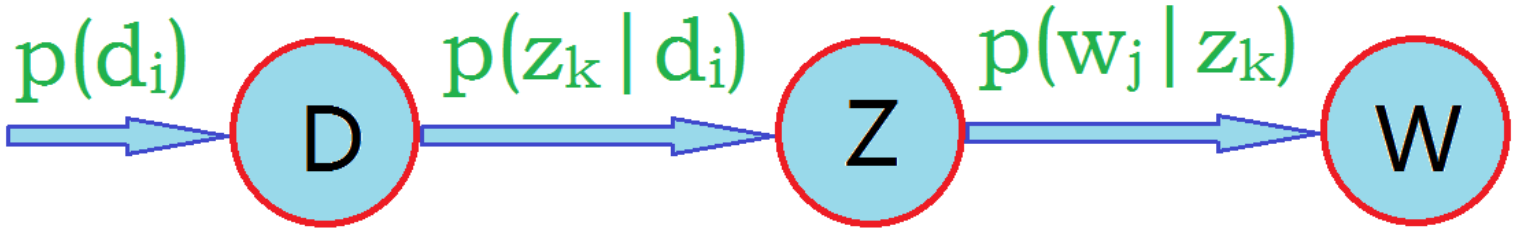

pLSA模型

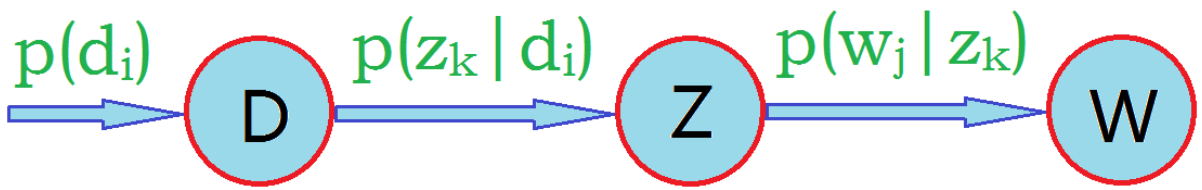

- D代表文档，Z代表主题(隐含类别)，W代表单词；
  - $P(d_i)$表示文档d_i的出现概率，
  - $P(z_k|d_i)$表示文档d_i中主题z_k出现的概率，
  - $P(w_j|z_k)$表示给定主题z_k的前提下单词w_j出现的概率。
- 每个文档在所有主题上服从多项分布；每个主题在所有词项上服从多项分布。
- 整个文档的生成过程是这样的：
  - 以$P(d_i)$的概率选中文档d_i；
  - 以$P(z_k|d_i)$的概率选中主题z_k；
  - 以$P(w_j|z_k)$的概率产生一个单词w_j。

pLSA模型

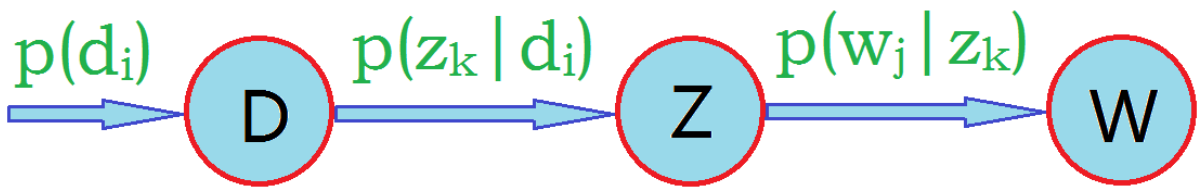

- 观察数据为(d_i,w_j)对，主题z_k是隐含变量。
- (d_i,w_j)的联合分布为

$$P(d_i, w_j) = P(w_j \mid d_i) P(d_i)$$

$$P(w_j \mid d_i) = \sum_{k=1}^{K} P(w_j \mid z_k) P(z_k \mid d_i)$$

- 而 $P(w_j \mid z_k), P(z_k \mid d_i)$对应了两组多项分布，而计算每个文档的主题分布，就是该模型的任务目标。

极大似然估计：w_j在d_i中出现的次数 $n(d_i, w_j)$

$$L = \prod_{i=1}^{N}\prod_{j=1}^{M} P(d_i, w_j) = \prod_i \prod_j P(d_i, w_j)^{n(d_i, w_j)}$$

$$l = \sum_i \sum_j n(d_i, w_j) \log P(d_i, w_j)$$

$$= \sum_i \sum_j n(d_i, w_j) \log P(w_j \mid d_i) P(d_i)$$

$$= \sum_i \sum_j n(d_i, w_j) \log \left(\sum_{k=1}^{K} P(w_j \mid z_k) P(z_k \mid d_i) \right) P(d_i)$$

$$= \sum_i \sum_j n(d_i, w_j) \log \left(\sum_{k=1}^{K} P(w_j \mid z_k) P(z_k \mid d_i) P(d_i) \right)$$

$$P(d_i, w_j) = P(w_j \mid d_i) P(d_i)$$

$$P(w_j \mid d_i) = \sum_{k=1}^{K} P(w_j \mid z_k) P(z_k \mid d_i)$$

目标函数分析

- 观察数据为(d_i,w_j)对，主题z_k是隐含变量。
- 目标函数 $$l=\sum_i\sum_j n(d_i,w_j)\log\left(\sum_{k=1}^{K}P(w_j\mid z_k)P(z_k\mid d_i)P(d_i)\right)$$
- 未知变量/自变量 $P(w_j\mid z_k),P(z_k\mid d_i)$
- 使用逐次逼近的办法：
  - 假定P(z_k|d_i)、P(w_j|z_k)已知，求隐含变量z_k的后验概率；
  - 在(d_i,w_j ,z_k)已知的前提下，求关于参数P(z_k|d_i)、P(w_j|z_k)的似然函数期望极大值，得到最优解P(z_k|d_i)、P(w_j|z_k)，带入上一步，从而循环迭代；
  - 即：EM算法。

求隐含变量主题z_k的后验概率

- 假定$P(z_k|d_i)$、$P(w_j|z_k)$已知，求隐含变量z_k的后验概率；

$$P(z_k \mid d_i, w_j) = \frac{P(w_j \mid z_k) P(z_k \mid d_i)}{\sum_{l=1}^{K} P(w_j \mid z_l) P(z_l \mid d_i)}$$

- 在(d_i, w_j, z_k)已知的前提下，求关于参数$P(z_k|d_i)$、$P(w_j|z_k)$的似然函数期望的极大值，得到最优解$P(z_k|d_i)$、$P(w_j|z_k)$，带入上一步，从而循环迭代；

分析似然函数期望

- 在(d_i, w_j, z_k)已知的前提下，求关于参数$P(z_k|d_i)$、$P(w_j|z_k)$的似然函数期望的极大值，得到最优解$P(z_k|d_i)$、$P(w_j|z_k)$，带入上一步，从而循环迭代；

EM算法整体框架

Repeat until convergence {

(E-step) For each i, set

$$Q_i(z^{(i)}) := p(z^{(i)}|x^{(i)};\theta).$$

(M-step) Set

$$\theta := \arg\max_{\theta} \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)};\theta)}{Q_i(z^{(i)})}$$

}

关于参数$P(z_k|d_i)P(w_j|z_k)$ 的似然函数期望

$$l = \sum_i \sum_j n(d_i, w_j) \log P(d_i, w_j)$$

$$= \sum_i \sum_j n(d_i, w_j) \log(P(w_j \mid d_i) P(d_i))$$

$$= \sum_i \sum_j n(d_i, w_j)(\log P(w_j \mid d_i) + \log P(d_i))$$

$$= \left(\sum_i \sum_j n(d_i, w_j) \log P(w_j \mid d_i) \right) + \left(\sum_i \sum_j n(d_i, w_j) \log P(d_i) \right)$$

$$\Rightarrow$$

$$l_{new} = \left(\sum_i \sum_j n(d_i, w_j) \log P(w_j \mid d_i) \right)$$

$$E(l_{new}) = \sum_i \sum_j n(d_i, w_j) \sum_{k=1}^{K} P(z_k \mid d_i, w_j) \log P(w_j, z_k \mid d_i)$$

$$= \sum_i \sum_j n(d_i, w_j) \sum_{k=1}^{K} P(z_k \mid d_i, w_j) \log P(w_j \mid z_k) P(z_k \mid d_i)$$

完成目标函数的建立

- 关于参数$P(z_k|d_i)$、$P(w_j|z_k)$的函数E，并且，带有概率加和为1的约束条件：

$$E=\sum_i\sum_j n(d_i,w_j)\sum_{k=1}^{K}P(z_k\mid d_i,w_j)\log P(w_j\mid z_k)P(z_k\mid d_i)$$

$$s.t.\begin{cases}\sum_{j=1}^{M}P(w_j\mid z_k)=1\\ \sum_{k=1}^{K}P(z_k\mid d_i)=1\end{cases}$$

- 显然，这是只有等式约束的求极值问题，使用Lagrange乘子法解决。

pLSA目标函数的求解

- Lagrange函数为：

$$Lag = \sum_i \sum_j n(d_i, w_j) \sum_{k=1}^{K} P(z_k \mid d_i, w_j) \log P(w_j \mid z_k) P(z_k \mid d_i)$$

$$+ \sum_{k=1}^{K} \tau_k \left(1 - \sum_{j=1}^{M} P(w_j \mid z_k)\right) + \sum_{i=1}^{N} \rho_i \left(1 - \sum_{k=1}^{K} P(z_k \mid d_i)\right)$$

- 求驻点：

$$\frac{\partial Lag}{\partial P(w_j \mid z_k)} = \frac{\sum_i n(d_i, w_j) P(z_k \mid d_i, w_j)}{P(w_j \mid z_k)} - \tau_k \overset{令}{==} 0$$

$$\frac{\partial Lag}{\partial P(z_k \mid d_i)} = \frac{\sum_j n(d_i, w_j) P(z_k \mid d_i, w_j)}{P(z_k \mid d_i)} - \rho_i \overset{令}{==} 0$$

分析第一个等式

$$\frac{\partial Lag}{\partial P(w_j \mid z_k)} = \frac{\sum_i n(d_i, w_j) P(z_k \mid d_i, w_j)}{P(w_j \mid z_k)} - \tau_k \overset{令}{==} 0$$

$$\Rightarrow \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j) = \tau_k P(w_j \mid z_k)$$

$$\Rightarrow \sum_{m=1}^{M} \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j) = \sum_{m=1}^{M} \tau_k P(w_j \mid z_k)$$

$$\Rightarrow \sum_{m=1}^{M} \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j) = \tau_k \sum_{m=1}^{M} P(w_j \mid z_k)$$

$$\Rightarrow \sum_{m=1}^{M} \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j) = \tau_k$$

$$\xrightarrow{\text{将}\tau_k\text{代回第二行式子}} \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j) = \left(\sum_{m=1}^{M} \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j) \right) \cdot P(w_j \mid z_k)$$

$$\Rightarrow P(w_j \mid z_k) = \frac{\sum_i n(d_i, w_j) P(z_k \mid d_i, w_j)}{\sum_{m=1}^{M} \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j)}$$

同理分析第二个等式

- 求极值时的解——M-Step：

$$\begin{cases} P(w_j \mid z_k) = \dfrac{\sum_i n(d_i, w_j) P(z_k \mid d_i, w_j)}{\sum_{m=1}^{M} \sum_i n(d_i, w_j) P(z_k \mid d_i, w_j)} \\ P(z_k \mid d_i) = \dfrac{\sum_j n(d_i, w_j) P(z_k \mid d_i, w_j)}{\sum_{k=1}^{K} \sum_j n(d_i, w_j) P(z_k \mid d_i, w_j)} \end{cases}$$

- 别忘了E-step： $P(z_k \mid d_i, w_j) = \dfrac{P(w_j \mid z_k) P(z_k \mid d_i)}{\sum_{l=1}^{K} P(w_j \mid z_l) P(z_l \mid d_i)}$

pLSA的总结

- pLSA应用于信息检索、过滤、自然语言处理等领域，pLSA考虑到词分布和主题分布，使用EM算法来学习参数。
- pLSA可以看做概率化的矩阵分解。
- 虽然推导略显复杂，但最终公式简洁清晰，很符合直观理解；推导过程使用了EM算法，也是学习EM算法的重要素材。

pLSA进一步思考

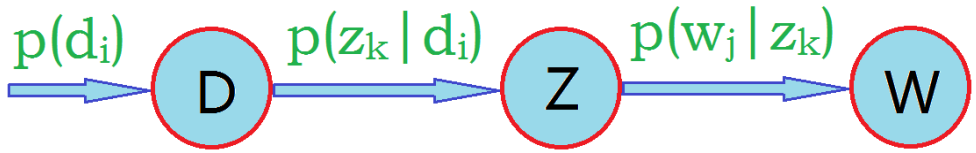

- 相对于“简单”的链状贝叶斯网络，可否给出“词”“主题”“文档”更细致的网络拓扑，形成更具一般性的模型？
- pLSA不需要先验信息即可完成自学习——这是它的优势。如果在特定的要求下，需要有先验知识的影响呢？
- 答：LDA模型；
  - 三层结构的贝叶斯模型
  - 需要超参数

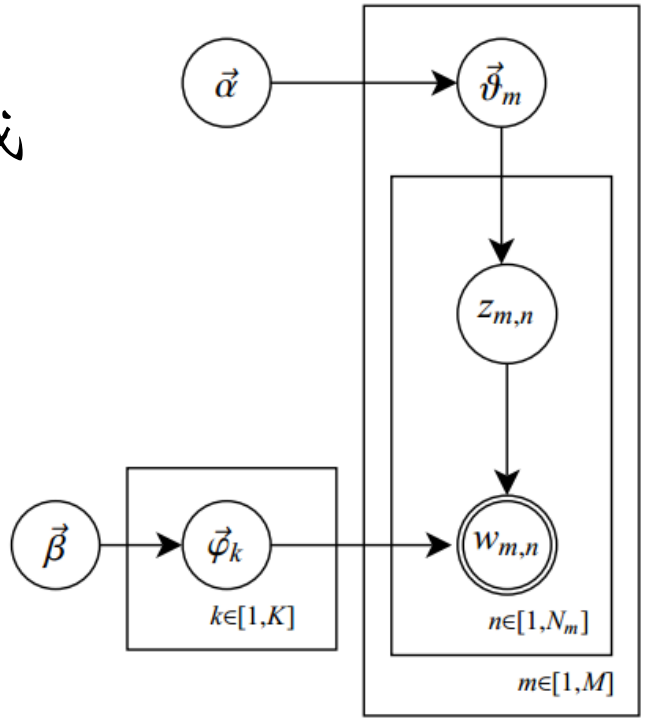

LDA涉及的主要问题

- 共轭先验分布
- Dirichlet分布
- LDA模型
  - Gibbs采样算法学习参数

两种认识

- 给定某系统的若干样本，求该系统的参数。
- 矩估计/MLE/MaxEnt/EM等：
  - 假定参数是某个/某些未知的定值，求这些参数如何取值，能够使得某目标函数取极大/极小。
  - 频率学派
- 贝叶斯模型：
  - 假定参数本身是变化的，服从某个分布。求在这个分布约束下使得某目标函数极大/极小。
  - 贝叶斯学派

频率学派和贝叶斯学派

- 无高低好坏之分，只是认识自然的手段。只是在当前人们掌握的数学工具和需解决的实践问题中，贝叶斯学派的理论体系往往能够比较好的解释目标函数、分析相互关系等。
  - 前面章节的内容，大多是频率学派的思想；下面的推理，使用贝叶斯学派的观点。
- 思考：大数据
  - 频率学派对于贝叶斯学派一次强有力逆袭

贝叶斯公式 $P(A|B)=\frac{P(B|A)P(A)}{P(B)}$

- 给定某系统的若干样本x，计算该系统的参数，即

$$P(\theta|x)=\frac{P(x|\theta)P(\theta)}{P(x)}$$

  - P(θ)：没有数据支持下，θ发生的概率：先验概率。
  - P(θ|x)：在数据x的支持下，θ发生的概率：后验概率。
  - P(x|θ)：给定某参数θ的概率分布：似然函数。
- 例如：
  - 在没有任何信息的前提下，猜测某人姓氏：先猜李王张刘……猜对的概率相对较大：先验概率。
  - 若知道某人来自“牛家村”，则他姓牛的概率很大：后验概率——但不排除他姓郭、杨等情况。

线性回归的复杂度惩罚因子

- 线性回归的目标函数为：

$$J(\vec{\theta})=\frac{1}{2}\sum_{i=1}^{m}\left(h_{\vec{\theta}}\left(x^{(i)}\right)-y^{(i)}\right)^2$$

- 将目标函数增加平方和损失：

$$J(\vec{\theta})=\frac{1}{2}\sum_{i=1}^{m}\left(h_{\vec{\theta}}\left(x^{(i)}\right)-y^{(i)}\right)^2+\lambda\sum_{j=1}^{n}\theta_j^2$$

- 本质即为假定参数θ服从高斯分布。

共轭先验分布

- 由于x为给定样本，P(x)有时被称为“证据”，仅仅是归一化因子，如果不关心P(θ|x)的具体值，只考察θ取何值时后验概率P(θ|x)最大，则可将分母省去。

$$P(\theta \mid x) = \frac{P(x \mid \theta)P(\theta)}{P(x)} \propto P(x \mid \theta)P(\theta)$$

- 在贝叶斯概率理论中，如果后验概率P(θ|x)和先验概率p(θ)满足同样的分布律，那么，先验分布和后验分布被叫做共轭分布，同时，先验分布叫做似然函数的共轭先验分布。
- In Bayesian probability theory, if the posterior distributions p(θ|x) are in the same family as the prior probability distribution p(θ), the prior and posterior are then called conjugate distributions, and the prior is called a conjugate prior for the likelihood function.

共轭先验分布的提出 $P(\theta|x) \propto P(x|\theta)P(\theta)$

- 某系统服从概率分布P(θ)时，
- 当观测到新的X数据时，有如下问题：
  - 根据新观测数据X，是否可以更新参数θ
  - 根据新观测数据X可以在多大程度上更新参数θ
    - θ← θ+ Δθ
  - 当重新估计θ的时候，以新参数值θ的新概率分布最大作为估计依据。即：maxP(θ|x)

共轭先验分布的实践意义

- 根据贝叶斯法则 $P(\theta|x) \propto P(x|\theta)P(\theta)$
  - 似然函数P(x|θ)表示以先验θ为参数的概率分布，可以直接求得
  - 先验分布P(θ)是θ的分布率，可根据先验知识获得。
    - 从哪里获得先验知识？
- 方案：选取似然函数P(x|θ)的共轭先验作为P(θ)的分布，这样，P(x|θ)乘以P(θ)(然后归一化)得到的P(θ|x)的形式和P(θ)的形式一样。

复习：二项分布的极大似然估计

- 投硬币试验中，进行N次独立试验，n次朝上，N-n次朝下。
- 假定朝上的概率为p，使用对数似然函数作为目标函数：

$$f(n \mid p) = \log\left(p^n (1-p)^{N-n}\right) \xrightarrow{\Delta} h(p)$$

$$\frac{\partial h(p)}{\partial p} = \frac{n}{p} - \frac{N-n}{1-p} \xrightarrow{\Delta} 0 \quad \Rightarrow p = \frac{n}{N}$$

二项分布与先验举例

- 在校门口统计一定时间段内出入的男女生数目分别为N_B和N_G，估算该校男女生比例。

$$\begin{cases} P_B = \dfrac{N_B}{N_B + N_G} \\ P_G = \dfrac{N_G}{N_B + N_G} \end{cases}$$

- 若观察到4个女生和1个男生，可以得出该校女生比例是80%吗？
- 修正公式：

$$\begin{cases} P_B = \dfrac{N_B + 5}{N_B + N_G + 10} \\ P_G = \dfrac{N_G + 5}{N_B + N_G + 10} \end{cases} \Rightarrow \begin{cases} P_B = \dfrac{1+5}{1+4+10} = 40\% \\ P_G = \dfrac{4+5}{1+4+10} = 60\% \end{cases}$$

上述过程的理论解释

- 投掷一个非均匀硬币，可以使用参数为θ的伯努利模型，θ为硬币为正面的概率，那么结果x的分布形式为：$P(x|\theta)=\theta^{x}\cdot(1-\theta)^{1-x}$
- 两点分布/二项分布的共轭先验是Beta分布，它具有两个参数α和β，Beta分布形式为

$$P(\theta|\alpha,\beta)=\frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{\int_0^1\theta^{\alpha-1}(1-\theta)^{\beta-1}d\theta}$$

先验概率和后验概率的关系

- 根据似然和先验：

$$P(x|\theta)=\theta^{x}\cdot(1-\theta)^{1-x} \qquad P(\theta|\alpha,\beta)=\frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{\int_0^1\theta^{\alpha-1}(1-\theta)^{\beta-1}d\theta}$$

- 计算后验概率

$$\begin{aligned}&P(\theta|x)\\&\propto P(x|\theta)\cdot P(\theta)\\&\propto\left(\theta^{x}(1-\theta)^{x}\right)\left(\theta^{\alpha-1}(1-\theta)^{\beta-1}\right)\\&=\theta^{x+a-1}(1-\theta)^{1-x+\beta-1}\end{aligned}$$

- 该后验概率的形式与先验概率的形式完全一样——后验概率是参数为(x+α,x+β)的另一个Beta分布，即：伯努利分布的共轭先验是Beta分布。

伪计数

- 如果我们关心的是Bernoulli分布的参数θ，则参数α、β是决定参数θ的参数，常常称之为“超参数”。
- 观察Beta分布的定义和后验概率：

$$P(\theta|\alpha,\beta)=\frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{\int_0^1\theta^{\alpha-1}(1-\theta)^{\beta-1}d\theta} \qquad P(\theta|x)\propto\theta^{x+a-1}(1-\theta)^{1-x+\beta-1}$$

  - 可以发现，在后验概率的最终表达式中，参数α和β和x一起作为参数θ的指数——后验概率的参数为(x+α,x+β)。而这个指数的实践意义是：投币过程中，正面朝上的次数。α和β 先验性的给出了在没有任何实验的前提下，硬币朝上的概率分配；因此，α和β常常被称作“伪计数”。

共轭先验的直接推广

- 从2到K：
  - 二项分布→多项分布
  - Beta分布→Dirichlet分布

Dirichlet分布

- Beta分布：$f(x)=\begin{cases}\dfrac{1}{B(\alpha,\beta)}x^{\alpha-1}(1-x)^{\beta-1}, & x\in(0,1)\\ 0, & \text{其他}\end{cases}$
  - 其中：$B(\alpha,\beta)=\dfrac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
- Dirichlet分布：$f(\vec{p}\,|\,\vec{\alpha})=\begin{cases}\dfrac{1}{\Delta(\vec{\alpha})}\prod_{k=1}^{K}p_k^{\alpha_k-1}, & p_k\in(0,1)\\ 0, & \text{其他}\end{cases}$
  - 简记：$Dir(\vec{p}\,|\,\vec{\alpha})=\dfrac{1}{\Delta(\vec{\alpha})}\prod_{k=1}^{K}p_k^{\alpha_k-1}$ 其中：$\Delta(\vec{\alpha})=\dfrac{\prod_{k=1}^{K}\Gamma(\alpha_k)}{\Gamma\left(\sum_{k=1}^{K}\alpha_k\right)}$

Dirichlet分布分析 $Dir(\vec{p}\,|\,\vec{\alpha}) = \frac{1}{\Delta(\vec{\alpha})}\prod_{k=1}^{K} p_k^{\alpha_k - 1}$

- α是参数向量，共K个
- 定义在$x_1,x_2\ldots x_{K-1}$维上
  - $x_1+x_2+\ldots+x_{K-1}+x_K=1$
  - $x_1,x_2\ldots x_{K-1}>0$
  - 定义在(K-1)维的单纯形上，其他区域的概率密度为0
- α的取值对Dir(p|α)有什么影响？

Symmetric Dirichlet distribution

- A very common special case is the symmetric Dirichlet distribution, where all of the elements making up the parameter vector have the same value. Symmetric Dirichlet distributions are often used when a Dirichlet prior is called for, since there typically is *no prior knowledge* favoring one component over another. Since all elements of the parameter vector have the same value, the distribution alternatively can be parametrized by a single scalar value α, called the concentration parameter(聚集参数).

对称Dirichlet分布

- Dirichlet分布：$Dir(\vec{p}\,|\,\vec{\alpha}) = \frac{1}{\Delta(\vec{\alpha})}\prod_{k=1}^{K} p_k^{\alpha_k - 1}$
  - 其中：$\Delta(\vec{\alpha}) = \frac{\prod_{k=1}^{K}\Gamma(\alpha_k)}{\Gamma\left(\sum_{k=1}^{K}\alpha_k\right)}$
- 对称Dirichlet分布：$Dir(\vec{p}\,|\,\alpha, K) = \frac{1}{\Delta_K(\alpha)}\prod_{k=1}^{K} p_k^{\alpha - 1}$
  - 其中：$\Delta_K(\vec{\alpha}) = \frac{\Gamma^K(\alpha_k)}{\Gamma(K\cdot\alpha)}$

对称Dirichlet分布的参数分析

- α=1时
  - 退化为均匀分布
- 当α>1时
  - $p_1=p_2=\ldots=p_k$的概率增大
- 当α<1时
  - $p_i=1$，$p_{非i}=0$的概率增大

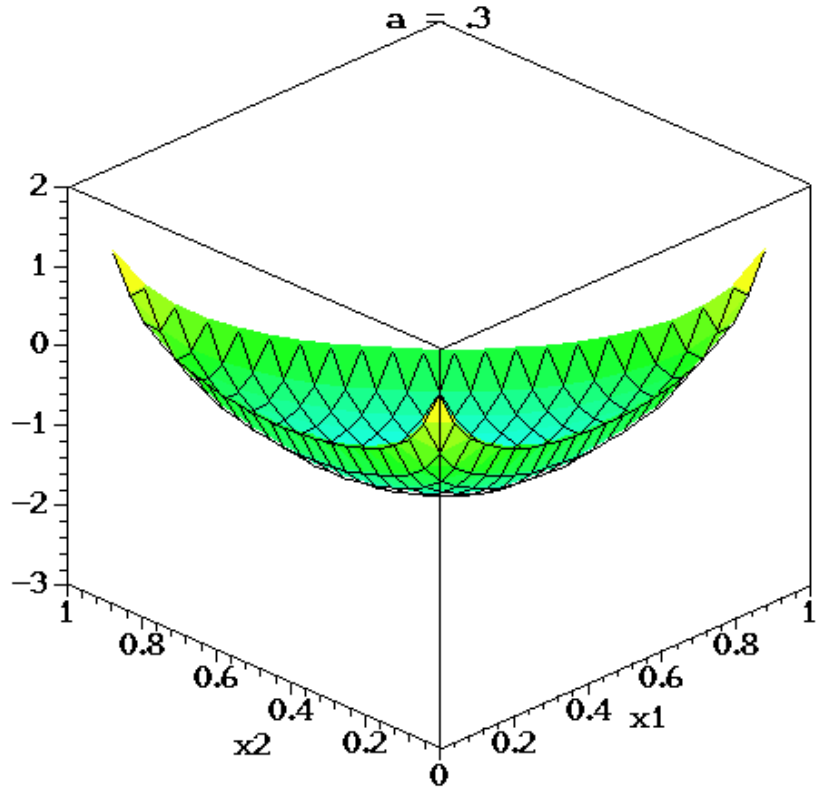

图像说明：将Dirichlet分布的概率密度函数取对数,绘制对称Dirichlet分布的图像，取K=3，也就是有两个独立参数x1,x2，分别对应图中的两个坐标轴，第三个参数始终满足x3=1-x1-x2且α1=α2=α3=α，图中反映的是α从0.3变化到2.0的概率对数值的变化情况。

小象学院 ChinaHadoop.cn

参数α对Dirichlet分布的影响

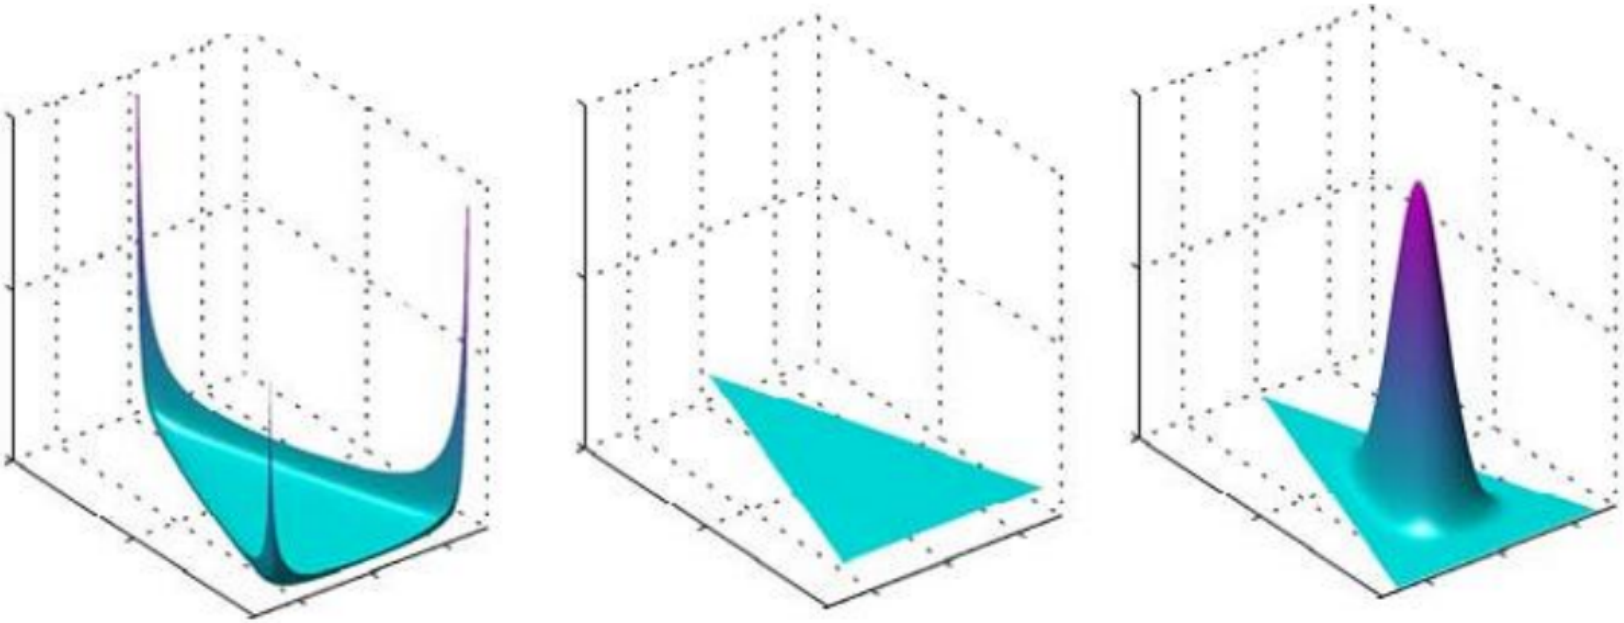

$\{\alpha_k\} = 0.1$ $\{\alpha_k\} = 1$ $\{\alpha_k\} = 10$

参数选择对对称Dirichlet分布的影响

- When α=1, the symmetric Dirichlet distribution is equivalent to a uniform distribution over the open standard (K−1)-simplex, i.e. it is uniform over all points in its support. Values of the concentration parameter above 1 prefer variants that are dense, evenly distributed distributions, i.e. all the values within a single sample are similar to each other. Values of the concentration parameter below 1 prefer sparse distributions, i.e. most of the values within a single sample will be close to 0, and the vast majority of the mass will be concentrated in a few of the values.

多项分布的共轭分布是Dirichlet分布

$$
\begin{aligned}
\boldsymbol{\alpha} &= (\alpha_1, \cdots, \alpha_K) &&= \text{concentration hyperparameter} \\
\mathbf{p} \mid \boldsymbol{\alpha} &= (p_1, \cdots, p_K) &&\sim \mathrm{Dir}(K, \boldsymbol{\alpha}) \\
\mathbb{X} \mid \mathbf{p} &= (\mathbf{x}_1, \cdots, \mathbf{x}_K) &&\sim \mathrm{Cat}(K, \mathbf{p}) \\
\mathbf{c} &= (c_1, \cdots, c_K) &&= \text{number of occurrences of category } i \\
\mathbf{p} \mid \mathbb{X}, \boldsymbol{\alpha} &\sim \mathrm{Dir}(K, \mathbf{c} + \boldsymbol{\alpha}) &&= \mathrm{Dir}\left(K, c_1 + \alpha_1, \cdots, c_K + \alpha_K\right)
\end{aligned}
$$

LDA的解释

- 共有m篇文章，一共涉及了K个主题；
- 每篇文章(长度为N_m)都有各自的主题分布，主题分布是多项分布，该多项分布的参数服从Dirichlet分布，该Dirichlet分布的参数为α；
- 每个主题都有各自的词分布，词分布为多项分布，该多项分布的参数服从Dirichlet分布，该Dirichlet分布的参数为β；
- 对于某篇文章中的第n个词，首先从该文章的主题分布中采样一个主题，然后在这个主题对应的词分布中采样一个词。不断重复这个随机生成过程，直到m篇文章全部完成上述过程。

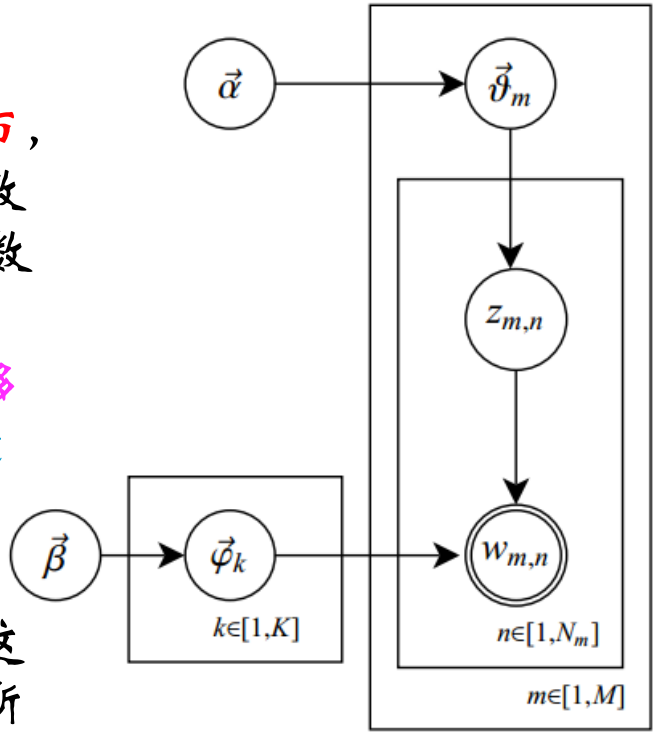

详细解释

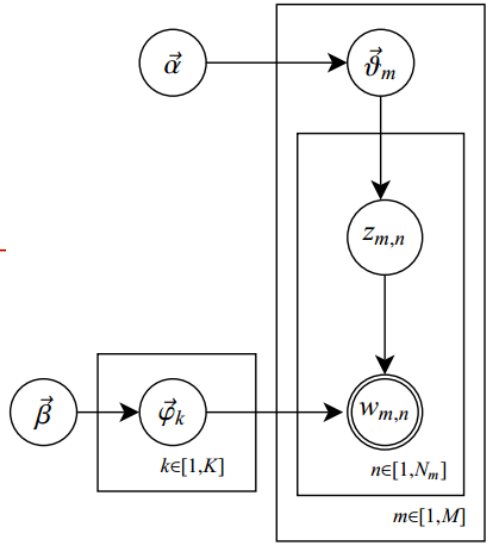

- 字典中共有V个term(不可重复)，这些term出现在具体文章中，就是word——在具体某文章中的word当然可能重复的。
- 语料库中共有m篇文档$d_1,d_2\ldots d_m$；
- 对于文档d_i，由N_i个word组成，可重复；
- 语料库中共有K个主题T_1，$T_2\ldots T_k$；
- α和β为先验分布的参数，一般事先给定：如取0.1的对称Dirichlet分布——表示在参数学习结束后，期望每个文档的主题不会十分集中。
- θ是每篇文档的主题分布
  - 对于第i篇文档d_i的主题分布是$\boldsymbol{\theta}_i=(\theta_{i1}, \theta_{i2}\ldots,\theta_{iK})$，是长度为K的向量；
- 对于第i篇文档d_i，在主题分布$\boldsymbol{\theta}_i$下，可以确定一个具体的主题$z_{ij}=k$，$k\in[1,K]$，
- φ_k表示第k个主题的词分布，$k\in[1,K]$
  - 对于第k个主题T_k的词分布$\varphi_k=(\varphi_{k1}, \varphi_{k2}\ldots \varphi_{kv})$，是长度为v的向量
- 由z_{ij}选择φ_{zij}，表示由词分布φ_{zij}确定term，即得到观测值w_{ij}。

参考文献

- David M. Blei, Andrew Y. Ng, Michael I. Jordan, *Latent Dirichlet Allocation*, 2003
- Gregor Heinrich, *Parameter estimation for text analysis*. 2008
- http://en.wikipedia.org/wiki/Dirichlet_distribution
- http://en.wikipedia.org/wiki/Conjugate_prior

我们在这里

- 问题答疑：http://www.xxwenda.com/
  - 烦请邀请visio或其他人回答问题

- 本课程QQ群：
  - 471632108(小象学院：机器学习群)

感谢大家！

恳请大家批评指正！