法律声明

- 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，小象学院和主讲老师拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意及内容，我们保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：小象
  - 新浪微博：ChinaHadoop

采样

小象学院 ChinaHadoop.cn

邹博

主要内容

- 采样的意义
- 拒绝采样方法
- 马尔科夫链
  - 细致平稳条件
- Matropolis-Hastings算法
- Gibbs采样

思考：LDA的迭代为何如此设计？

$$
\begin{aligned}
p(z_i{=}k|\vec{z}_{\neg i},\vec{w}) &= \frac{p(\vec{w},\vec{z})}{p(\vec{w},\vec{z}_{\neg i})} = \frac{p(\vec{w}|\vec{z})}{p(\vec{w}_{\neg i}|\vec{z}_{\neg i})p(w_i)} \cdot \frac{p(\vec{z})}{p(\vec{z}_{\neg i})} \\
&\propto \frac{\Delta(\vec{n}_z+\vec{\beta})}{\Delta(\vec{n}_{z,\neg i}+\vec{\beta})} \cdot \frac{\Delta(\vec{n}_m+\vec{\alpha})}{\Delta(\vec{n}_{m,\neg i}+\vec{\alpha})} \\
&= \frac{\Gamma(n_k^{(t)}+\beta_t)\,\Gamma(\sum_{t=1}^{V} n_{k,\neg i}^{(t)}+\beta_t)}{\Gamma(n_{k,\neg i}^{(t)}+\beta_t)\,\Gamma(\sum_{t=1}^{V} n_k^{(t)}+\beta_t)} \cdot \frac{\Gamma(n_m^{(k)}+\alpha_k)\,\Gamma(\sum_{k=1}^{K} n_{m,\neg i}^{(k)}+\alpha_k)}{\Gamma(n_{m,\neg i}^{(k)}+\alpha_k)\,\Gamma(\sum_{k=1}^{K} n_m^{(k)}+\alpha_k)} \\
&= \frac{n_{k,\neg i}^{(t)}+\beta_t}{\sum_{t=1}^{V} n_{k,\neg i}^{(t)}+\beta_t} \cdot \frac{n_{m,\neg i}^{(k)}+\alpha_k}{[\sum_{k=1}^{K} n_m^{(k)}+\alpha_k]-1} \\
&\propto \frac{n_{k,\neg i}^{(t)}+\beta_t}{\sum_{t=1}^{V} n_{k,\neg i}^{(t)}+\beta_t}(n_{m,\neg i}^{(k)}+\alpha_k)
\end{aligned}
$$

Code

```python
def gibbs_sampling(z, m, i, nt, nd, nt_sum, nd_sum, term):
    topic = z[m][i]          # 当前主题
    nt[term][topic] -= 1     # 去除当前词
    nd[m][topic] -= 1
    nt_sum[topic] -= 1
    nd_sum[m] -= 1

    topic_alpha = topic_number * alpha
    term_beta = len(dic) * beta
    p = [0 for x in range(topic_number)] # p[k]:属于主题k的概率
    for k in range(topic_number):
        p[k] = (nd[m][k] + alpha) / (nd_sum[m] + topic_alpha)\
               * (nt[term][k] + beta) / (nt_sum[k] + term_beta)
        if k >= 1:        # 顺手转换成累加概率
            p[k] += p[k-1]
    gs = random.random() * p[topic_number-1]    # 采样
    new_topic = 0
    while new_topic < topic_number:
        if p[new_topic] > gs:
            break
        new_topic += 1

    nt[term][new_topic] += 1
    nd[m][new_topic] += 1
    nt_sum[new_topic] += 1
    nd_sum[m] += 1
    z[m][i] = new_topic     # 新主题
```

为什么要研究采样？

- 根据采样结果估算分布的参数，完成参数学习。
  - 前提：模型已经存在，但参数未知；
  - 方法：通过采样的方式，获得一定数量的样本，从而学习该系统的参数。
  - 例：投硬币试验中，进行N次试验，n次朝上，N-n次朝下——可以认为，是进行了N次(独立)抽样。
  - 假定朝上的概率为p，使用对数似然函数作为目标函数：

$$f(n \mid p) = \log\left(p^n (1-p)^{N-n}\right) \xrightarrow{\Delta} h(p) = \log\left(p^n (1-p)^{N-n}\right)$$

$$\frac{\partial h(p)}{\partial p} = \frac{n}{p} - \frac{N-n}{1-p} \xrightarrow{\Delta} 0 \Rightarrow p = \frac{n}{N}$$

附：Bernoulli版本的大数定理

- 一次试验中事件A发生的概率为p；重复n次独立试验中，事件A发生了n_A次，则p、n、n_A的关系满足：

  对于任意整数ε，

$$\lim_{n\to\infty} P\left\{\left|\frac{n_A}{n}-p\right|<\varepsilon\right\}=1$$

应用Bernoulli版本的大数定理

- 一般的说，上述结论可以直接推广：频率的极限为概率：$p = n/N$
- 将上述二项分布扩展成多项分布，如K项分布：$p_i = \frac{n_i}{N}$
  - 从而得到K项分布的参数：$p = \left(\frac{n_1}{N}, \frac{n_2}{N} \cdots \frac{n_k}{N}\right)$
- 在主体模型LDA中，每个文档的主题分布和每个主题的词分布都是多项分布，如果能够通过采样的方式获得关于参数的一定数量的样本，即可估算主题分布和词分布的参数，即可完成参数学习。

采样算法

- 现需要对概率密度函数f(x)的参数进行估计，若已知的某概率密度函数g(x)容易采样获得其样本，可以如何估计f(x)的参数？
  - 若离散分布，则f(x)为概率分布律。

Matropolis-Hastings算法

- 假定t时刻$X^{(t)}=x^{(t)}$，采取如下策略采样$X^{(t+1)}$
- 在给定$x^{(t)}$的条件分布$g(x|x^{(t)})$中采样一个值x^*
- 计算M-H率：$R\left(x^{(t)},x^*\right)=\dfrac{f(x^*)g(x^{(t)}|x^*)}{f(x^{(t)})g(x^*|x^{(t)})}$ $\begin{cases} f\left(x^{(t)}\right)>0 \\ g\left(x^*|x^{(t)}\right)>0 \end{cases}$
- 则t+1时刻的X值$x^{(t+1)}$为：

$$X^{(t+1)}=\begin{cases} x^*, & p(t)\le R\left(x^{(t)},x^*\right), t\in Uniform(0,1) \\ x^{(t)}, & otherwise \end{cases}$$

- 最终得到的序列收敛于f(x)分布。

分析MH率 $R\left(x^{(t)},x^{*}\right)=\dfrac{f(x^{*})g(x^{(t)}\mid x^{*})}{f(x^{(t)})g(x^{(t)}\mid x^{*})}$

- 两样本x_1,x_2，不妨假定$f\left(x_2\right)g\left(x_1\mid x_2\right)\geq f\left(x_1\right)g\left(x_2\mid x_1\right)$
- 则：

$$p\left(X^{(t)}=x_1,X^{(t+1)}=x_2\right)$$
$$=f\left(x_1\right)\cdot g\left(x_2\mid x_1\right)\cdot R\left(x_1,x_2\right)$$
$$=f\left(x_1\right)\cdot g\left(x_2\mid x_1\right)$$

$$p\left(X^{(t)}=x_2,X^{(t+1)}=x_1\right)$$
$$=f\left(x_2\right)\cdot g\left(x_1\mid x_2\right)\cdot R\left(x_2,x_1\right)$$
$$=f\left(x_2\right)\cdot g\left(x_1\mid x_2\right)\cdot\frac{f\left(x_1\right)\cdot g\left(x_2\mid x_1\right)}{f\left(x_2\right)\cdot g\left(x_1\mid x_2\right)}$$
$$=f\left(x_1\right)\cdot g\left(x_2\mid x_1\right)$$

- 若在某个时刻t，使得$x^{(t)}$满足f(x)的分布，则后面的采样值服从f(x)的分布。

给定区域的二维随机数

- 最简单的采样问题：
  - 给定区间$[a_x,b_x]\times[a_y,b_y]$，使得二维随机点(x,y)落在等概率落在区间的某个点上。
- 分析：因为两个维度是独立的，分别生成两个随机数即可。

产生二维随机数代码与效果

```
int rand50()
{
    return rand() % 100 - 50;
}

int _tmain(int argc, _TCHAR* argv[])
{
    ofstream oFile;
    oFile.open(_T("D:\\rand.txt"));
    int x,y;
    for(int i = 0; i < 1000; i++)
    {
        x = rand50();
        y = rand50();
        oFile << x << '\t' << y << '\n';
    }
    oFile.close();
    return 0;
}
```

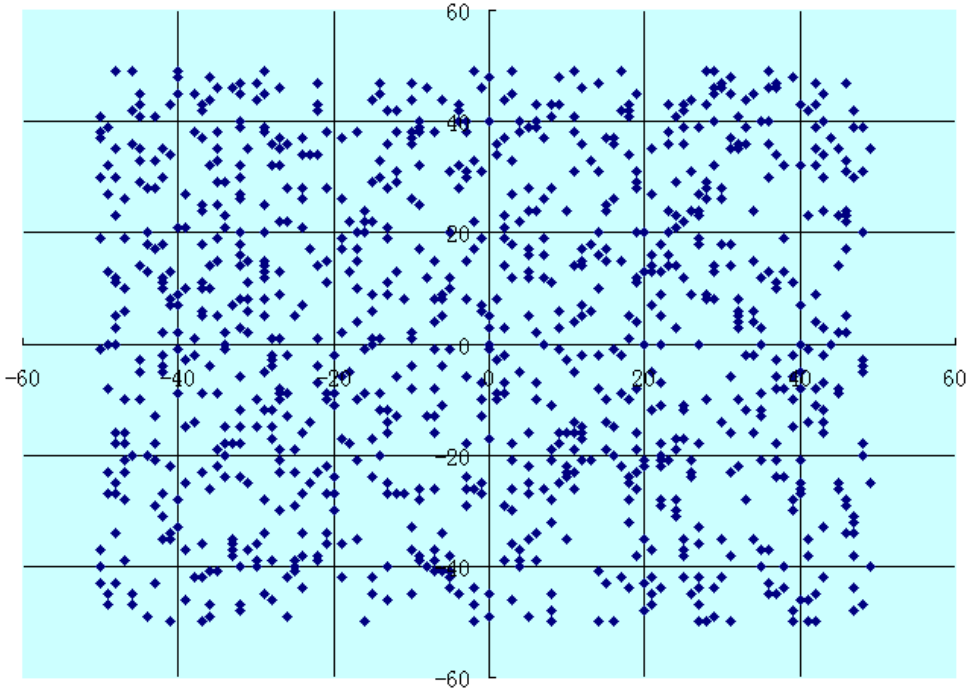

圆内均匀取点

- 给定定点$O(x_0,y_0)$和半径r，使得二维随机点(x,y)等概率落在圆内。
- 直接使用$x=x_0+r*\cos\theta$，$y=y_0+r*\sin\theta$？

```
int rand50()
{
    return rand() % 100 - 50;
}

int _tmain(int argc, _TCHAR* argv[])
{
    ofstream oFile;
    oFile.open(_T("D:\\rand.txt"));
    double r,theta;
    double x,y;
    for(int i = 0; i < 1000; i++)
    {
        r = rand50();
        theta = rand();
        x = r*cos(theta);
        y = r*sin(theta);
        oFile << x << '\t' << y << '\n';
    }
    oFile.close();
    return 0;
}
```

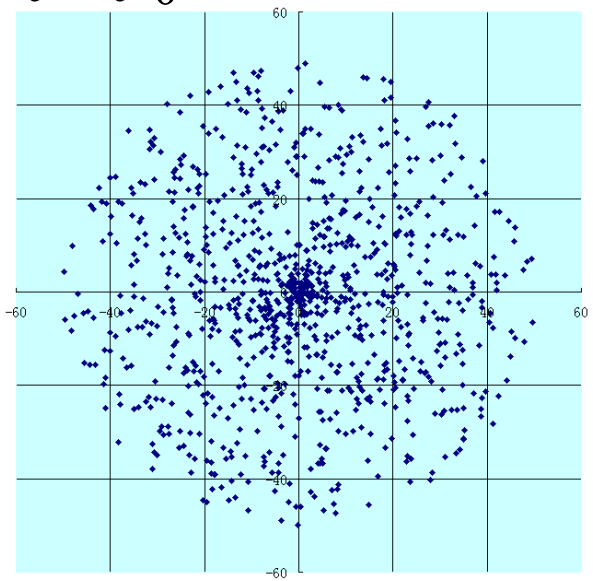

有选择的取点

- 显然上述做法是不对的。但可以使用二维随机点的做法，若落在圆外，则重新生成点。结果如下。

```
int rand50()
{
    return rand() % 100 - 50;
}

int _tmain(int argc, _TCHAR* argv[])
{
    ofstream oFile;
    oFile.open(_T("D:\\rand.txt"));
    int x,y;
    for(int i = 0; i < 1000; i++)
    {
        x = rand50();
        y = rand50();
        if(x*x + y*y < 2500)
            oFile << x << '\t' << y << '\n';
    }
    oFile.close();
    return 0;
}
```

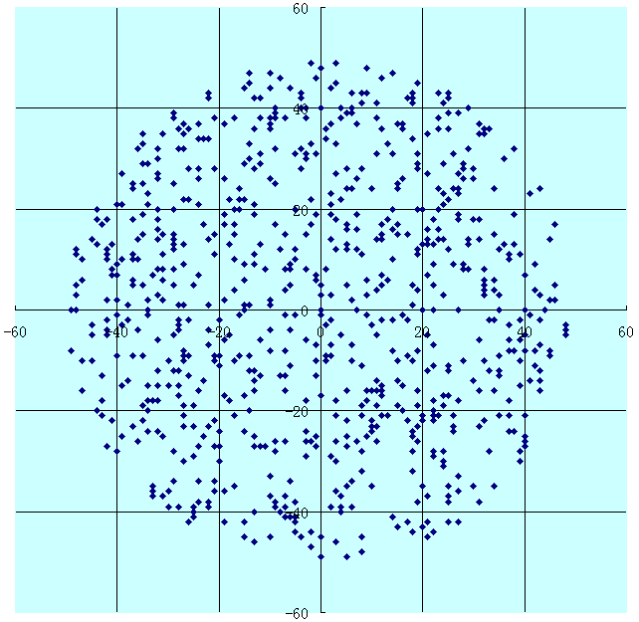

分析

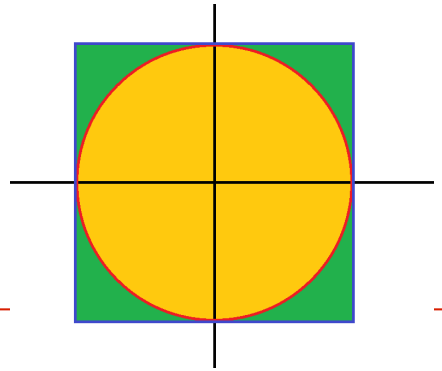

- 在对某区域$f(x,y)\le 0$抽样的过程中，若该区域$f(x,y)\le 0$不容易直接求解，则寻找某容易采样的区域$g(x,y)\le 0$，G为F的上界。当采样$(x_0,y_0)\in G$且落在F内部时，接收该采样；否则拒绝之。
  - 该例中，$f(x,y)\le 0$是圆，$g(x,y)\le 0$是该圆的外包围正方形。
  - 注：区域$f(x,y)\le 0$的可行解集合记做F；区域$g(x,y)\le 0$的可行解集合记做G；显然$F\subseteq G$

附：产生圆内随机数的其他方法

```
double rand2500()
{
    return rand() % 2500;
}

int _tmain(int argc, _TCHAR* argv[])
{
    ofstream oFile;
    oFile.open(_T("D:\\rand.txt"));
    double r,theta;
    double x,y;
    for(int i = 0; i < 1000; i++)
    {
        r = sqrt(rand2500());
        theta = rand();
        x = r*cos(theta);
        y = r*sin(theta);
        oFile << x << '\t' << y << '\n';
    }
    oFile.close();
    return 0;
}
```

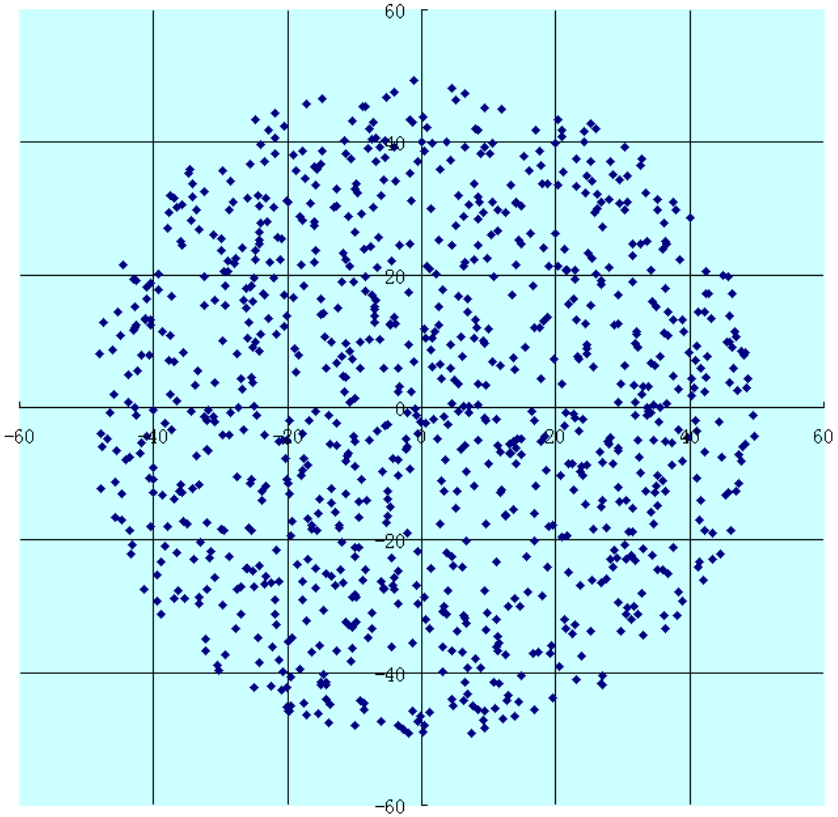

附：产生三角形内随机数

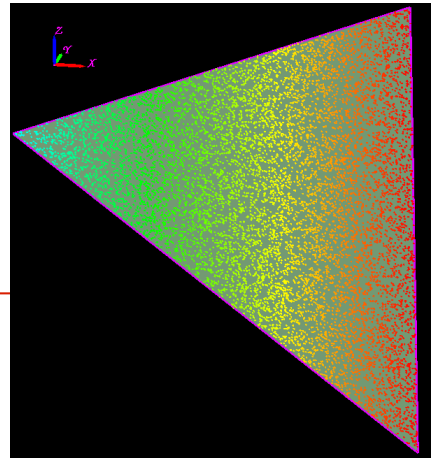

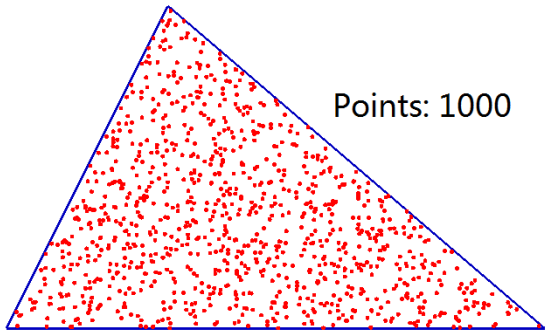

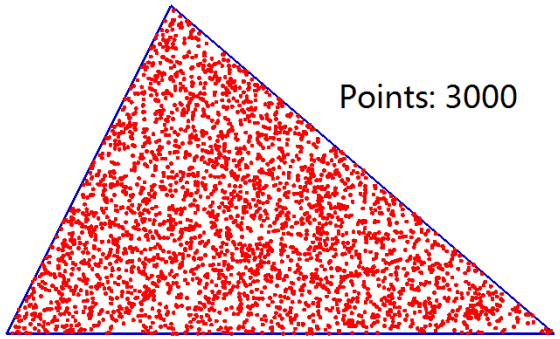


```
void CRandomTriangle::Random2(int nSize)
{
    CalcRotate();
    m_nSize = nSize;
    if(m_pRandomPoint)
        delete[] m_pRandomPoint;
    m_pRandomPoint = new CDelPoint[nSize];
    CDelPoint pt;
    for(int i = 0; i < nSize; i++)
    {
        pt.RandomInRectangle(m_ptExtend, m_ptHeight);
        if(m_tsBig.IsIn(pt))
        {
            pt += m_ptBase;
            m_pRandomPoint[i] = pt;
        }
        else if(m_tsLeft.IsIn(pt))
        {
            CDelPoint::MirrorPoint(pt, m_ptLeft0);
            pt += m_ptBase;
            m_pRandomPoint[i] = pt;
        }
        else if(m_tsRight.IsIn(pt))
        {
            CDelPoint::MirrorPoint(pt, m_ptRight0);
            pt += m_ptBase;
            m_pRandomPoint[i] = pt;
        }
    }
    CDelPoint::Save(m_pRandomPoint, m_nSize, _T("D:\\random.pt"), 0);
}
```

进一步思考：Rejection sampling

- 上述方法能够一定程度的估算圆周率——虽然精度很差。
- 上述抽样问题能否用来解决一般概率分布函数的抽样问题？如：根据均匀分布函数得到正态分布的抽样。
- Rejection sampling

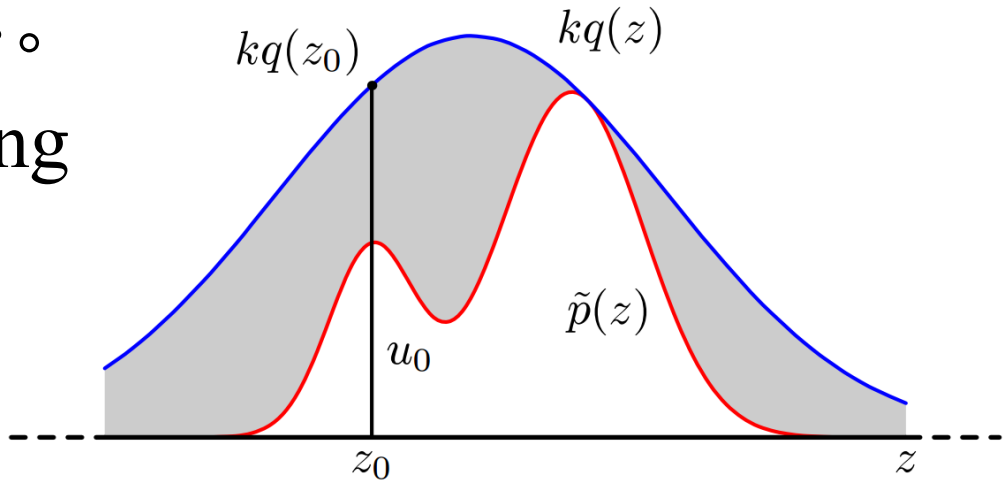

重述采样

- 采样：给定概率分布p(x)，如何在计算机中生成它的若干样本？
- 方法：马尔科夫链模型
- 考虑某随机过程π，它的状态有n个，用1~n表示。记在当前时刻t时位于i状态，它在t+1时刻位于j状态的概率为P(i,j)=P(j|i)：即状态转移的概率只依赖于前一个状态。

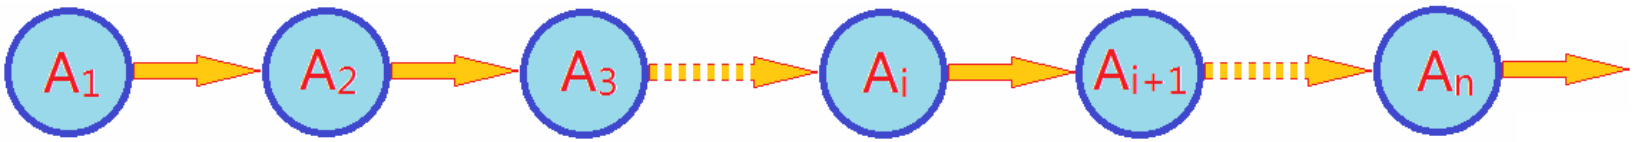

举例

- 假定按照经济状况将人群分成上、中、下三个阶层，用1、2、3表示。假定当前处于某阶层只和上一代有关，即：考察父代为第i阶层，则子代为第j阶层的概率。假定为如下转移概率矩阵：

$$
\begin{array}{cc}
P & \text{子代} \\
\text{父代} & \begin{bmatrix} 0.65 & 0.28 & 0.07 \\ 0.15 & 0.67 & 0.18 \\ 0.12 & 0.36 & 0.52 \end{bmatrix}
\end{array}
$$

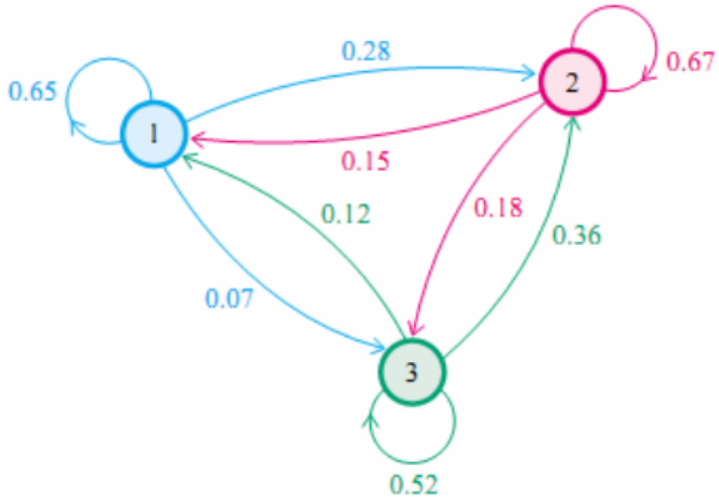

概率转移矩阵

- 显然，第n+1代中处于第j个阶层的概率为：

$$\pi(X_{n+1}=j)=\sum_{i=1}^{n}\pi(X_n=i)\cdot P(X_{n+1}=j\mid X_n=i)$$

- 因此，矩阵P即贝叶斯网络中描述的(条件)概率转移矩阵。
  - 第i行元素表示：在上一个状态为i时的分布概率，即：每一行元素的和为1。

初始概率π= [0.21, 0.68, 0.1]的迭代结果

第n代	第1阶层	第2阶层	第3阶层
0	0.21	0.68	0.11
1	0.252	0.554	0.194
2	0.27	0.512	0.218
3	0.278	0.497	0.225
4	0.282	0.49	0.226
5	0.285	0.489	0.225
6	0.286	0.489	0.225
7	0.286	0.489	0.225
8	0.286	0.488	0.225
9	0.286	0.489	0.225
10	0.286	0.489	0.225

初始概率π= [0.75, 0.15, 0.1]的迭代结果

第n代	第1阶层	第2阶层	第3阶层
0	0.75	0.15	0.1
1	0.522	0.347	0.132
2	0.407	0.426	0.167
3	0.349	0.459	0.192
4	0.318	0.475	0.207
5	0.303	0.482	0.215
6	0.295	0.485	0.22
7	0.291	0.487	0.222
8	0.289	0.488	0.225
9	0.286	0.489	0.225
10	0.286	0.489	0.225

马尔科夫随机过程的平稳分布

- 初始概率不同，但经过若干次迭代，π最终稳定收敛在某个分布上。
- 转移概率矩阵P的性质，而非初始分布的性质。事实上，上述矩阵P的n次幂，每行都是(0.286,0.489,0.225)，n>20
- 如果一个非周期马尔科夫随机过程具有转移概率矩阵P，且它的任意两个状态都是连通的，则 $\lim_{n\to\infty} P_{ij}^{n}$ 存在，记做 $\lim_{n\to\infty} P_{ij}^{n} = \pi(j)$。

马尔科夫随机过程的平稳分布

- 事实上，下面两种写法等价：

$$\lim_{n\to\infty} P_{ij}^{n} = \pi(j) \qquad \lim_{n\to\infty} P^{n} = \begin{bmatrix} \pi(1) & \pi(2) & \dots & \pi(n) \\ \pi(1) & \pi(2) & \dots & \pi(n) \\ \vdots & \vdots & \ddots & \vdots \\ \pi(1) & \pi(2) & \cdots & \pi(n) \end{bmatrix}$$

- 同时，若某概率分布πP=π，说明
  - 该多项分布π是状态转移矩阵P的平稳分布；
  - 线性方程xP=x的非负解为π，而P^n唯一，因此π是线性方程xP=x的唯一非负解。

马尔科夫随机过程与采样

- 上述平稳分布的马尔科夫随机过程对采样带来很大的启发：对于某概率分布π，生成一个能够收敛到概率分布π的马尔科夫状态转移矩阵P，则经过有限次迭代，一定可以得到概率分布π。
- 该方法可使用Monte Carlo模拟来完成，称之为MCMC(Markov Chain Monte Carlo)。

细致平稳条件

- 从稳定分布满足πP=π可以抽象出如下定义：
- 如果非周期马尔科夫过程的转移矩阵P和分布π(x)满足

$$\forall i, j, \pi(i)P(i,j) = \pi(j)P(j,i)$$

- 则π(x)是马尔科夫过程的平稳分布。上式又被称作细致平稳条件 (detailed balance condition) 。
  - P(i,j)为矩阵P的第i行第j列，其意思为前一个状态为i时，后一个状态为j的概率：即P(j|i)，因此，有时也写成P(i→j)
  - 细致平稳的理解：根据定义，对于任意两个状态i，j，从i转移到j的概率和从j转移到i的概率相等。可直观的理解成每一个状态都是平稳的。

细致平稳条件和平稳分布的关系

- 根据马尔科夫过程的定义：$\pi(j)=\sum_{i=1}^{n}\pi(i)\cdot P(i,j)$
- 根据细致平稳条件：

$$\forall i,j,\pi(i)P(i,j)=\pi(j)P(j,i)$$

- 得：

$$\pi(j)=\sum_{i=1}^{n}\pi(j)\cdot P(j,i)$$

- 从而：

$$\pi=\pi\cdot P$$

设定接受率

- 假定当前马尔科夫过程的转移矩阵为Q，对于给定分布p，一般的说，$p(i)q(i,j) \neq p(j)q(j,i)$
- 通过加入因子α的方式，使得上式满足细致平稳条件 $p(i)q(i,j)\alpha(i,j) = p(j)q(j,i)\alpha(j,i)$
- 满足等式的因子α有很多，根据对称性，可以取：$\alpha(i,j) = p(j)q(j,i)$，$\alpha(j,i) = p(i)q(i,j)$
- 根据接受率α改造转移矩阵Q：

$$p(i)\underline{\underline{q(i,j)\alpha(i,j)}} = p(j)\underline{\underline{q(j,i)\alpha(j,i)}}$$

MCMC：Metropolis-Hastings算法

- 根据需要满足的细致平稳条件

$$p(i)q(i,j)\alpha(i,j)=p(j)q(j,i)\alpha(j,i)$$

- 若令α(j,i)=1，则有： $p(i)q(i,j)\alpha(i,j)=p(j)q(j,i)$
- 从而：

$$\alpha(i,j)=\frac{p(j)q(j,i)}{p(i)q(i,j)}$$

- 将接受率置为恒小于1，从而

$$\alpha(i,j)=\min\left(\frac{p(j)q(j,i)}{p(i)q(i,j)},1\right)$$

Metropolis-Hastings算法

- 初始化马尔科夫过程初始状态$I=i_0$
- 对$t=0,1,2,3\ldots$
  - 第t时刻马尔科夫过程初始状态i_t,采样$q=q(j|i_t)$
  - 从均匀分布中采样$u\in[0,1]$
  - 如果 $$u<\alpha(i,j)=\min\left(\frac{p(j)q(j,i)}{p(i)q(i,j)},1\right)$$

    则接受状态j，即$i_{t+1}=j$

    否则，不接受状态j，即$i_{t+1}=i$

改造MCMC算法

- MCMC有一定的拒绝率。
- 若需要采样二维联合分布p(x,y)，固定x，得

$$p(x_1,y_1)\alpha_{x_1}(y_1,y_2)=p(x_1,y_2)\alpha_{x_1}(y_2,y_1)$$

$$\Rightarrow p(x_1)p(y_1\mid x_1)\alpha_{x_1}(y_1,y_2)=p(x_1)p(y_2\mid x_1)\alpha_{x_1}(y_2,y_1)$$

$$\Rightarrow \alpha_{x_1}(y_1,y_2)=p(y_2\mid x_1)\ ,\ \alpha_{x_1}(y_2,y_1)=p(y_1\mid x_1)$$

$$\Rightarrow \alpha_{x_1}(y_{cur},y_{other})=p(y_{other}\mid x_1)\ ,\ \alpha_{x_1}(y_{other},y_{cur})=p(y_{cur}\mid x_1)$$

  - 若固定y，可得到对偶的结论。

二维Gibbs采样算法

- 由 $\begin{cases} \alpha_{x_1}(y_{cur}, y_{other}) = p(y_{other} \mid x_1) \\ \alpha_{y_1}(x_{cur}, x_{other}) = p(x_{other} \mid y_1) \end{cases}$
- 很容易得到二维Gibbs采样算法：
  - 随机初始化(X,Y)=(x_0,y_0)
  - 对t=0,1,2…，循环采样：

$$\begin{cases} y_{t+1} = p(y \mid x_t) \\ x_{t+1} = p(x \mid y_{t+1}) \end{cases}$$

将二维Gibbs采样推广到高维

- 随机初始化 $\left(X_1, X_2 \cdots X_n\right) = \left(x_1^{(0)}, x_2^{(0)} \cdots, x_n^{(0)}\right)$
- 对t=1,2…，循环采样直至收敛(burn-in)：

$$
\begin{cases}
x_1^{(t+1)} = p\left(x_1 \mid x_2^{(t)}, x_3^{(t)}, \cdots, x_n^{(t)}\right) \\
x_2^{(t+1)} = p\left(x_2 \mid x_1^{(t+1)}, x_3^{(t)}, \cdots, x_n^{(t)}\right) \\
\cdots \\
x_i^{(t+1)} = p\left(x_i \mid x_1^{(t+1)}, \cdots, x_{i-1}^{(t+1)}, x_{i+1}^{(t)}, \cdots, x_n^{(t)}\right) \\
\cdots \\
x_{n-1}^{(t+1)} = p\left(x_{n-1} \mid x_1^{(t+1)}, x_2^{(t+1)}, \cdots, x_{n-2}^{(t+1)}, x_n^{(t)}\right) \\
x_n^{(t+1)} = p\left(x_n \mid x_1^{(t+1)}, x_2^{(t+1)}, \cdots, x_{n-1}^{(t+1)}\right)
\end{cases}
$$

  - 很显然，主题模型LDA中采样更新即采取的以上策略。

用采样改造EM算法

Repeat until convergence {

(E-step) For each i, set

$$Q_i(z^{(i)}) := p(z^{(i)}|x^{(i)};\theta).$$

(M-step) Set

$$\theta := \arg\max_{\theta} \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)};\theta)}{Q_i(z^{(i)})}$$

}

用采样改造EM算法

- 在EM算法中，E-Step求出隐变量的条件概率，从而给出期望Q，M-Step将目标函数Q求极大值，期望Q为：

$$Q(\theta,\bar{\theta})=\int p(Z\mid X,\bar{\theta})\ln p(Z,X\mid\theta)dZ$$

- 显然，这仍然可以使用采样的方式近似得到：

$$Q(\theta,\bar{\theta})\approx\frac{1}{L}\sum_{i=1}^{L}\ln p(Z^{(l)},X\mid\theta)$$

  - 这种EM算法称为MC-EM算法(Monte Carlo EM)

- 极限情况：若MC-EM算法的期望Q的估计，仅采样一个样本，则称之为随机EM算法(stochastic EM algorithm)。

变分预备知识

- KL散度的两种形式

两个KL散度的区别

- KL(q||p)，又称为I-投影，信息投影(information projection)

$$KL(q \| p) = \sum_x q(x) log \frac{q(x)}{p(x)} = E_{q(x)}\left(log \frac{q(x)}{p(x)} \right)$$

  - 如果p(x)=0，q(x)>0，则KL为无穷大。因此，当p(x)=0时必须保证q(x)=0。即：该公式是对待求分布q“0强制”(zero forcing)的。从而，q往往被低估。

- KL(p||q)，又称为M-投影，矩投影(moment projection)

$$KL(p \| q) = \sum_x p(x) log \frac{p(x)}{q(x)} = E_{p(x)}\left(log \frac{p(x)}{q(x)} \right)$$

  - 如果p(x)>0，q(x)=0，则KL为无穷大。因此，当p(x)>0时必须保证q(x)>0。即：该公式是对待求分布q“0避免”(zero avoiding)的。从而，q往往被高估。

两个KL散度的区别

- 绿色曲线是真实分布p的等高线；红色曲线是使用近似$p(z_1,z_2)=p(z_1)p(z_2)$得到的等高线
  - 左：KL(p||q)：zero avoiding
  - 右：KL(q||p)：zero forcing

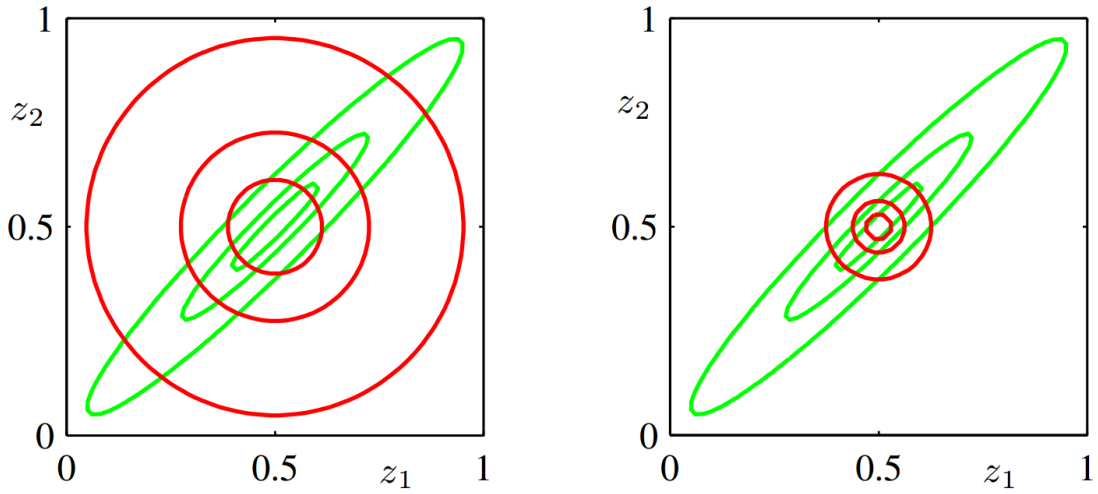

两个KL散度的区别

- 蓝色曲线是真实分布p的等高线；红色曲线是单模型近似分布q的等高线。
  - 左：KL(p||q)：q趋向于覆盖p
  - 中、右：KL(q||p)：q能够锁定某一个峰值

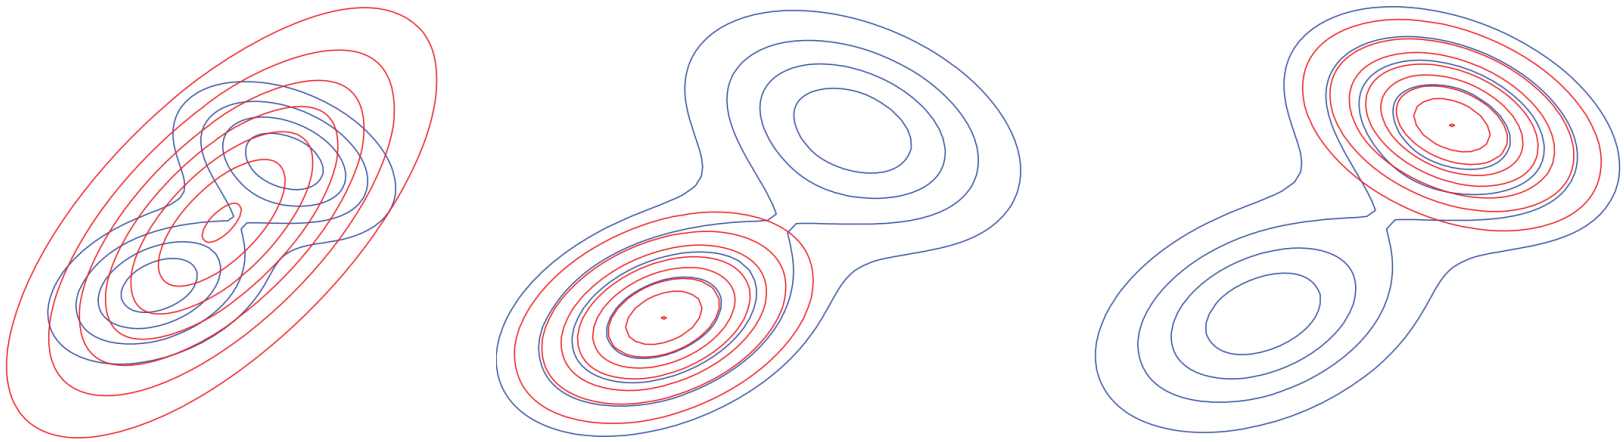

两个KL散度之间的联系

- 给定分布p和q的距离定义

$$D_\alpha(p\|q)=\frac{2}{1-\alpha^2}\left(1-\int p(x)^{\frac{1+\alpha}{2}}q(x)^{\frac{1-\alpha}{2}}dx\right)$$

- p和q的KL散度

$$KL(p\|q)=\int p(x)\log\frac{p(x)}{q(x)}dx=-\int p(x)\log\frac{q(x)}{p(x)}dx$$

- 变换：

$$-\int p(x)^{\frac{1+\alpha}{2}}q(x)^{\frac{1-\alpha}{2}}dx=-\int p(x)^{1+\frac{\alpha-1}{2}}q(x)^{\frac{1-\alpha}{2}}dx$$

$$=-\int p(x)p(x)^{\frac{\alpha-1}{2}}q(x)^{\frac{1-\alpha}{2}}dx=-\int p(x)\left(\frac{q(x)}{p(x)}\right)^{\frac{1-\alpha}{2}}dx$$

两个KL散度之间的联系

$$u=\frac{q(x)}{p(x)}\Rightarrow\begin{cases}f(u)=u^{\frac{1-\alpha}{2}}\\ g(u)=\log u\end{cases}\Rightarrow\begin{cases}f'(u)=\frac{1-\alpha}{2}u^{-\frac{1+\alpha}{2}}\\ g'(u)=u^{-1}\end{cases}\Rightarrow\begin{cases}\frac{1-\alpha}{2}=1\\ -\frac{1+\alpha}{2}=-1\end{cases}\Rightarrow\begin{cases}\alpha=-1\\ \alpha=1\end{cases}$$

- 当α=1时退化为KL(q||p)
- 当α=-1时退化为KL(q||p)
- 当α=0时？

Hellinger distance

$$D_\alpha(p\,\|\,q)=\frac{2}{1-\alpha^2}\left(1-\int p(x)^{\frac{1+\alpha}{2}}q(x)^{\frac{1-\alpha}{2}}dx\right)$$

$$\Rightarrow D_H(p\,\|\,q)=2\left(1-\int\sqrt{p(x)q(x)}dx\right)=2-2\int\sqrt{p(x)q(x)}dx$$

$$=\int p(x)dx+\int q(x)dx-\int 2\sqrt{p(x)q(x)}dx$$

$$=\int\left(p(x)-2\sqrt{p(x)q(x)}+q(x)\right)dx$$

$$=\int\left(\sqrt{p(x)}-\sqrt{q(x)}\right)^2dx$$

- 该距离满足三角不等式，是对称、非负距离

参考文献

- Christopher M. Bishop. *Pattern Recognition and Machine Learning Chapter 10.* Springer-Verlag, 2006
- https://www.zybuluo.com/Hederahelix/note/101859
- http://thexbar.me/2014/11/07/reject-sample/
- http://www.cnblogs.com/daniel-D/p/3388724.html

我们在这里

- 问题答疑：http://www.xxwenda.com/
  - 烦请邀请visio或其他人回答问题

- 本课程QQ群：
  - 471632108(小象学院：机器学习群)

感谢大家！

恳请大家批评指正！