法律声明

- 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，小象学院和主讲老师拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意及内容，我们保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：小象
  - 新浪微博：ChinaHadoop

变分

小象学院 ChinaHadoop.cn

邹博

主要内容

- 理解变分的算法框架
  - 和采样算法的区别和联系
- 使用变分做隐变量的估计
  - 将去噪后的图像当做“隐变量”
- 使用变分做未知参数的估计
  - 取系统的参数为某概率分布

变分的核心

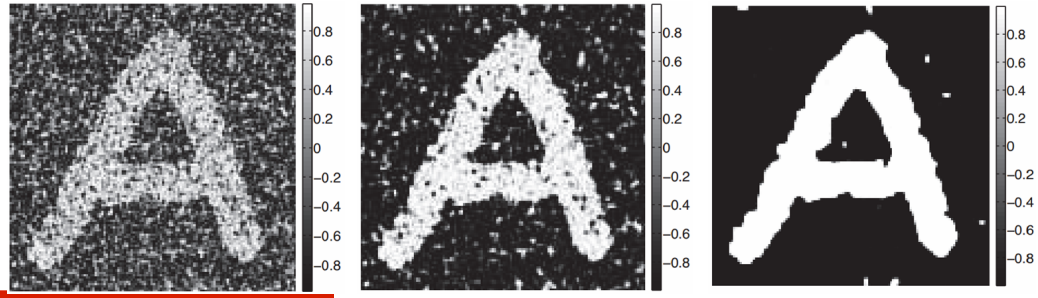

$$\log q_j(x_j) = E_{-q_j}\left[\log \tilde{p}(x)\right] + const$$

- 当更新q_j时，仅需要计算与x_j有公共边的那些变量即可——j的Markov毯包含的那些结点。
- Gibbs采样和变分：
  - Gibbs采样：使用邻居结点(同文中的词主题)的采样值；
  - 变分：采用相邻结点的均值。
  - 这将使得变分往往比采样算法的更高效：用一个均值代替了大量的采样值。直观上，均值的信息是高密(dense)的，而采样值的信息是稀疏(sparse)的。

思考：MC-EM的启示

- 采样算法改造EM算法：Monte Carlo EM

$$Q(\theta,\bar{\theta})=\int p(Z\mid X,\bar{\theta})\ln p(Z,X\mid\theta)dZ$$

$$Q(\theta,\bar{\theta})\approx\frac{1}{L}\sum_{i=1}^{L}\ln p(Z^{(l)},X\mid\theta)$$

- 可否用计算统计量的方式改造采样？

$$p(z_i=k\mid\vec{z}_{\neg i},\vec{w})\propto\frac{n_{k,\neg i}^{(t)}+\beta_t}{\sum_{t=1}^{V}n_{k,\neg i}^{(t)}+\beta_t}\left(n_{m,\neg i}^{(k)}+\alpha_k\right)$$

思考：根据函数形式判断概率分布

- 正态分布的概率密度函数

$$p(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- 对数正态分布

$$\ln p(x)=\ln\frac{1}{\sqrt{2\pi}}-\ln\sigma-\frac{(x-\mu)^2}{2\sigma^2}=\alpha\cdot x^2+\beta\cdot x+\gamma$$

- 该分布的对数是关于随机变量x的二次函数
  - 根据计算过程的可逆性，若某对数分布能够写成随机变量二次形式，则该分布必然是正态分布。

举例

- Gamma分布的定义

$$p(x;\alpha,\beta)=\frac{\beta^{\alpha}x^{\alpha-1}e^{-\beta x}}{\Gamma(\alpha)}\quad,\quad x\geq 0(\text{常系数}\alpha,\beta>0)$$

- 对数形式

$$\ln p(x;\alpha,\beta)=\alpha\ln\beta+(\alpha-1)\ln x-\beta x-\ln\Gamma(\alpha)=A\cdot x+B\cdot\ln x+C$$

  - 若某对数分布能够写成随机变量一次项和对数项的和，则该分布必然是Gamma分布。

- 注：
  - Gamma函数：$\Gamma(\alpha)=\int_0^{\infty}t^{\alpha-1}e^{-t}dt \qquad \Gamma(n)=(n-1)!$
  - Gamma分布的期望为：$E(X)=\frac{\alpha}{\beta}$

最大熵的理解 $0 \le H(X) \le \log|X|$

- 熵是随机变量不确定性的度量，不确定性越大，熵值越大；
  - 若随机变量退化成定值，熵最小：为0
  - 若随机分布为均匀分布，熵最大。
- 以上是无条件的最大熵分布，若有条件呢？
  - 最大熵模型
- 思考：若只给定期望和方差的前提下，最大熵的分布形式是什么？

给定期望和方差的分布率

- 建立目标函数

$$\arg\max_{p(x)} H(X) = -\sum_x p(x)\ln p(x) \qquad s.t.\begin{cases} E(X) = \mu \\ Var(X) = \sigma^2 \end{cases}$$

- 使用方差公式化简约束条件

$$Var(X) = E(X^2) - E^2(X)$$
$$\Rightarrow E(X^2) = E^2(X) + Var(X) = \mu^2 + \sigma^2$$

- 显然，此问题为带约束的极值问题。
  - Lagrange乘子法

建立Lagrange函数，求驻点

$$\arg\max_{p(x)} H(X) = -\sum_x p(x)\ln p(x) \quad s.t.\begin{cases} E(X) = \mu \\ E(X^2) = \mu^2 + \sigma^2 \end{cases}$$

$$L(p) = -\sum_x p(x)\ln p(x) + \lambda_1\left(E(X) - \mu\right) + \lambda_2\left(E(X^2) - \mu^2 - \sigma^2\right)$$

$$= -\sum_x p(x)\ln p(x) + \lambda_1\left(\sum_x xp(x) - \mu\right) + \lambda_2\left(\sum_x x^2 p(x) - \mu^2 - \sigma^2\right)$$

$$\Rightarrow \frac{\partial L}{\partial p} = -\ln p(x) - 1 + \lambda_1 x + \lambda_2 x^2 \overset{\Delta}{==} 0 \Rightarrow \ln p(x) = \lambda_2 x^2 + \lambda_1 x - 1$$

- P(x)的对数是关于随机变量x的二次形式，所以，该分布p(x)必然是**正态分布**！

正态分布的最大熵属性

- 实践中往往只依赖数据的前两阶矩(期望、方差)来估计分布，希望在做尽量少的假定的前提下获得满足这些属性的分布。

参数估计总结

- 给定样本$X_1,X_2\ldots X_n$，求系统参数θ
  - 极大似然估计：Maximum Likelihood Estimate

$$P(\theta \mid X)=\prod_i P(\theta \mid x_i)$$

  - 极大后验概率：Maximum A Posteriori

$$P(\theta \mid X)=\frac{P(X \mid \theta)P(\theta)}{P(X)} \propto P(X \mid \theta)P(\theta)=\prod_i P(x_i \mid \theta)P(\theta)$$

- 若存在隐变量：
  - EM算法——衍生品：随机EM、MAP-EM、IP算法
    - GMM、pLSA、HMM、CRF
  - 采样：MCMC、Gibbs

另一个思路

- 变分推导(variational inference)是一般的确定性的近似推导算法。
- 基本思想：选择一个容易计算的近似分布 $q(x)$，它能够尽可能的接近真正的后验分布 $p(x|D)$。
  - 通过降低约束条件，在精度和速度上折中。
- 问题：如何定义两个分布的相似度？

变分的提法

- 假定p*(x)是真实(难解的)分布，q(x)是某个近似的(容易的)分布——如多元高斯分布或者多个简单分布的乘积。
- 假定q(x)有若干自由参数需要估计，我们需要优化这些未知参数使得q近似于p*。
- 一个显然的损失函数是最小化KL散度

$$KL(p^* \| q) = \sum_x p^*(x) log \frac{p^*(x)}{q(x)} = E_{p^*(x)}\left(log \frac{p^*(x)}{q(x)} \right)$$

变分目标函数分析

$$KL(p^* \| q) = \sum_x p^*(x) log \frac{p^*(x)}{q(x)} = E_{p^*(x)}\left(log \frac{p^*(x)}{q(x)} \right)$$

- 上式关于后验概率p*的期望是不容易计算的，作为替代，将上述KL散度变成“逆KL散度”(reverse KL divergence)

$$KL(q \| p^*) = \sum_x q(x) log \frac{q(x)}{p^*(x)} = E_{q(x)}\left(log \frac{q(x)}{p^*(x)} \right)$$

- 第二个式子的主要优点是转换为计算关于q的期望(而q是关于未知参数的简单分布)；进一步，由于p(D)是归一化因子

$$p^*(x) = p(x|D) = \frac{p(x,D)}{p(D)} \overset{\Delta}{==} \frac{\tilde{p}(x)}{Z} \Rightarrow \tilde{p}(x) = Z \cdot p^*(x)$$

- 上式变成：$J(q) = KL(q \| \tilde{p}) = \sum_x q(x) log \frac{q(x)}{\tilde{p}(x)}$

新目标函数的可行性 $J(q)=KL(q\|\tilde{p})$

$$J(q)=KL(q\|\tilde{p})=\sum_x q(x)log\frac{q(x)}{\tilde{p}(x)}$$

$$=\sum_x q(x)log\frac{q(x)}{Z\cdot p^*(x)}$$

$$=\sum_x q(x)log\frac{q(x)}{p^*(x)}+\sum_x q(x)log\frac{1}{Z}$$

$$=\sum_x q(x)log\frac{q(x)}{p^*(x)}-logZ$$

$$=KL(q\|p^*(x))-logZ$$

- 由于Z是常数，通过最小化J(q)，能够使得q接近p*。

变分和EM的联系

- 因为KL散度总是非负的，J(p)是NLL的上界
  - negative log likelihood

$$J(q) = KL(q \| p^*) - \log Z \geq -\log Z = -\log p(D)$$

  - 进一步：

$$L(q) \overset{\Delta}{==} -J(q) = -KL(q \| p^*) + \log Z \leq \log Z = \log p(D)$$

- 因此，L(q)是似然函数的下界，当q=p*时取等号。
  - 可取等号，说明下界是紧的(tight)
- EM和变分
  - EM算法：计算关于隐变量后验概率的期望，得到下界；
  - 变分：计算KL散度，得到下界；
  - 相同的思维：不断迭代，得到更好的下界。
  - 不断上升。

思考：目标函数的物理含义

- 定义能量 $E(x) = -\log \tilde{p}(x)$
- 目标函数是能量的期望减去系统的熵。J(q)被叫做“变分自由能”或“Helmholtz free energy”。

$$J(q) = KL(q \parallel \tilde{p}) = \sum_x q(x) \log \frac{q(x)}{\tilde{p}(x)}$$

$$= E_q\left(\log \frac{q(x)}{\tilde{p}(x)}\right) = E_q\left(\log q(x) - \log \tilde{p}(x)\right)$$

$$= E_q\left(\log q(x)\right) + E_q\left(-\log \tilde{p}(x)\right)$$

$$\overset{\triangle}{=\!=} -H(X) + E_q\left(E(x)\right)$$

思考：似然函数期望与目标函数

- 负似然函数NLL的期望，加上一个惩罚项——近似分布与先验分布的KL距离。

$$J(q)=KL(q\,\|\,\tilde{p})=\sum_x q(x)\log\frac{q(x)}{\tilde{p}(x)}=E_q\left(\log\frac{q(x)}{\tilde{p}(x)}\right)$$

$$=E_q\left(\log\frac{q(x)}{p(x,D)}\right)=E_q\left(\log\frac{q(x)}{p(x)p(D\,|\,x)}\right)$$

$$=E_q\left(\log\frac{1}{p(D\,|\,x)}+\log\frac{q(x)}{p(x)}\right)=E_q\left(\log\frac{1}{p(D\,|\,x)}\right)+E_q\left(\log\frac{q(x)}{p(x)}\right)$$

$$=E_q\left(-\log p(D\,|\,x)\right)+KL(q\,\|\,p)$$

平均场方法(Mean field method)

- 最流行的变分方法之一是平均场近似。在这种方法中，假定后验概率能够近似分解为若干因子的乘积。
  - 思考：无向图中的“最大团” Hammersley-Clifford定理

$$q(x)=\prod_i q_i(x_i)$$

- 我们的目标是解决最优化问题：$\min_{q_1,\cdots q_D} KL(q \| p)$
- 平均场方法使得可以在若干边界分布q_i上进行(依次)优化。事实上，很快将得知，有如下近似等式：

$$\log q_j(x_j)=E_{-q_j}\left[\log \tilde{p}(x)\right]+const$$

- 其中，未正则化的后验概率 $\tilde{p}(x)=p(x,D)$
- 关于除了x_j的所有其他变量的f(x)的期望 $E_{-q_j}\left[f(x)\right]$

平均场方法(Mean field method)

$$\log q_j(x_j) = E_{-q_j}\left[\log \tilde{p}(x)\right] + const$$

- 当更新q_j时，仅需要计算与x_j有公共边的那些变量即可——j的Markov毯包含的那些结点。因为该方法使用相邻结点的期望(均值)，所以称作平均场。
- 思考Gibbs采样和变分：
  - Gibbs采样：使用邻居结点(同文中的词主题)的采样值；
  - 变分：采用相邻结点的均值。
  - 这将使得变分往往比采样算法的更高效：用一个均值代替了大量的采样值。直观上，均值的信息是高密(dense)的，而采样值的信息是稀疏(sparse)的。

变分推导/似然下界L

$$J(q)=KL(q\,\|\,\tilde{p})=\sum_x q(x)\log\frac{q(x)}{\tilde{p}(x)}$$

$$L(q_j)\overset{\Delta}{==}-J(q_j)=-\sum_x q(x)\log\frac{q(x)}{\tilde{p}(x)}$$

$$=\sum_x q(x)\left[\log\tilde{p}(x)-\log q(x)\right]$$

$$=\sum_x\prod_i q_i(x_i)\left[\log\tilde{p}(x)-\log\prod_i q_i(x_i)\right]$$

$$=\sum_{x_j}\sum_{x_{-j}} q_j(x_j)\prod_{i\neq j} q_i(x_i)\left[\log\tilde{p}(x)-\sum_k\log q_k(x_k)\right]$$

$$=\sum_{x_j} q_j(x_j)\sum_{x_{-j}}\prod_{i\neq j} q_i(x_i)\left[\log\tilde{p}(x)-\left(\log q_j(x_j)+\sum_{k\neq j}\log q_k(x_k)\right)\right]$$

$$=\left(\sum_{x_j} q_j(x_j)\sum_{x_{-j}}\prod_{i\neq j} q_i(x_i)\log\tilde{p}(x)\right)-\left(\sum_{x_j} q_j(x_j)\log q_j(x_j)\right)+const$$

$$=\left(\sum_{x_j} q_j(x_j)\log f_j(x_j)\right)-\left(\sum_{x_j} q_j(x_j)\log q_j(x_j)\right)+const=-KL(q_j\,\|\,f_j)$$

$$\log f_j(x_j)\overset{\Delta}{==}\sum_{x_{-j}}\prod_{i\neq j} q_i(x_i)\log\tilde{p}(x)=E_{-q_j}\left[\log\tilde{p}(x)\right]$$

变分推导最终结论

- 下界 $L(q_j) = -KL(q_j \| f_j)$ 取极大，则 $KL(q_j \| f_j)$ 取极小，此刻，要求二者分布相同。
- 由于 $\log f_j(x_j) \overset{\triangle}{==} \sum_{x_{-j}} \prod_{i \neq j} q_i(x_i) \log \tilde{p}(x) = E_{-q_j}[\log \tilde{p}(x)]$
- 所以

$$q_j(x_j) = f_j(x_j) = \frac{1}{Z_j} \exp\left(E_{-q_j}[\log \tilde{p}(x)]\right)$$

- 忽略归一化因子

$$\log q_j(x_j) = E_{-q_j}[\log \tilde{p}(x)] + const$$

Ising model

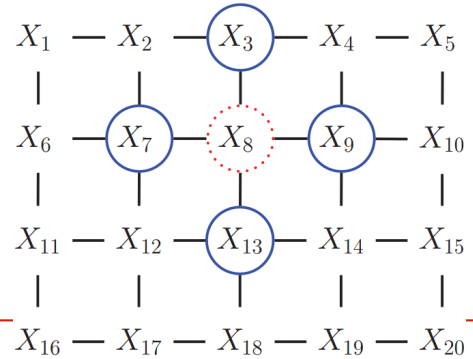

- Ising模型是统计物理提出的马尔科夫随机场MRF，它最初是用来对磁化行为建模。令$y_s \in \{-1,+1\}$表示原子的自旋，它的旋转角速度方向要么朝上，要么朝下。在某些环境下，表现为铁磁现象(ferro-magnets)：相邻结点的自旋方向趋近于同向；而其他环境中表现为反铁磁现象(anti-ferromagnets)，相邻结点的自旋方向趋近于相反。
- 可以使用MRF建模：连接相邻变量，然后定义团(clique)之间的势函数：

$$\varphi_{st}(y_s, y_t) = \begin{pmatrix} e^{w_{st}} & e^{-w_{st}} \\ e^{-w_{st}} & e^{w_{st}} \end{pmatrix}$$

势函数的系数 $\varphi_{st}(y_s, y_t) = \begin{pmatrix} e^{w_{st}} & e^{-w_{st}} \\ e^{-w_{st}} & e^{w_{st}} \end{pmatrix}$

- w_{st}是结点s和t之间的**耦合强度**(coupling strength)。如果两个结点没有连接，则设置$w_{st}=0$。假定权值矩阵W是对称阵，即$w_{st}=w_{ts}$；进一步假定所有的边有相同的强度，即$w_{st}=J\neq 0$。
- 如果所有的权值都为正(J>0)，则相邻结点的自旋趋向于同向，能够对**铁磁现象**建模：如果权值足够强，则结点的概率分布将只有两种状态：一部分结点是1状态，一部分结点是-1状态，这被称作系统的**基态**(groud states)。
  - 类比：将某状态认为是实际观测的图像，基态认为是去噪后的“干净”的图像。
- 同理，如果J<0可以对**反铁磁现象**建模。

使用变分做图像去噪

- 考虑图像的去噪问题：$x_i \in \{-1,+1\}$是隐藏在观测图像背后的“干净”图像的像素取值。为简洁方便，假定是二值图。x的联合分布假定具有如下先验形式：

$$p(x)=\frac{1}{Z_0}\exp(-E_0(x)), \qquad \text{其中}, E_0(x)=-\sum_{i=1}^{D}\sum_{j\in nbr_i}W_{ij}x_i x_j$$

- 似然函数 $p(y\mid x)=\prod_i p(y_i\mid x_i)=\prod_i\left(\exp(\ln p(y_i\mid x_i))\right)$

$$=\exp\sum_i \ln p(y_i\mid x_i)=\exp\sum_i\left(L_i(x_i)\right)$$

后验概率

- 后验概率 $$p(x \mid y) = \frac{p(y \mid x)p(x)}{p(y)} \propto p(y \mid x)p(x)$$

$$\propto \left(\exp \sum_i (L_i(x_i))\right)(\exp(-E_0(x)))$$

$$= \exp\left(-E_0(x) + \sum_i L_i(x_i)\right)$$

$$\Rightarrow p(x \mid y) = \frac{1}{Z}\exp(-E(x))$$

- 其中， $$E(x) = E_0(x) - \sum_i L_i(x_i)$$

近似概率

- 根据后验概率 $p(x|y)=\frac{1}{Z}\exp(-E(x))=\frac{1}{Z}\exp\left(-E_0(x)+\sum_i L_i(x_i)\right)$
- 得到经验概率的对数：

$$\ln\tilde{p}(x)=-E_0(x)+\sum_i L_i(x_i)=\sum_{i=1}^{D}\sum_{j\in nbr_i}W_{ij}x_ix_j+\sum_i L_i(x_i)$$

- 只考虑与i相关的部分 $\ln\tilde{p}(x)=x_i\sum_{j\in nbr_i}W_{ij}x_j+L_i(x_i)+const$
- 即结点i的均值为μ_i，利用变分结论

$$\log q_i(x_i)\propto\sum_{x_{-i}}\prod_{j\neq i}q_j(x_j)\log\tilde{p}(x)=E_{-q_i}[\log\tilde{p}(x)]$$

- 得：

$$q_i(x_i)\propto\sum_{x_{-i}}\prod_{j\neq i}q_j(x_j)\cdot\left(x_i\sum_{j\in nbr_i}W_{ij}x_j+L_i(x_i)\right)=\exp\left(x_i\sum_{j\in nbr_i}W_{ij}\mu_j+L_i(x_i)\right)$$

根据公式：

- 记平均场对结点i的影响为：$m_i = \sum_{j \in nbr_i} W_{ij}\mu_j$

$$q_i(x_i) \propto \exp\left(x_i \sum_{j \in nbr_i} W_{ij}\mu_j + L_i(x_i) \right) = \exp\left(x_i \cdot m_i + L_i(x_i)\right)$$

- 进一步，记：$L_i^+ = L_i(+1),\ L_i^- = L_i(-1)$
- 则近似边缘后验概率为：

$$\begin{cases} q_i(x_i = 1) = \dfrac{e^{m_i + L_i^+}}{e^{m_i + L_i^+} + e^{-m_i + L_i^-}} = \dfrac{1}{1 + e^{-2m_i + L_i^- - L_i^+}} = sigmiod(2a_i) \\ q_i(x_i = -1) = sigm(-2a_i) \quad \text{其中，} a_i = m_i + \dfrac{L_i^+ - L_i^-}{2} \end{cases}$$

更新方程

- 结点i迭代后的期望为：

$$\mu_i = E_{q_i}(x_i) = q_i(x_i = +1)\cdot(+1) + q_i(x_i = -1)\cdot(-1)$$

$$= \frac{1}{1+e^{-2a_i}} - \frac{1}{1+e^{2a_i}} = \frac{e^{a_i}}{e^{a_i}+e^{-a_i}} - \frac{e^{-a_i}}{e^{-a_i}+e^{a_i}} = \tanh(a_i)$$

- 因此，更新方程为：

$$\mu_i = \tanh\left(\sum_{j\in nbr_i} W_{ij}\mu_j + \frac{L_i^+ - L_i^-}{2}\right)$$

迭代方程

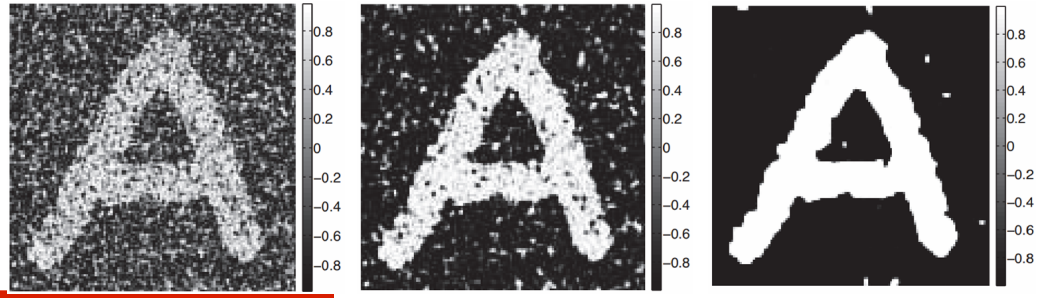

- 根据上式很容易得到迭代公式：

$$\mu_i^{(t)} = \tanh\left(\sum_{j\in nbr_i} W_{ij}\mu_i^{(t-1)} + \frac{L_i^+ - L_i^-}{2}\right)$$

- 实践中，往往需要增加衰减因子，得
  - damped updates：1>λ>0

$$\mu_i^{(t)} = (1-\lambda)\mu_i^{(t-1)} + \lambda\tanh\left(\sum_{j\in nbr_i} W_{ij}\mu_i^{(t-1)} + \frac{L_i^+ - L_i^-}{2}\right)$$

实际效果

- 2维Ising模型：(混入 $\sigma = 2$ 的高斯噪声)
  - 先验权值 $W_{ij} = 1$，衰减因子 $\lambda = 0.5$
  - 左：迭代1次；中：迭代3次；右：迭代15次。

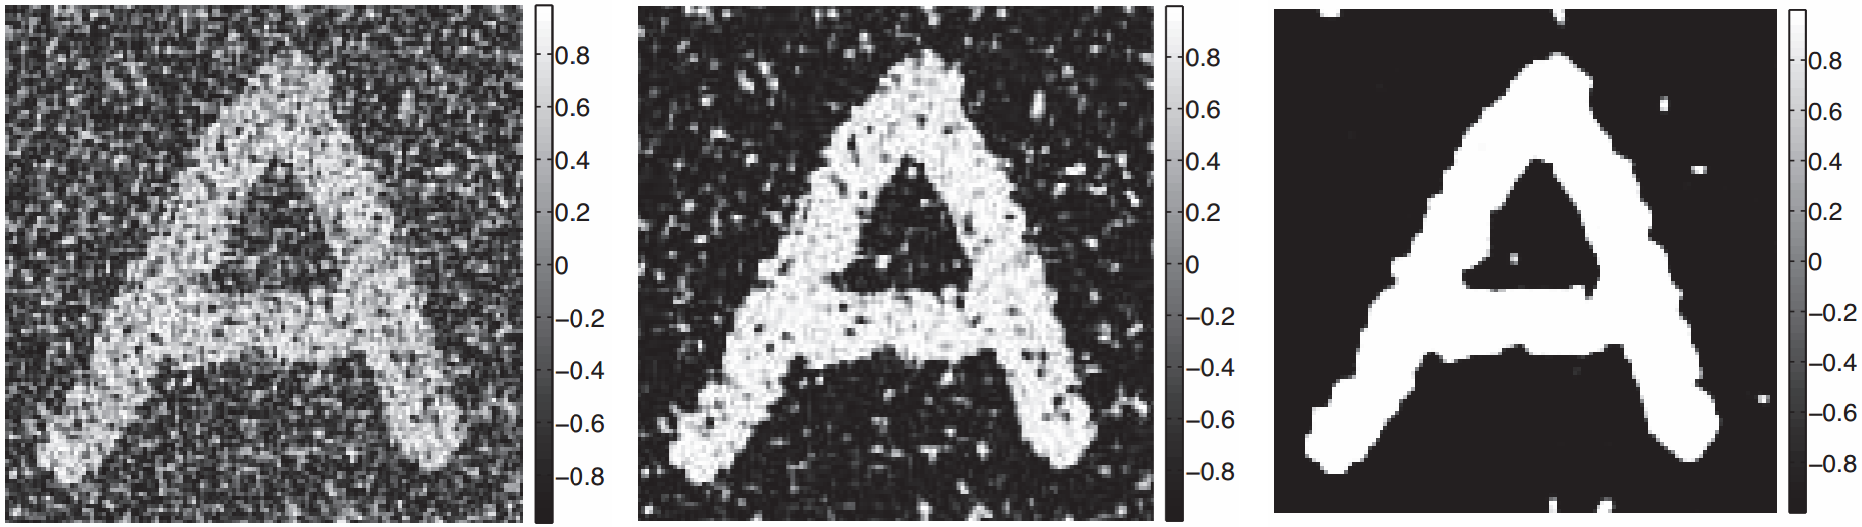

变分贝叶斯(Variational Bayes,VB)

- 上述变分实践是计算给定模型参数，推断隐变量。此外，变分方法也可以推断参数本身。使用平均场方法，将后验概率写成参数各自分布的乘积，即得到变分贝叶斯方法(Variational Bayes, VB)。
- 变分贝叶斯：$p(\theta \mid D) \approx \prod_k q_k(\theta_k)$

高斯分布的变分贝叶斯Variational Bayes

- 使用变分贝叶斯推断一维高斯分布$p(\mu,\lambda^{-1}|D)$后验概率的参数。其中，λ为精度(方差的倒数)。为计算方便，使用共轭先验的形式。

$$p(\mu,\lambda)=N\left(\mu|\mu_0,(\kappa_0\lambda)^{-1}\right)\cdot Ga(\lambda|a_0,b_0)$$

- 近似分解得到如下形式：

$$q(\mu,\lambda)=q_\mu(\mu)q_\lambda(\lambda)$$

未正则化的对数后验

$$\begin{cases} p(D\mid\mu,\lambda)=\sqrt{\dfrac{\lambda}{2\pi}}\cdot e^{-\frac{\lambda(x-\mu)^2}{2}} \\ p\left(\mu\mid\mu_0,(\kappa_0\lambda)^{-1}\right)=\sqrt{\dfrac{\kappa_0\lambda}{2\pi}}\cdot e^{-\frac{\kappa_0\lambda(\mu-\mu_0)^2}{2}} \\ p(\lambda\mid a_0,b_0)=\dfrac{\beta^{a_0}}{\Gamma(a_0)}\cdot\lambda^{a_0-1}e^{-b_0\lambda} \end{cases}$$

- 目标函数

$$\begin{aligned}
&\log\tilde{p}(\mu,\lambda) \\
&=\log p(\mu,\lambda,D) \\
&=\log p(D\mid\mu,\lambda)+\log p(\mu\mid\lambda)+\log p(\lambda) \\
&=\log\prod_{i=1}^{N}\sqrt{\frac{\lambda}{2\pi}}\cdot e^{-\frac{\lambda(x_i-\mu)^2}{2}}+\log\sqrt{\frac{\kappa_0\lambda}{2\pi}}\cdot e^{-\frac{\kappa_0\lambda(\mu-\mu_0)^2}{2}}+\log\frac{\beta^{a_0}\lambda^{a_0-1}e^{-b_0\lambda}}{\Gamma(a_0)} \\
&=\frac{N}{2}\log\lambda-\frac{\lambda}{2}\sum_{i=1}^{N}(x_i-\mu)^2+\frac{1}{2}\log(\kappa_0\lambda)-\frac{\kappa_0\lambda}{2}(\mu-\mu_0)^2 \\
&+(a_0-1)\log\lambda-b_0\lambda+const
\end{aligned}$$

更新 $q_\mu(\mu)$

- 最优形式的 $q_\mu(\mu)$ 是通过计算关于λ的平均值获得的：

$$\log \tilde{p}(\mu,\lambda)=\frac{N}{2}\log\lambda-\frac{\lambda}{2}\sum_{i=1}^{N}(x_i-\mu)^2+\frac{1}{2}\log(\kappa_0\lambda)-\frac{\kappa_0\lambda}{2}(\mu-\mu_0)^2+(a_0-1)\log\lambda-b_0\lambda+const$$

$$\begin{aligned}\log q_\mu(\mu)&=E_{q_\lambda}\left(\log\tilde{p}(\mu,\lambda)\right)\\&=E_{q_\lambda}\left(-\frac{\lambda}{2}\sum_{i=1}^{N}(x_i-\mu)^2-\frac{\kappa_0\lambda}{2}(\mu-\mu_0)^2\right)+const\\&=-\frac{E_{q_\lambda}(\lambda)}{2}\left(\sum_{i=1}^{N}(x_i-\mu)^2+\kappa_0(\mu-\mu_0)^2\right)+const\end{aligned}$$

由$q_\mu(\mu)$ 得到的参数等式

- 对比正态分布的对数形式：

$$\ln p(x) = \ln\frac{1}{\sqrt{2\pi}} - \ln\sigma - \frac{(x-\mu)^2}{2\sigma^2}$$

$$\log q_\mu(\mu) = -\frac{E_{q_\lambda}(\lambda)}{2}\left(\sum_{i=1}^{N}(x_i-\mu)^2 + \kappa_0(\mu-\mu_0)^2\right) + const$$

- 得，

$$\begin{cases}\mu_N = \dfrac{\kappa_0\mu_0 + N\overline{x}}{\kappa_0 + N} \\ \kappa_N = (\kappa_0 + N)E_{q_\lambda}(\lambda)\end{cases} \qquad \begin{cases}E_{q(\mu)}(\mu) = \mu_N \\ E_{q(\mu)}(\mu^2) = \dfrac{1}{\kappa_N} + \mu_N^2\end{cases}$$

  - 目前尚未知 $q_\lambda(\lambda)$，因此无法计算 $E_{q_\lambda}(\lambda)$，继续考察 $q_\lambda(\lambda)$。

更新 $q_\lambda(\lambda)$

- 最优形式的$q_\lambda(\lambda)$是通过计算关于μ的平均值获得的：

$$\log \tilde{p}(\mu,\lambda)=\frac{N}{2}\log\lambda-\frac{\lambda}{2}\sum_{i=1}^{N}(x_i-\mu)^2+\frac{1}{2}\log(\kappa_0\lambda)-\frac{\kappa_0\lambda}{2}(\mu-\mu_0)^2+(a_0-1)\log\lambda-b_0\lambda+const$$

$$\log q_\lambda(\lambda)=E_{q_\mu}(\log\tilde{p}(\mu,\lambda))$$

$$=E_{q_u}\left(\frac{N}{2}\log\lambda-\frac{\lambda}{2}\sum_{i=1}^{N}(x_i-\mu)^2+\frac{1}{2}\log(\kappa_0\lambda)-\frac{\kappa_0\lambda}{2}(\mu-\mu_0)^2+(a_0-1)\log\lambda-b_0\lambda\right)+const$$

$$=\frac{N}{2}\log\lambda+\frac{1}{2}\log\lambda+(a_0-1)\log\lambda-b_0\lambda-\frac{\lambda}{2}E_{q_u}\left(\kappa_0(\mu-\mu_0)^2+\sum_{i=1}^{N}(x_i-\mu)^2\right)+const$$

由$q_\lambda(\lambda)$ 得到的参数等式

- 对比正态分布的对数形式

$$\ln p(x;\alpha,\beta)=\alpha\ln\beta+(\alpha-1)\ln x-\beta x-\ln\Gamma(\alpha)$$

$$\log q_\lambda(\lambda)=\frac{N}{2}\log\lambda+\frac{1}{2}\log\lambda+(a_0-1)\log\lambda-b_0\lambda-\frac{\lambda}{2}E_{q_u}\left(\kappa_0(\mu-\mu_0)^2+\sum_{i=1}^{N}(x_i-\mu)^2\right)+const$$

- 得，

$$\begin{cases} a_N=a_0+\dfrac{N+1}{2} \\ b_N=b_0+\dfrac{1}{2}E_{q_u}\left(\kappa_0(\mu-\mu_0)^2+\sum_{i=1}^{N}(x_i-\mu)^2\right) \\ =b_0+\kappa_0\left(E(\mu^2)+\mu_0^2-2E(\mu)\mu_0\right)+\dfrac{1}{2}\sum_{i=1}^{N}\left(x_i^2+E(\mu^2)-2E(\mu)x_i\right) \end{cases}$$

- 同时：$E_{q(\lambda)}(\lambda)=\dfrac{a_N}{b_N}$

迭代公式

- 根据

$$\begin{cases} \mu_N = \dfrac{\kappa_0\mu_0 + N\cdot\bar{x}}{\kappa_0 + N} \\ \kappa_N = (\kappa_0 + N)E_{q_\lambda}(\lambda) \end{cases} \qquad \begin{cases} a_N = a_0 + \dfrac{N+1}{2} \\ b_N = b_0 + \kappa_0\left(E(\mu^2) + \mu_0^2 - 2E(\mu)\mu_0\right) + \dfrac{1}{2}\sum_{i=1}^{N}\left(x_i^2 + E(\mu^2) - 2E(\mu)x_i\right) \end{cases}$$

- 以及

$$\begin{cases} E_{q(\mu)}(\mu) = \mu_N \\ E_{q(\mu)}(\mu^2) = \dfrac{1}{\kappa_N} + \mu_N^2 \end{cases} \qquad E_{q(\lambda)}(\lambda) = \frac{a_N}{b_N}$$

- 得：

$$\begin{cases} \mu_N = \dfrac{\kappa_0\mu_0 + N\cdot\bar{x}}{\kappa_0 + N} \\ \kappa_N = (\kappa_0 + N)\dfrac{a_N}{b_N} \end{cases}$$

变分参数估计实例

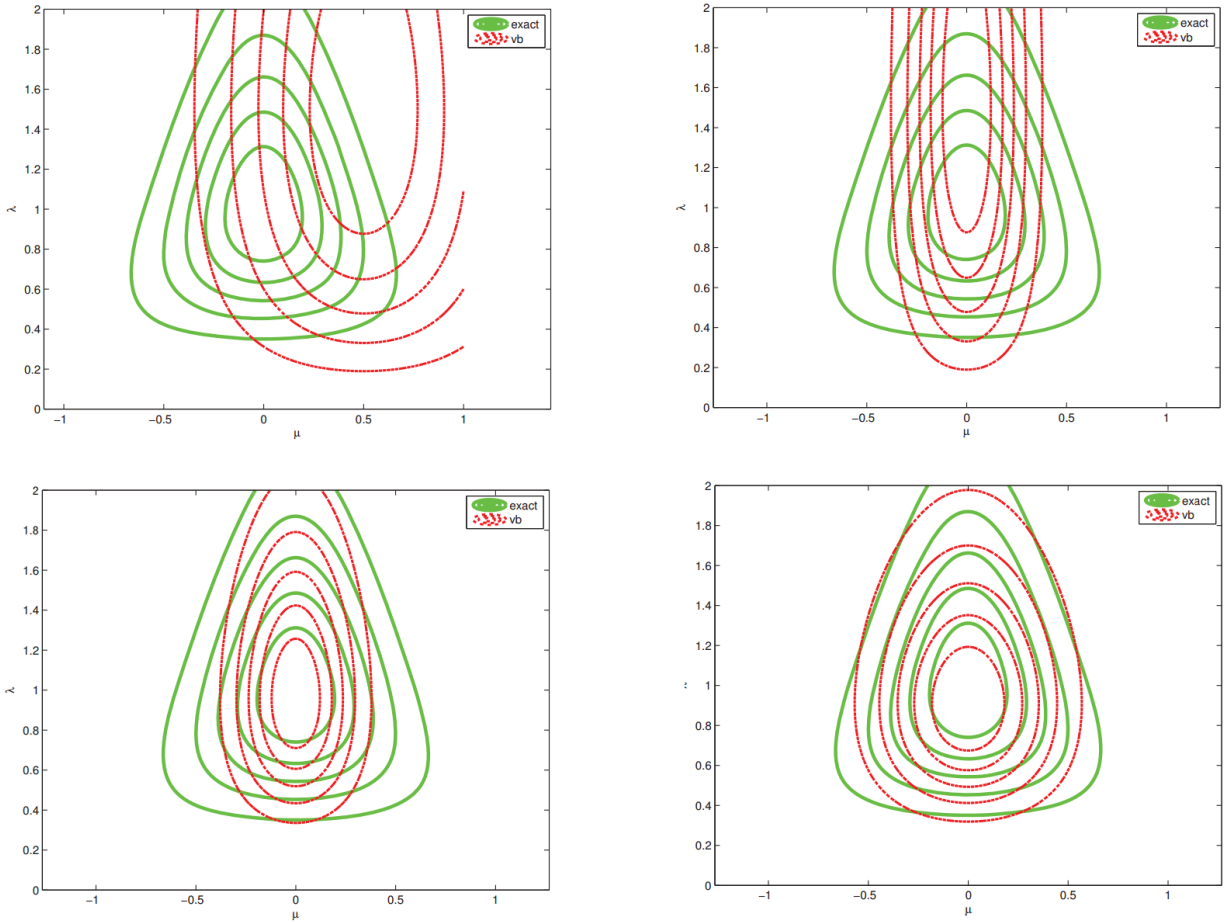

初始状态	更新$q_\mu(\mu)$
更新$q_\lambda(\lambda)$	5次迭代后

变分总结

- 变分既能够推断隐变量，也能推断未知参数，是非常有力的参数学习工具。其难点在于公式演算略复杂，和采样相对：一个容易计算但速度慢，一个不容易计算但运行效率高。
- 平均场方法的变分推导，对离散和连续的隐变量都适用。在平均场方法的框架下，变分推导一次更新一个分布，其本质为坐标上升。可以使用模式搜索(pattern search)、基于参数的扩展(parameter expansion)等方案加速。
  - 思考：EM的梯度上升理解。
- 有时假定所有变量都独立不符合实际，可使用结构化平均场(structured mean field)，将变量分成若干组，每组之间独立。
- 变分除了能够和贝叶斯理论相配合得到VB，还能进一步与EM算法结合，得到VBEM，用于带隐变量和未知参数的推断。
  - 如GMM、LDA

参考文献

- Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective, Chapter 21*. MIT Press, 2012
- Christopher M. Bishop. *Pattern Recognition and Machine Learning Chapter 10.* Springer-Verlag, 2006

我们在这里

- 问题答疑：http://www.xxwenda.com/
  - 烦请邀请visio或其他人回答问题

- 本课程QQ群：
  - 471632108(小象学院：机器学习群)

感谢大家！

恳请大家批评指正！