法律声明

- 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，小象学院和主讲老师拥有完全知识产权的权利；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意及内容，我们保留一切通过法律手段追究违反者的权利。

- 课程详情请咨询
  - 微信公众号：小象
  - 新浪微博：ChinaHadoop

HMM与中文分词

小象学院 ChinaHadoop.cn

邹博

主要内容

- 隐马尔科夫模型三个问题：
  - 概率计算：前向后向算法
  - 参数估计：Baum-Welch算法
  - 模型预测：Viterbi算法
- 中文分词算法实践

中文分词

```
if __name__ == "__main__":
    pi, A, B = load_train()
    f = file(".\\text\\novel.txt")
    data = f.read()[3:].decode('utf-8')
    f.close()
    decode = viterbi(pi, A, B, data)
    segment(data, decode)
```

bug HMM

Console | Frames | Variables | Watches

```
Connected to pydev debugger (build 139.1001)
我 | 与 | 地坛 |
史 | 铁生 |
一 |
我 | 在 | 好 | 几 | 篇 | 小说 | 中 | 都 | 提到 | 过 | 一 | 座 | 废弃 | 的 | 古园 | ， | 实际 | 就 | 是 | 地坛 | 。 | 许多 | 年前 | 旅游业 | 还 | 没有 | 开
地坛 | 离 | 我家 | 很 | 近 | 。 | 或者 | 说 | 我家 | 离 | 地坛 | 很 | 近 | 。 | 总之 | ， | 只好 | 认为 | 这 | 是 | 缘分 | 。 | 地坛 | 在 | 我出 | 生前 |
它 | 等待 | 我 | 出生 | ， | 然后 | 又 | 等待 | 我活 | 到 | 最狂 | 妄 | 的 | 年龄 | 上 | 忽地 | 残废 | 了 | 双腿 | 。 | 四百 | 多 | 年里 | ， | 它 | 一面
自 | 从 | 那个 | 下午 | 我 | 无意 | 中进 | 了 | 这 | 园子 | ， | 就 | 再 | 没长 | 久 | 地离 | 开过 | 它 | 。 | 我 | 一 | 下子 | 就 | 理解 | 了 | 它 | 的 |
两 | 条 | 腿 | 残废 | 后 | 的 | 最初 | 几年 | ， | 我找 | 不 | 到 | 工作 | ， | 找 | 不到 | 去路 | ， | 忽然 | 间 | 几乎 | 什么 | 都 | 找 | 不到 | 了 | ，
除 | 去 | 几 | 座 | 殿堂 | 我 | 无法 | 进去 | ， | 除去 | 那 | 座 | 祭坛 | 我 | 不 | 能 | 上去 | 而 | 只能 | 从 | 各个 | 角度 | 张望 | 它 | ， | 地坛 | 的
剩 | 下 | 的 | 就 | 是 | 怎样活 | 的 | 问题 | 了 | ， | 这 | 却 | 不 | 是 | 在 | 某 | 一个 | 瞬间 | 就 | 能 | 完全 | 想透 | 的 | 、 | 不 | 是 | 一次性 | 能
二 |
我 | 才 | 想到 | ， | 当年 | 我 | 总是 | 独自 | 跑 | 到 | 地坛 | 去 | ， | 曾 | 经给 | 母亲 | 出 | 了 | 一个 | 怎样 | 的 | 难题 | 。 |
她 | 不 | 是 | 那种 | 光会 | 疼爱 | 儿子 | 而 | 不 | 懂得 | 理解 | 儿子 | 的 | 母亲 | 。
有 | 一 | 回 | 我摇 | 车出 | 了 | 小院 | ； | 想 | 起 | 一件 | 什么 | 事 | 又 | 返身 | 回
有 | 一次 | 与 | 一个 | 作家 | 朋友 | 聊天 | ， | 我问 | 他学 | 写作 | 的 | 最 | 初动 |
在 | 我 | 的 | 头 | 一 | 篇 | 小 | 说 | 发表 | 的 | 时候 | ， | 在 | 我 | 的 | 小 | 说 |
只 | 是 | 到 | 了 | 这 | 时候 | ， | 纷纭 | 的 | 往事 | 才 | 在 | 我 | 眼前 | 幻现 | 得
摇 | 着 | 轮椅 | 在 | 园中 | 慢慢 | 走 | ， | 又 | 是 | 雾霭 | 的 | 清晨 | ， | 又 | 是
曾 | 有 | 过好 | 多 | 回 | ， | 我 | 在 | 这园 | 子里 | 呆得 | 太久 | 了 | ， | 母亲 | 就
```

前言 |
数据 | ， | 数据 | ， | 数据 | ！ | 想 | 必在
等 | 媒介 | 的 | 持续 | 冲击 | 下 | ， | 人们
的 | 洗礼 | 。 | 现实 | 需求 | 推动 | 了 | 对
这些 | 数据 | 来 | 自于 | 社交 | 媒体 | 、 |
“ | 物联网 | ” | ） | 、 | 传感器 | 等 | 任何
大 | 多 | 数数 | 据 | 挖掘 | 的 | 宣传 | 着 |
数据 | 洪 | 水(| data flood) | 的 | 预言 |
数据 | ， | 硬件 | 推销 | 人员 | 会进 | 一步
能够 | 满足 | 处理 | 速度 | 的 | 要求 | 。 |
对 | 的 | ， | 但 | 是 | 我们 | 值得 | 停下 |
务 | 进行 | 适当 | 的 | 再 | 认识 | 。 |
近 | 年来 | ， | 数据 | 挖掘 | 和 | 机器 | 学习 | 在 | 我们 | 周围 | 持续 | 火爆 | ， | 各种 |
媒体 | 也 | 不断 | 推送 | 着 | 海量 | 的 | 数据 | 。 | 仔细 | 观察 | 就 | 能 | 发现 | ， | 实
际 | 应用 | 中 | 的 | 那些 | 机器 | 学习 | 算法 | 与 | 多 | 年前 | 并 | 没有 | 什么 | 两样 |
； | 它们 | 只 | 是 | 在 | 应用 | 的 | 数据 | 规模 | 上 | 有些 | 不同 | 。 | 历数 | 一 | 下 |
产生 | 数据 | 的 | 组织 | ， | 至少 | 在 | 我 | 看来 | ， | 数目 | 其实 | 并 | 不 | 多 | 。 |
无非 | 是 | Google | 、 | Facebook | 、 | Twitter | 、 | NetFlix | 以及 | 其 | 他 | 为数 | 不
| 多 | 的 | 机构 | 在 | 使用 | 若 | 干学 | 习算法 | 和 | 工具 | ， | 这些 | 算法 | 和 | 工具 |
使 | 得 | 他们 | 能够 | 对 | 数据 | 进行 | 测试 | 分析 | 。 | 那么 | ， | 真正 | 的 | 问题 |
是 | ： | “ | 对于 | 其 | 他人 | ， | 大数 | 据 | 框架 | 下 | 的 | 算法 | 和 | 工具 | 的 | 作用
| 是 | 什么 | 呢 | ？ | ” |
我承认 | 本书 | 将 | 多 | 次 | 提及 | 大 | 数据 | 和 | 机器 | 学习 | 之间 | 的 | 关系 | ， |
这 | 是 | 我 | 无法 | 忽视 | 的 | 一个 | 客观 | 问题 | ； | 但 | 是 | 它 | 只 | 是 | 一个 | 很
| 小 | 的 | 因素 | ， | 终极 | 目标 | 是 | 如何 | 利用 | 可用 | 数据 | 获取 | 数据 | 的 | 本质

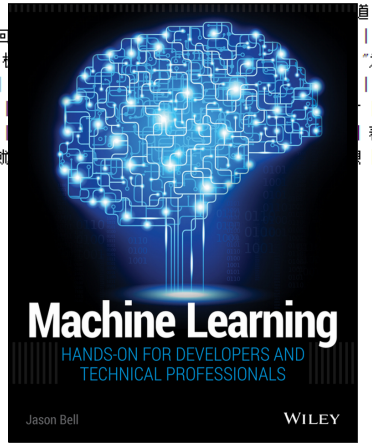

Jason Bell. *Machine Learning: Hands-On for Developers and Technical Professionals*. Wiley.2014

HMM的参数表达

- HMM由初始概率分布π(向量)、状态转移概率分布A(矩阵)以及观测概率分布B(矩阵)确定。π和A决定状态序列，B决定观测序列。因此，HMM可以用三元符号表示，称为HMM的三要素：

$$\lambda = (A, B, \pi)$$

HMM的两个基本性质

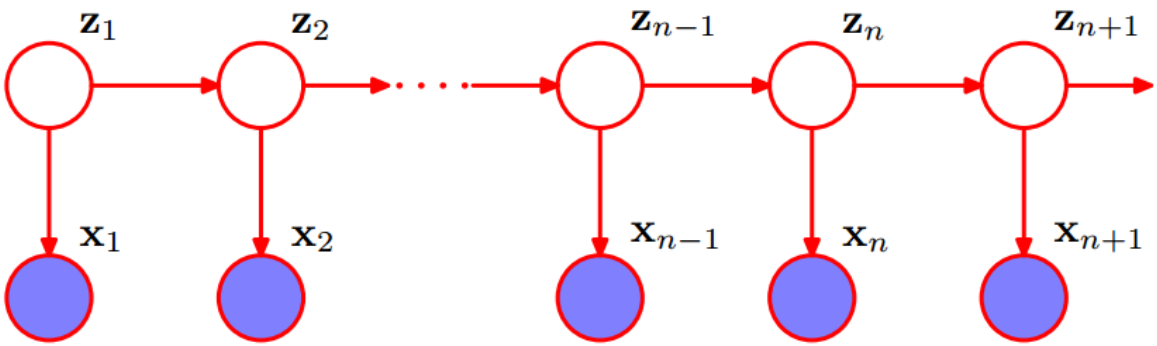

- 齐次假设：

$$P\left(i_t \middle| i_{t-1}, o_{t-1}, i_{t-2}, o_{t-2} \cdots i_1, o_1\right) = P\left(i_t \middle| i_{t-1}\right)$$

- 观测独立性假设：

$$P\left(o_t \middle| i_T, o_T, i_{T-1}, o_{T-1} \cdots i_1, o_1\right) = P\left(o_t \middle| i_t\right)$$

HMM的3个基本问题

- 概率计算问题：前向-后向算法——动态规划
  - 给定模型 $\lambda=(A,B,\pi)$ 和观测序列 $O=\{o_1,o_2,\ldots o_T\}$ 计算模型λ下观测序列O出现的概率P(O| λ)
- 学习问题：Baum-Welch算法(状态未知)——EM
  - 已知观测序列 $O=\{o_1,o_2,\ldots o_T\}$，估计模型 $\lambda=(A,B,\pi)$ 的参数，使得在该模型下观测序列P(O| λ)最大
- 预测问题：Viterbi算法——动态规划
  - 解码问题：已知模型 $\lambda=(A,B,\pi)$ 和观测序列 $O=\{o_1,o_2,\ldots o_T\}$ 求给定观测序列条件概率P(I|O, λ)最大的状态序列I

定义：前向概率-后向概率

$$\alpha_i(t) = p(y_1, y_2, \ldots y_t, q_t = i|\lambda)$$

$$\beta_i(t) = p(y_{t+1}, \ldots, y_T|q_t = i, \lambda)$$

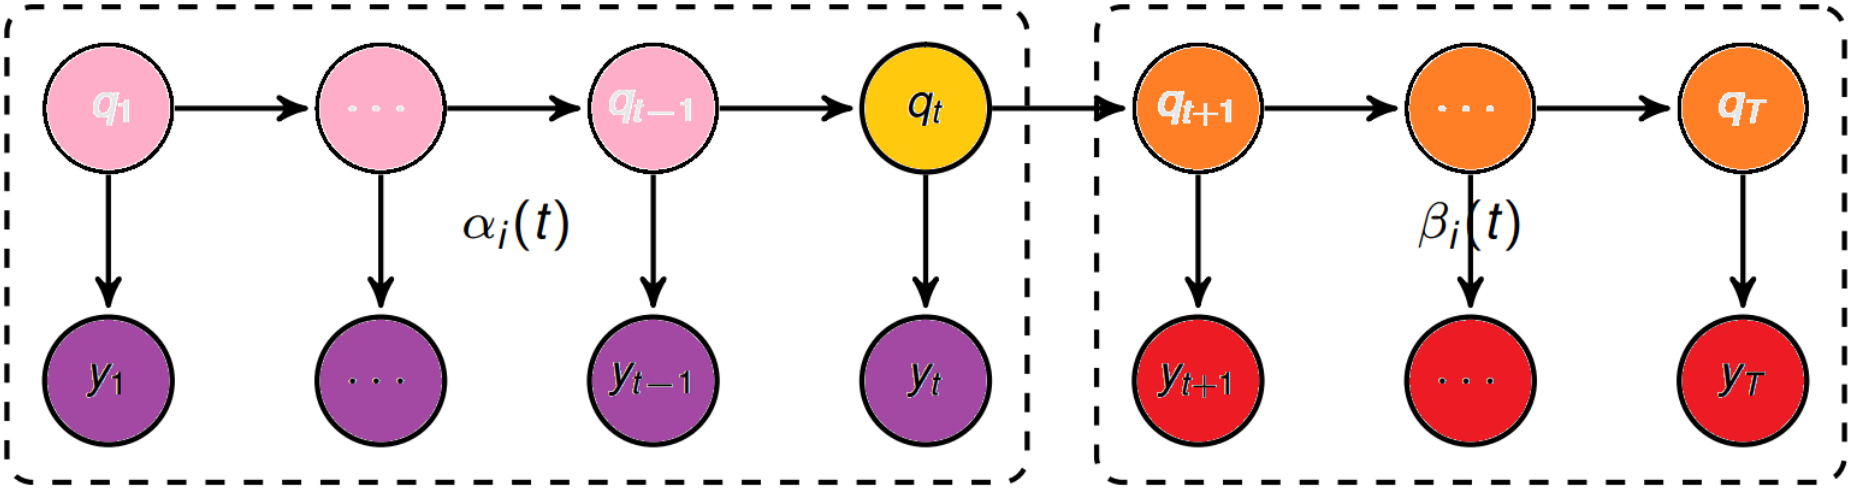

前向算法

- 定义：给定λ，定义到时刻t部分观测序列为o1,o2…ot且状态为qi的概率称为前向概率，记做：

$$\alpha_t(i) = P(o_1, o_2, \cdots o_t, i_t = q_i | \lambda)$$

  - 可以递推计算前向概率$\alpha_t(i)$及观测序列概率P(O|λ)

前向算法 $\alpha_t(i) = P(o_1, o_2, \cdots o_t, i_t = q_i | \lambda)$

- 初值： $\alpha_1(i) = \pi_i b_{io_1}$

- 递推：对于t=1,2…T-1

$$\alpha_{t+1}(i) = \left(\sum_{j=1}^{N} \alpha_t(j) a_{ji} \right) b_{io_{t+1}}$$

- 最终： $P(O|\lambda) = \sum_{i=1}^{N} \alpha_T(i)$

后向算法

- 定义：给定λ，定义到时刻t状态为qi的前提下，从t+1到T的部分观测序列为$o_{t+1},o_{t+2}\ldots o_T$的概率为后向概率，记做：

$$\beta_t(i)=P(o_{t+1},o_{t+2},\cdots o_T|i_t=q_i,\lambda)$$

- 可以递推计算后向概率$\beta_t(i)$及观测序列概率$P(O|\lambda)$

后向算法 $\beta_t(i)=P(o_{t+1},o_{t+2},\cdots o_T|i_t=q_i,\lambda)$

- 初值： $\beta_T(i)=1$

- 递推：对于t=T-1,T-2…,1

$$\beta_t(i)=\left(\sum_{j=1}^{N}a_{ij}b_{jo_{t+1}}\beta_{t+1}(j)\right)$$

- 最终： $P(O|\lambda)=\sum_{i=1}^{N}\pi_i b_{io_1}\beta_1(i)$

前后向关系

$\alpha_i(t) = p(y_1, y_2, \ldots y_t, q_t = i|\lambda)$ $\beta_i(t) = p(y_{t+1}, \ldots, y_T|q_t = i, \lambda)$

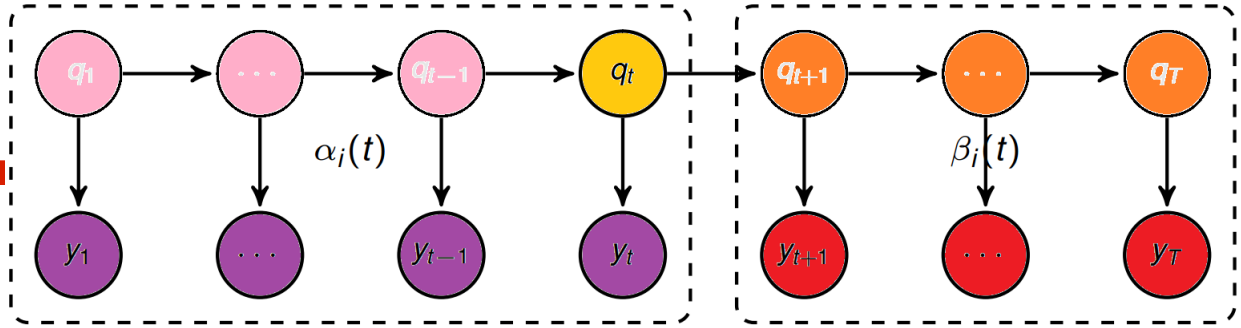

- 根据定义：

$$
\begin{aligned}
&P(i_t = q_i, O|\lambda) \\
&= P(O|i_t = q_i, \lambda)P(i_t = q_i|\lambda) \\
&= P(o_1, \cdots o_t, o_{t+1}, \cdots o_T|i_t = q_i, \lambda)P(i_t = q_i|\lambda) \\
&= P(o_1, \cdots o_t|i_t = q_i, \lambda)P(o_{t+1}, \cdots o_T|i_t = q_i, \lambda)P(i_t = q_i|\lambda) \\
&= P(o_1, \cdots o_t, i_t = q_i|\lambda)P(o_{t+1}, \cdots o_T|i_t = q_i, \lambda) \\
&= \alpha_t(i)\beta_t(i)
\end{aligned}
$$

单个状态的概率 $P(i_t = q_i, O|\lambda) = \alpha_t(i)\beta_t(i)$

- 求给定模型λ和观测O，在时刻t处于状态qi的概率。
- 记：$\gamma_t(i) = P(i_t = q_i | O, \lambda)$

单个状态的概率

- 根据前向后向概率的定义，

$$P(i_t = q_i, O|\lambda) = \alpha_t(i)\beta_t(i)$$

$$\gamma_t(i) = P(i_t = q_i|O,\lambda) = \frac{P(i_t = q_i, O|\lambda)}{P(O|\lambda)}$$

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{i=1}^{N}\alpha_t(i)\beta_t(i)}$$

γ的意义

- 在每个时刻t选择在该时刻最有可能出现的状态i_t^*，从而得到一个状态序列$I^*=\{i_1^*, i_2^* \cdots i_T^*\}$，将它作为预测的结果。
- 给定模型和观测序列，时刻t处于状态qi的概率为：

$$\gamma_t(i)=\frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)}=\frac{\alpha_t(i)\beta_t(i)}{\sum_{i=1}^{N}\alpha_t(i)\beta_t(i)}$$

两个状态的联合概率

- 求给定模型λ和观测O，在时刻t处于状态qi并且时刻t+1处于状态qj的概率。

$$\xi_t(i,j) = P(i_t = q_i, i_{t+1} = q_j | O, \lambda)$$

两个状态的联合概率

$$\xi_t(i,j) = P(i_t = q_i, i_{t+1} = q_j | O, \lambda)$$

$$= \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{P(O|\lambda)}$$

$$= \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{\sum_{i=1}^{N}\sum_{j=1}^{N} P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}$$

$$P(i_t = q_i, i_{t+1} = q_j, O | \lambda) = \alpha_t(i) a_{ij} b_{jo_{t+1}} \beta_{t+1}(j)$$

期望

- 在观测O下状态i出现的期望：

$$\sum_{t=1}^{T} \gamma_t(i)$$

- 在观测O下状态i转移到状态j的期望：

$$\sum_{t=1}^{T-1} \xi_t(i,j)$$

学习算法

- 若训练数据包括观测序列和状态序列，则HMM的学习非常简单，是监督学习；
- 若训练数据只有观测序列，则HMM的学习需要使用EM算法，是非监督学习。

大数定理

- 假设已给定训练数据包含S个长度相同的观测序列和对应的状态序列$\{(O_1,I_1), (O_2,I_2)\ldots (O_s,I_s)\}$，那么，可以直接利用Bernoulli大数定理的结论“频率的极限是概率”，给出HMM的参数估计。

监督学习方法

- 初始概率 $\hat{\pi}_i = \dfrac{|q_i|}{\sum_i |q_i|}$

- 转移概率 $\hat{a}_{ij} = \dfrac{|q_{ij}|}{\sum_{j=1}^{N} |q_{ij}|}$

- 观测概率 $\hat{b}_{ik} = \dfrac{|s_{ik}|}{\sum_{k=1}^{M} |s_{ik}|}$

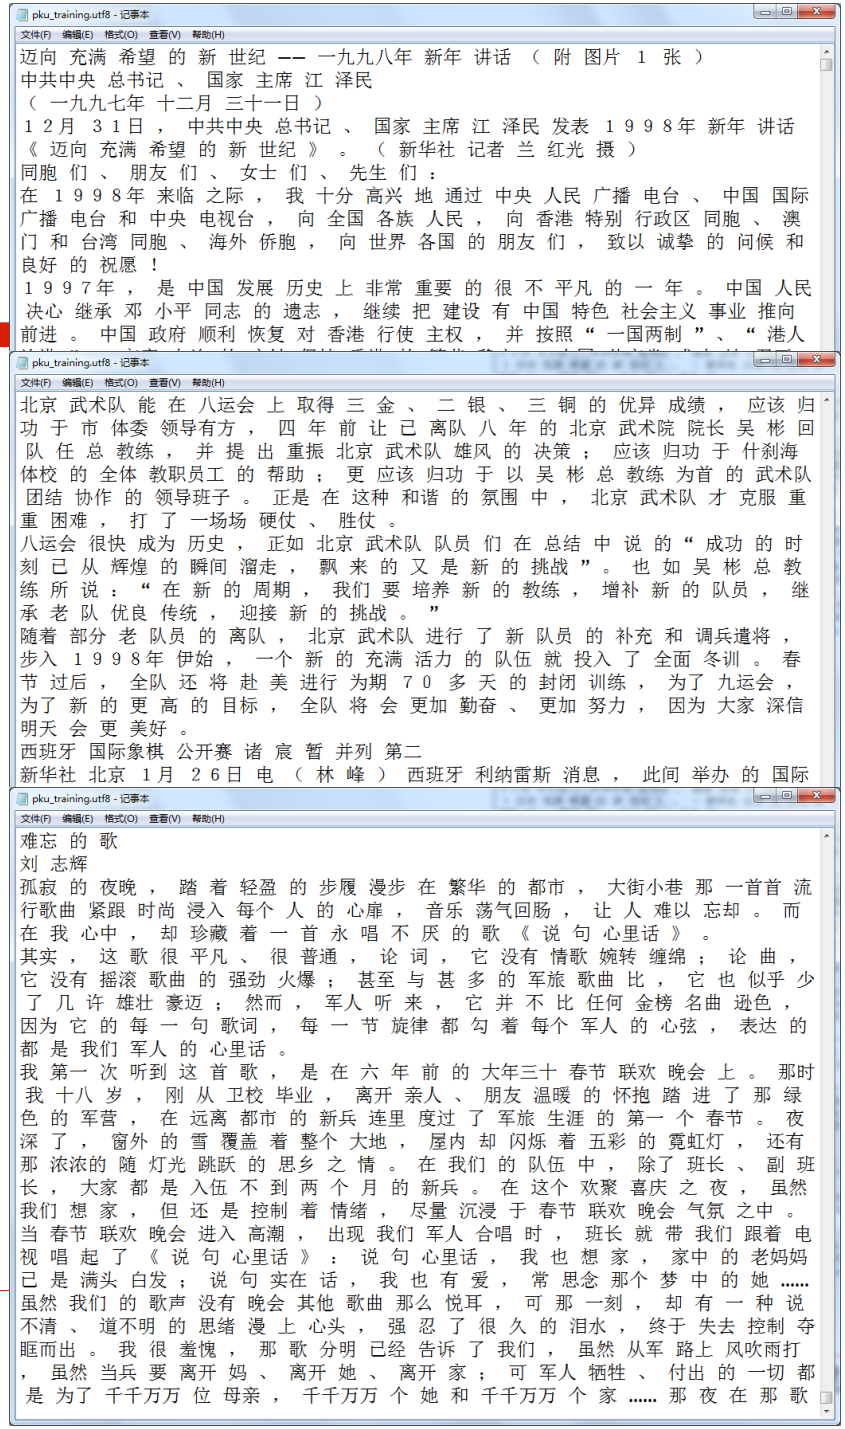

Baum-Welch算法

- 若训练数据只有观测序列，则HMM的学习需要使用EM算法，是非监督学习。

附：EM算法整体框架

Repeat until convergence {

(E-step) For each i, set

$$Q_i(z^{(i)}) := p(z^{(i)}|x^{(i)};\theta).$$

(M-step) Set

$$\theta := \arg\max_{\theta} \sum_i \sum_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)};\theta)}{Q_i(z^{(i)})}$$

}

Baum-Welch算法

- 所有观测数据写成$O=(o_1,o_2\ldots o_T)$，所有隐数据写成$I=(i_1,i_2\ldots i_T)$，完全数据是$(O,I)=(o_1,o_2\ldots o_T,i_1,i_2\ldots i_T)$，完全数据的对数似然函数是$\ln P(O,I|\lambda)$
- 假设$\bar{\lambda}$是HMM参数的当前估计值，λ为待求的参数。

$$Q(\lambda,\bar{\lambda})=\sum_I(\ln P(O,I|\lambda))P(I|O,\bar{\lambda})$$

$$=\sum_I \ln P(O,I|\lambda)\frac{P(O,I|\bar{\lambda})}{P(O,\bar{\lambda})}$$

$$\propto\sum_I \ln P(O,I|\lambda)P(O,I|\bar{\lambda})$$

EM过程

- 根据 $P(O,I|\lambda)=P(O|I,\lambda)P(I|\lambda)$

$$=\pi_{i_1}b_{i_1o_1}a_{i_1i_2}b_{i_2o_2}\cdots a_{i_{T-1}i_T}b_{i_To_T}$$

- 函数可写成

$$Q(\lambda,\bar{\lambda})=\sum_I \ln P(O,I|\lambda)P(O,I|\bar{\lambda})$$

$$=\sum_I \ln \pi_{i_1} P(O,I|\bar{\lambda})$$

$$+\sum_I\left(\sum_{t=1}^{T-1}\ln a_{i_ti_{t+1}}\right)P(O,I|\bar{\lambda})$$

$$+\sum_I\left(\sum_{t=1}^{T}\ln b_{i_to_t}\right)P(O,I|\bar{\lambda})$$

极大化

- 极大化Q，求得参数A,B,π
- 由于该三个参数分别位于三个项中，可分别极大化

$$\sum_{I} \ln \pi_{i_1} P\left(O, I \middle| \bar{\lambda}\right) = \sum_{i=1}^{N} \ln \pi_{i_1} P\left(O, i_1 = i \middle| \bar{\lambda}\right)$$

- 注意到πi满足加和为1，利用拉格朗日乘子法，得到：

$$\sum_{i=1}^{N} \ln \pi_i P\left(O, i_1 = i \middle| \bar{\lambda}\right) + \gamma\left(\sum_{i=1}^{N} \pi_i - 1\right)$$

初始状态概率 $\sum_{i=1}^{N} \ln \pi_i P\left(O, i_1 = i \middle| \bar{\lambda}\right) + \gamma\left(\sum_{i=1}^{N} \pi_i - 1\right)$

- 对上式相对于πi求偏导，得到：

$$P\left(O, i_1 = i \middle| \bar{\lambda}\right) + \gamma \pi_i = 0$$

- 对i求和，得到：

$$\gamma = -P\left(O \middle| \bar{\lambda}\right)$$

- 从而得到初始状态概率：

$$\pi_i = \frac{P\left(O, i_1 = i \middle| \bar{\lambda}\right)}{P\left(O \middle| \bar{\lambda}\right)} = \frac{P\left(O, i_1 = i \middle| \bar{\lambda}\right)}{\sum_{i=1}^{N} P\left(O, i_1 = i \middle| \bar{\lambda}\right)} = \frac{\gamma_1(i)}{\sum_{i=1}^{N} \gamma_1(i)}$$

转移概率和观测概率

- 第二项可写成：

$$\sum_{I}\left(\sum_{t=1}^{T-1}\ln a_{i_t i_{t+1}}\right)P\left(O,I\middle|\bar{\lambda}\right)=\sum_{i=1}^{N}\sum_{j=1}^{N}\sum_{t=1}^{T-1}\ln a_{ij}P\left(O,i_t=i,i_{t+1}=j\middle|\bar{\lambda}\right)$$

- 仍然使用拉格朗日乘子法，得到

$$a_{ij}=\frac{\sum_{t=1}^{T-1}P\left(O,i_t=i,i_{t+1}=j\middle|\bar{\lambda}\right)}{\sum_{t=1}^{T-1}P\left(O,i_t=i\middle|\bar{\lambda}\right)}=\frac{\sum_{t=1}^{T-1}\xi_t(i,j)}{\sum_{t=1}^{T-1}\gamma_t(i)}$$

- 同理，得到：

$$b_{ik}=\frac{\sum_{t=1}^{T}P\left(O,i_t=i\middle|\bar{\lambda}\right)I(o_t=v_k)}{\sum_{t=1}^{T}P\left(O,i_t=i\middle|\bar{\lambda}\right)}=\frac{\sum_{t=1,o_t=v_k}^{T}\gamma_t(i)}{\sum_{t=1}^{T}\gamma_t(i)}$$

预测算法

- 近似算法
- Viterbi算法

预测的近似算法

- 在每个时刻t选择在该时刻最有可能出现的状态i_t^*，从而得到一个状态序列$I^*=\{i_1^*, i_2^* \cdots i_T^*\}$，将它作为预测的结果。
- 给定模型和观测序列，时刻t处于状态qi的概率为：

$$\gamma_t(i)=\frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)}=\frac{\alpha_t(i)\beta_t(i)}{\sum_{i=1}^{N}\alpha_t(i)\beta_t(i)}$$

- 选择概率最大的i作为最有可能的状态
  - 会出现此状态在实际中可能不会发生的情况

算法：走棋盘/格子取数

- 给定m*n的矩阵，每个位置是一个非负整数，从左上角开始，每次只能朝右和下走，走到右下角，求总和最小的路径。

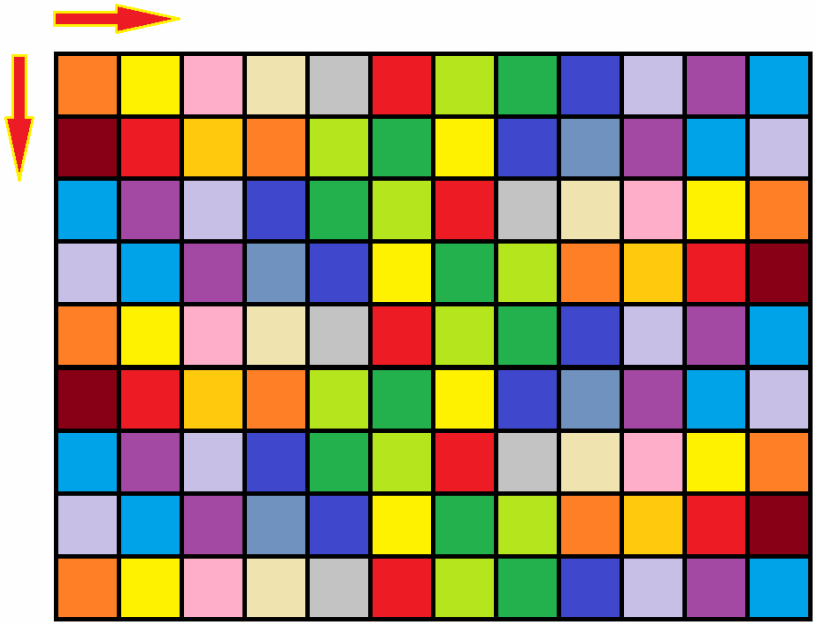

问题分析

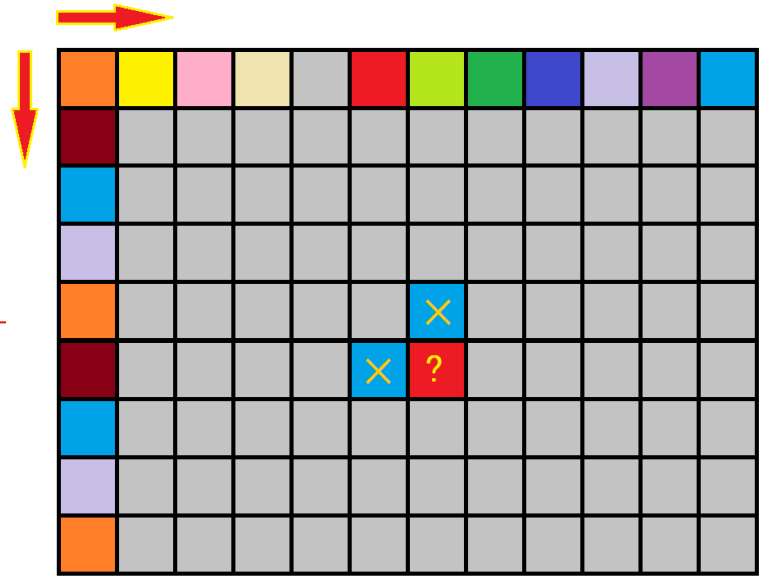

- 走的方向决定了同一个格子不会经过两次。
  - 若当前位于(x,y)处，它来自于哪些格子呢？
  - dp[0,0]=a[0,0] / 第一行(列)累积
  - dp[x,y] = min(dp[x-1,y]+a[x,y],dp[x,y-1]+a[x,y])
  - 即：dp[x,y] = min(dp[x-1,y],dp[x,y-1]) +a[x,y]
- 思考：若将上述问题改成“求从左上到右下的最大路径”呢？

Viterbi算法

- Viterbi算法实际是用动态规划解HMM预测问题，用DP求概率最大的路径(最优路径)，这是一条路径对应一个状态序列。
- 定义变量$\delta_t(i)$：在时刻t状态为i的所有路径中，概率的最大值。

给定m*n的矩阵，每个位置是一个非负整数，从左上角开始，每次只能朝右和下走，走到右下角，求总和最小的路径。

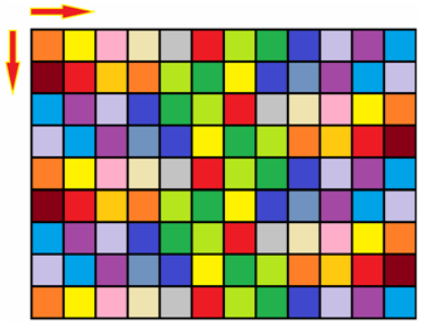

Viterbi算法

- 定义：

$$\delta_t(i) = \max_{i_1, i_2, \ldots i_{t-1}} P(i_t = i, i_{t-1}, \ldots i_1, o_t, \ldots o_1 | \lambda)$$

- 递推：

$$\delta_1(i) = \pi_i b_{io_1}$$

$$\delta_{t+1}(i) = \max_{i_1, i_2, \ldots i_t} P(i_{t+1} = i, i_t, \ldots i_1, o_{t+1}, \ldots o_1 | \lambda)$$

$$= \max_{1 \le j \le N} (\delta_t(j) a_{ji}) b_{io_{t+1}}$$

- 终止：

$$P^* = \max_{1 \le i \le N} \delta_T(i)$$

例

- 考察盒子球模型，观测向量O=“红白红”，试求最优状态序列。

$$\pi = \begin{pmatrix} 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \quad A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix} \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}$$

解：观测向量O=“红白红” $\pi = \begin{pmatrix} 0.2 \\ 0.4 \\ 0.4 \end{pmatrix}$ $B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}$

- 初始化：
- 在t=1时，对于每一个状态i，求状态为i观测到o1=红的概率，记此概率为$\delta_1(t)$

$$\delta_1(i) = \pi_i b_{io_1} = \pi_i b_{i红}$$

- 求得$\delta_1(1)=0.1$
- $\delta_1(2)=0.16$
- $\delta_1(3)=0.28$

解：观测向量O=“红白红” $\begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}$ $B=\begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}$

- 在t=2时，对每个状态i，求在t=1时状态为j观测为红并且在t=2时状态为i观测为白的路径的最大概率，记概率为$\delta_2(t)$，则：

$$\delta_{t+1}(i)=\max_{1\le j\le 3}\left(\delta_1(j)a_{ji}\right)b_{io_2}=\max_{1\le j\le 3}\left(\delta_1(j)a_{ji}\right)b_{i白}$$

- 求得

$$\delta_2(1)=\max_{1\le j\le 3}\left(\delta_1(j)a_{j1}\right)b_{i白}$$

$$=\max\{0.10\times 0.5,0.16\times 0.3,0.28\times 0.2\}\times 0.5=0.028$$

- 同理：
  - $\delta_2(2)=0.0504$
  - $\delta_2(3)=0.042$

解：观测向量O=“红白红”

- 同理，求得
- $\delta_3(1)=0.00756$
- $\delta_3(2)=0.01008$
- $\delta_3(3)=0.0147$

- 从而，最大是$\delta_3(3)= 0.0147$，根据每一步的最大，得到序列是(3,3,3)

求最优路径图解

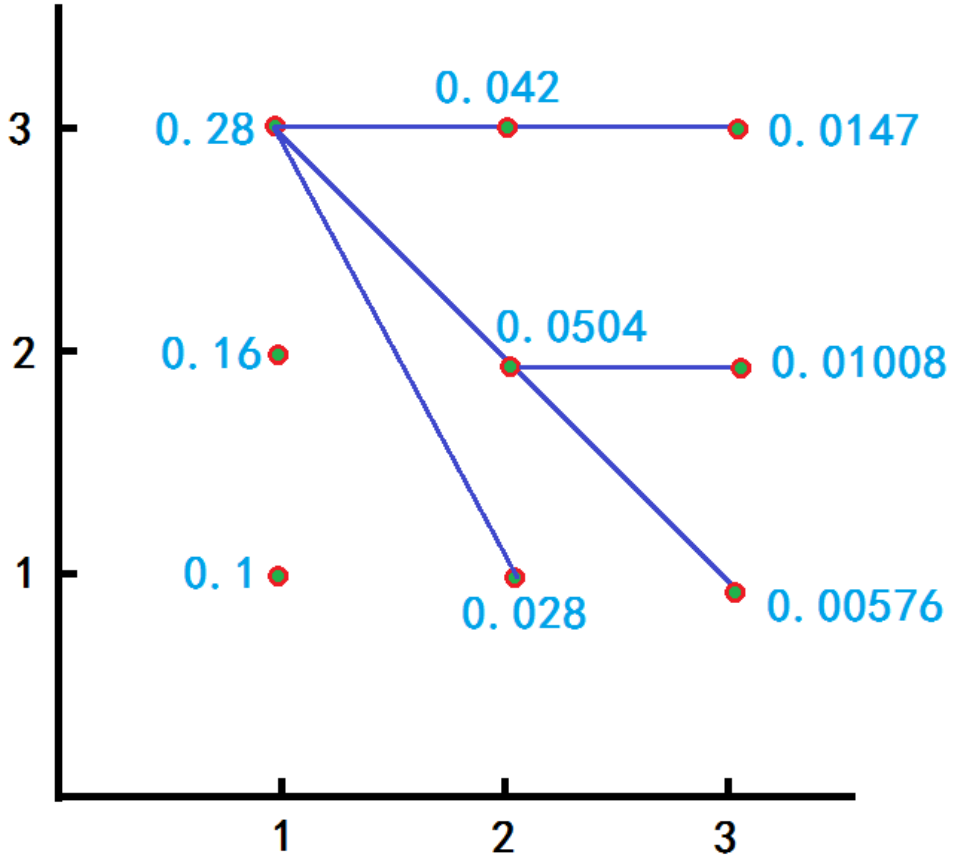

Baum-Welch code：初始化

```
if __name__ == "__main__":
    # 初始化pi,A,B
    pi = [random.random() for x in range(4)]    # 初始分布
    log_normalize(pi)
    A = [[random.random() for y in range(4)] for x in range(4)] # 转移矩阵
    A[0][0] = A[0][3] = A[1][0] = A[1][3]\
        = A[2][1] = A[2][2] = A[3][1] = A[3][2] = 0 # 不可能事件
    B = [[random.random() for y in range(65536)] for x in range(4)]
    for i in range(4):
        log_normalize(A[i])
        log_normalize(B[i])
    baum_welch(pi, A, B)
    save_parameter(pi, A, B)
```

Baum-Welch：主函数

```
def baum_welch(pi, A, B):
    f = file(".\\text\\1.txt")
    sentence = f.read()[3:].decode('utf-8') # 跳过文件头
    f.close()
    T = len(sentence)   # 观测序列
    alpha = [[0 for i in range(4)] for t in range(T)]
    beta = [[0 for i in range(4)] for t in range(T)]
    gamma = [[0 for i in range(4)] for t in range(T)]
    ksi = [[[0 for j in range(4)] for i in range(4)] for t in range(T-1)]
    for time in range(100):
        calc_alpha(pi, A, B, sentence, alpha)    # alpha(t,i):给定lamda，在时刻t的状态为i
        calc_beta(pi, A, B, sentence, beta)      # beta(t,i): 给定lamda和时刻t的状态i，观
        calc_gamma(alpha, beta, gamma)           # gamma(t,i): 给定lamda和O，在时刻t状态
        calc_ksi(alpha, beta, A, B, sentence, ksi)    # ksi(t,i,j): 给定lamda和O，在时刻t
        bw(pi, A, B, alpha, beta, gamma, ksi, sentence) #baum_welch算法
```

前向-后向

```
def calc_alpha(pi, A, B, o, alpha):
    for i in range(4):
        alpha[0][i] = pi[i] + B[i][ord(o[0])]
    T = len(o)
    temp = [0 for i in range(4)]
    del i
    for t in range(1, T):
        for i in range(4):
            for j in range(4):
                temp[j] = (alpha[t-1][j] + A[j][i])
            alpha[t][i] = log_sum(temp)
            alpha[t][i] += B[i][ord(o[t])]
```

```
def calc_beta(pi, A, B, o, beta):
    T = len(o)
    for i in range(4):
        beta[T-1][i] = 1
    temp = [0 for i in range(4)]
    del i
    for t in range(T-2, -1, -1):
        for i in range(4):
            beta[t][i] = 0
            for j in range(4):
                temp[j] = A[i][j] + B[j][ord(o[t+1])] + beta[t+1][j]
            beta[t][i] += log_sum(temp)
```

隐状态概率 – 隐状态转移概率

```python
def calc_gamma(alpha, beta, gamma):
    for t in range(len(alpha)):
        for i in range(4):
            gamma[t][i] = alpha[t][i] + beta[t][i]
        s = log_sum(gamma[t])
        for i in range(4):
            gamma[t][i] -= s
```

```python
def calc_ksi(alpha, beta, A, B, o, ksi):
    T = len(alpha)
    temp = [0 for x in range(16)]
    for t in range(T-1):
        k = 0
        for i in range(4):
            for j in range(4):
                ksi[t][i][j] = alpha[t][i] + A[i][j] + B[j][ord(o[t+1])] + beta[t+1][j]
                temp[k] =ksi[t][i][j]
                k += 1
        s = log_sum(temp)
        for i in range(4):
            for j in range(4):
                ksi[t][i][j] -= s
```

EM迭代

```
def bw(pi, A, B, alpha, beta, gamma, ksi, o):
    T = len(alpha)
    for i in range(4):
        pi[i] = gamma[0][i]
    s1 = [0 for x in range(T-1)]
    s2 = [0 for x in range(T-1)]
    for i in range(4):
        for j in range(4):
            for t in range(T-1):
                s1[t] = ksi[t][i][j]
                s2[t] = gamma[t][i]
            A[i][j] = log_sum(s1) - log_sum(s2)
    s1 = [0 for x in range(T)]
    s2 = [0 for x in range(T)]
    for i in range(4):
        for k in range(65536):
            valid = 0
            for t in range(T):
                if ord(o[t]) == k:
                    s1[valid] = gamma[t][i]
                    valid += 1
                s2[t] = gamma[t][i]
            if valid == 0:
                B[i][k] = infinite
            else:
                B[i][k] = log_sum(s1[:valid]) - log_sum(s2)
```

MLE

```python
def mle():  # 0B/1M/2E/3S
    pi = [0] * 4   # npi[i]: i状态的个数
    a = [[0] * 4 for x in range(4)]     # na[i][j]: 从i状态到j状态的转移个数
    b = [[0]* 65536 for x in range(4)]  # nb[i][o]: 从i状态到o字符的个数
    f = file(".\\text\pku_training.utf8")
    data = f.read()[3:].decode('utf-8')
    f.close()
    tokens = data.split('  ')
    last_q = 2
    for token in tokens:
        n = len(token)
        if n <= 0:
            continue
        if n == 1:
            pi[3] += 1
            a[last_q][3] += 1   # 上一个词的结束(last_q)到当前状态(3S)
            b[3][ord(token[0])] += 1
            last_q = 3
            continue
        # 初始向量
        pi[0] += 1
        pi[2] += 1
        pi[1] += (n-2)
        # 转移矩阵
        a[last_q][0] += 1
        last_q = 2
        if n == 2:
            a[0][2] += 1
        else:
            a[0][1] += 1
            a[1][1] += (n-3)
            a[1][2] += 1
        # 发射矩阵
        b[0][ord(token[0])] += 1
        b[2][ord(token[n-1])] += 1
        for i in range(1, n-1):
            b[1][ord(token[i])] += 1
    # 正则化
    log_normalize(pi)
    for i in range(4):
        log_normalize(a[i])
        log_normalize(b[i])
    return [pi, a, b]
```


小象学院 ChinaHadoop.cn

Viterbi

```python
def viterbi(pi, A, B, o):
    T = len(o)   # 观测序列
    delta = [[0 for i in range(4)] for t in range(T)]
    pre = [[0 for i in range(4)] for t in range(T)]  # 前一个状态
    for i in range(4):
        delta[0][i] = pi[i] + B[i][ord(o[0])]
    for t in range(1, T):
        for i in range(4):
            delta[t][i] = delta[t-1][0] + A[0][i]
            for j in range(1,4):
                vj = delta[t-1][j] + A[j][i]
                if delta[t][i] < vj:
                    delta[t][i] = vj
                    pre[t][i] = j
            delta[t][i] += B[i][ord(o[t])]
    decode = [-1 for t in range(T)]  # 解码：回溯查找最大路径
    q = 0
    for i in range(1, 4):
        if delta[T-1][i] > delta[T-1][q]:
            q = i
    decode[T-1] = q
    for t in range(T-2, -1, -1):
        q = pre[t+1][q]
        decode[t] = q
    return decode
```

分词

```
def segment(sentence, decode):
    N = len(sentence)
    i = 0
    while i < N:  #B/M/E/S
        if decode[i] == 0 or decode[i] == 1:  # Begin
            j = i+1
            while j < N:
                if decode[j] == 2:
                    break
                j += 1
            print sentence[i:j+1], "/"
            i = j+1
        elif decode[i] == 3 or decode[i] == 2:  # single
            print sentence[i:i+1], "/"
            i += 1
        else:
            print 'Error:', i, decode[i]
            i += 1
```

HMM与中文分词

```
if __name__ == "__main__":
    pi, A, B = load_train()
    f = file(".\\text\\novel.txt")
    data = f.read()[3:].decode('utf-8')
    f.close()
    decode = viterbi(pi, A, B, data)
    segment(data, decode)
```

bug HMM

Console | Frames | Variables | Watches

```
Connected to pydev debugger (build 139.1001)
我 | 与 | 地坛 |
史 | 铁生 |
一 |
我 | 在 | 好 | 几 | 篇 | 小说 | 中 | 都 | 提到 | 过 | 一 | 座 | 废弃 | 的 | 古园 | ， | 实际 | 就 | 是 | 地坛 | 。 | 许多 | 年前 | 旅游业 | 还 | 没有 | 开
地坛 | 离 | 我家 | 很 | 近 | 。 | 或者 | 说 | 我家 | 离 | 地坛 | 很 | 近 | 。 | 总之 | ， | 只好 | 认为 | 这 | 是 | 缘分 | 。 | 地坛 | 在 | 我出 | 生前 |
它 | 等待 | 我 | 出生 | ， | 然后 | 又 | 等待 | 我活 | 到 | 最狂 | 妄 | 的 | 年龄 | 上 | 忽地 | 残废 | 了 | 双腿 | 。 | 四百 | 多 | 年里 | ， | 它 | 一面
自 | 从 | 那个 | 下午 | 我 | 无意 | 中进 | 了 | 这 | 园子 | ， | 就 | 再 | 没长 | 久 | 地离 | 开过 | 它 | 。 | 我 | 一 | 下子 | 就 | 理解 | 了 | 它 | 的 |
两 | 条 | 腿 | 残废 | 后 | 的 | 最初 | 几年 | ， | 我找 | 不 | 到 | 工作 | ， | 找 | 不到 | 去路 | ， | 忽然 | 间 | 几乎 | 什么 | 都 | 找 | 不到 | 了 | ，
除 | 去 | 几 | 座 | 殿堂 | 我 | 无法 | 进去 | ， | 除去 | 那 | 座 | 祭坛 | 我 | 不 | 能 | 上去 | 而 | 只能 | 从 | 各个 | 角度 | 张望 | 它 | ， | 地坛 | 的
剩 | 下 | 的 | 就 | 是 | 怎样活 | 的 | 问题 | 了 | ， | 这 | 却 | 不 | 是 | 在 | 某 | 一个 | 瞬间 | 就 | 能 | 完全 | 想透 | 的 | 、 | 不 | 是 | 一次性 | 解
二 |
我 | 才 | 想到 | ， | 当年 | 我 | 总是 | 独自 | 跑 | 到 | 地坛 | 去 | ， | 曾 | 经给 | 母亲 | 出 | 了 | 一个 | 怎样 | 的 | 难题 | 。 |
她 | 不 | 是 | 那种 | 光会 | 疼爱 | 儿子 | 而 | 不 | 懂得 | 理解 | 儿子 | 的 | 母亲 | 。 | 她 | 知道 | 我心 | 里 | 的 | 苦闷 | ， | 知道 | 不 | 该 | 阻止
有 | 一 | 回 | 我摇 | 车出 | 了 | 小院 | ； | 想 | 起 | 一件 | 什么 | 事 | 又 | 返身 | 回来 | ， | 看见 | 母亲 | 仍站 | 在 | 原地 | ， | 还 | 是 | 送 | 我
有 | 一次 | 与 | 一个 | 作家 | 朋友 | 聊天 | ， | 我问 | 他学 | 写作 | 的 | 最 | 初动 | 机是 | 什么 | ？ | 他想 | 了 | 一会 | 说 | ： | “为 | 我 | 母亲 | 。
在 | 我 | 的 | 头 | 一 | 篇 | 小 | 说 | 发表 | 的 | 时候 | ， | 在 | 我 | 的 | 小 | 说 | 第一 | 次 | 获奖 | 的 | 那些 | 日子 | 里 | ， | 我真 | 是 | 多么
只 | 是 | 到 | 了 | 这 | 时候 | ， | 纷纭 | 的 | 往事 | 才 | 在 | 我 | 眼前 | 幻现 | 得 | 清晰 | ， | 母亲 | 的 | 苦难 | 与 | 伟大 | 才 | 在 | 我 | 心 |
摇 | 着 | 轮椅 | 在 | 园中 | 慢慢 | 走 | ， | 又 | 是 | 雾霭 | 的 | 清晨 | ， | 又 | 是 | 骄阳 | 高 | 悬 | 的 | 白昼 | ， | 我 | 只想 | 着 | 一件 | 事 | ：
曾 | 有 | 过好 | 多 | 回 | ， | 我 | 在 | 这园 | 子里 | 呆得 | 太久 | 了 | ， | 母亲 | 就 | 来找 | 我 | 。 | 她 | 来找 | 我 | 又 | 不想 | 让 | 我 | 发觉 |
```

前言 |
数据 | ， | 数据 | ， | 数据 | ！ | 想 | 必在 | 新闻 | 、 | 报刊 | 等 | 媒介 | 的 | 持续 | 冲击 | 下 | ， | 人们 | 无法 | 摆 脱| 大 | 的 | 洗礼 | 。 | 现实 | 需求 | 推动 | 了 | 对 | 数据 | 的 | 学习 | 这些 | 数据 | 来 | 自于 | 社交 | 媒体 | 、 | 智能 | 手机 | 、 | “ | 物联网 | ”| ） | 、 | 传感器 | 等 | 任何 | 可以 | 产生 | 数 | 大 | 多 | 数数 | 据 | 挖掘 | 的 | 宣传 | 着 | 重于 | 数据 | 规模 | 数据 | 洪 | 水(| data flood) | 的 | 预言 | 告诉 | 人们 | 我们 | 无法 | 实时 | 处理 | 这些 | 数据 | ， | 硬件 | 推销 | 人员 | 会进 | 一步 | 卖 | 给 | 我们 | 需要 | 的 | 服务 | ， | 以期 | 能够 | 满足 | 处理 | 速度 | 的 | 要求 | 。 | 从 | 某种 | 程度 | 上来 | 说 | ， | 他们 | 是 | 对 | 的 | ， | 但 | 是 | 我们 | 值得 | 停下 | 来 | 思考 | 片刻 | ， | 并 | 对 | 手边 | 的 | 任务 | 进行 | 适当 | 的 | 再 | 认识 | 。 |
近 | 年来 | ， | 数据 | 挖掘 | 和 | 机器 | 学习 | 在 | 我们 | 周围 | 持续 | 火爆 | ， | 各种 | 媒体 | 也 | 不断 | 推送 | 着 | 海量 | 的 | 数据 | 。 | 仔细 | 观察 | 就 | 能 | 发现 | ， | 实际 | 应用 | 中 | 的 | 那些 | 机器 | 学习 | 算法 | 与 | 多 | 年前 | 并 | 没有 | 什么 | 两样 | ； | 它们 | 只 | 是 | 在 | 应用 | 的 | 数据 | 规模 | 上 | 有些 | 不同 | 。 | 历数 | 一 | 下 | 产生 | 数据 | 的 | 组织 | ， | 至少 | 在 | 我 | 看来 | ， | 数目 | 其实 | 并 | 不 | 多 | 。 | 无非 | 是 | Google | 、 | Facebook | 、 | Twitter | 、 | NetFlix | 以及 | 其 | 他 | 为数 | 不 | 多 | 的 | 机构 | 在 | 使用 | 若 | 干学 | 习算法 | 和 | 工具 | ， | 这些 | 算法 | 和 | 工具 | 使 | 得 | 他们 | 能够 | 对 | 数据 | 进行 | 测试 | 分析 | 。 | 那么 | ， | 真正 | 的 | 问题 | 是 | ： | “ | 对于 | 其 | 他人 | ， | 大数 | 据 | 框架 | 下 | 的 | 算法 | 和 | 工具 | 的 | 作用 | 是 | 什么 | 呢 | ？ | ”|
我承认 | 本书 | 将 | 多 | 次 | 提及 | 大 | 数据 | 和 | 机器 | 学习 | 之间 | 的 | 关系 | ， | 这 | 是 | 我 | 无法 | 忽视 | 的 | 一个 | 客观 | 问题 | ； | 但 | 是 | 它 | 只 | 是 | 一个 | 很 | 小 | 的 | 因素 | ， | 终极 | 目标 | 是 | 如何 | 利用 | 可用 | 数据 | 获取 | 数据 | 的 | 本质

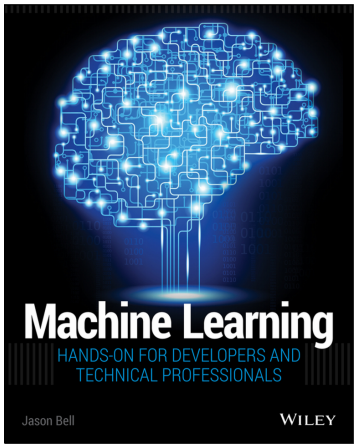

Jason Bell. *Machine Learning: Hands-On for Developers and Technical Professionals*. Wiley.2014

总结

- 马尔科夫模型可以用来解释贪心法和动态规划，后面的课程中将会以次为分析工具，统一贪心法和动态规划。
- HMM解决标注问题，在语音识别、NLP、生物信息、模式识别等领域被广泛使用。
  - 思考：可否用深度学习代替HMM?
- 加强算法模型和实践问题的相互转换能力。

参考文献

- 李航，统计学习方法，清华大学出版社，2012
- Christopher M. Bishop. *Pattern Recognition and Machine Learning Chapter 10.* Springer-Verlag, 2006
- Radiner L,Juang B. *An introduction of hidden markov Models*. IEEE ASSP Magazine, 1986

我们在这里

- 问题答疑：http://www.xxwenda.com/
  - 烦请邀请visio或其他人回答问题

- 本课程QQ群：
  - 471632108(小象学院：机器学习群)

感谢大家！

恳请大家批评指正！